

Frankfurt University
of Applied Sciences

– Fachbereich 2: Informatik und Ingenieurwissenschaften –

Deep-Learning-basierte Anomalieerkennung in Passantenfrequenzen

Projektarbeit im Rahmen des Bachelorstudiums

Bachelor of Science (B.Sc.)

vorgelegt am 29.08.2026 von

Sherwin Nourinfar, Wassim Hanane

Matrikelnummern: 1552887, 1583937

Referent : Daniel Helmer

Eidesstattliche Erklärung

Wir versichern hiermit, dass wir die vorliegende Arbeit selbständig verfasst und keine anderen als die im Literaturverzeichnis angegebenen Quellen benutzt haben.

Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder noch nicht veröffentlichten Quellen entnommen sind, sind als solche kenntlich gemacht.

Die Zeichnungen oder Abbildungen in dieser Arbeit sind von uns selbst erstellt worden oder mit einem entsprechenden Quellennachweis versehen.

Diese Arbeit ist in gleicher oder ähnlicher Form noch bei keiner anderen Prüfungsbehörde eingereicht worden.

Frankfurt, 29.08.2026



Sherwin Nourinfar



Wassim Hanane

Inhaltsverzeichnis

1 Einführung **2**

1.1 Motivation . . . 2

1.2 Zielsetzung . . . 2

2 Hintergrund **3**

2.1 Zeitreihen und Anomalien . . . 3

2.2 Erkennung mit Vorhersagen . . . 3

2.3 LSTM, Autoencoder und Transformer . . . 3

3 Stand der Technik **4**

3.1 Prognosebasierte Anomalieerkennung . . . 4

3.2 Transformer für Zeitreihenprognosen . . . 4

3.3 Anomalieerkennung durch Rekonstruktion . . . 4

3.4 Fairer Vergleich . . . 5

4 Entwickelte Methode **6**

4.1 Datengrundlage . . . 6

4.2 Datenqualität . . . 6

4.3 Bereinigung der Mehrfachmessungen . . . 8

4.4 Behandlung der Messlücken . . . 8

4.5 Kritische Betrachtung . . . 10

4.6 Forecaster . . . 11

4.6.1 Lernaufgabe und Eingaberepräsentation . . . 11

4.6.2 Architektur und Größenwahl . . . 12

4.6.3 Nichtkonformitätsscore und Intervallkalibrierung . . . 12

4.6.4 Kausale Alarmregel . . . 13

4.6.5 Umgang mit imputierten Zielwerten . . . 13

4.7 Transformer . . . 13

4.8 Autoencoder . . . 14

4.9 Baseline . . . 15

5 Evaluation der Methode **16**

5.1 Zeitliche Datentrennung 16

5.2 Bewertung der Prognosegüte 17

5.3 Anomalieinjektion 17

5.4 Punkt- und Ereignismetriken 18

5.5 Reproduzierbarkeit 18

6 Ergebnisse **19**

6.1 Training und Detektorkalibrierung 19

6.2 Prognosegüte im Testabschnitt 21

6.3 Anomaliekandidaten im nicht injizierten Testabschnitt 21

6.4 Ergebnisse der Anomalieinjektion 22

6.5 Vergleich der finalen Modelle 23

6.6 Diskussion und Limitationen 24

7 Zusammenfassung und Ausblick **25**

Literatur **26**

Kurzfassung

Diese Arbeit entwickelt und vergleicht vier Verfahren zur Erkennung auffälliger Passantenfrequenzen aus Bad Nauheim. Die neuronalen Modelle werden ohne reale Anomalieklassen selbstüberwacht trainiert; die Alarmregeln werden mit kontrollierten synthetischen Anomalien im Kalibrierungsabschnitt ausgewählt. Die Verweildauer bleibt eine zusätzliche Modellgröße, löst jedoch keinen Alarm aus. Der untersuchte API-Snapshot umfasst 30 Sensoren vom 30. Juni 2025 bis zum exklusiven Endzeitpunkt 1. Juli 2026. Die Datenaufbereitung verdichtet 537.810 Rohdatensätze zu 263.505 aktiven Sensorstunden und behandelt 17 gemeinsame Nullausfälle als fehlend. Von den aktiven Sensorstunden sind 177.004 beobachtet und 86.501 imputiert. Die Ersatzwerte stammen ausschließlich aus Vergangenheit oder Trainingsprofilen; sie bleiben als gekennzeichneter Kontext erhalten, werden aber nicht als Lern- oder Bewertungsziel verwendet.

Untersucht werden ein Quantil-LSTM mit 21.598 Parametern, ein Quantil-Transformer mit 61.398 Parametern, ein LSTM-Autoencoder mit 50.562 Parametern und ein robuster $t-24$-Detektor ohne trainierbare Modellparameter. Eine chronologische Kandidatensuche wird durch Successive Halving verkürzt; die jeweils zwei verbleibenden Konfigurationen werden bis zum Early-Stopping-Kriterium oder zur jeweiligen Epochenobergrenze trainiert. Bei starken künstlichen Anomalien, gleichgewichtet über die fünf untersuchten Typen, erreicht der LSTM-Forecaster einen mittleren Punkt-F1 von 0,674 und einen Ereignis-F1 von 0,876. Der Transformer erreicht 0,670 beziehungsweise 0,824, der Autoencoder 0,534 beziehungsweise 0,653 und die saisonale Methode 0,436 beziehungsweise 0,498. Der Transformer liefert auf den gemessenen Testzielen die genaueren Prognosen sowie die knapp höchste mittlere ROC-AUC und Average Precision. Die kalibrierte LSTM-Alarmregel erzielt dagegen den höchsten Punkt- und Ereignis-F1. Im nicht injizierten Testabschnitt markieren LSTM und Transformer 79 beziehungsweise 140 Stunden in 75 beziehungsweise 140 Ereignissen; 8.458 fehlende Messungen werden in 2.016 Datenqualitätsereignissen getrennt ausgewiesen. Die synthetischen Tests zeigen die erzielte Erkennungsleistung unter den definierten synthetischen Veränderungen. Die getrennten Punkt- und Ereignismetriken unterscheiden dabei zwischen stundengenauer Markierung und der Erkennung zusammenhängender Ereignisse. Das Fehlen vollständiger realer Markierungen sowie einer zeitlich und räumlich unabhängigen externen Datenquelle begrenzt weiterhin Aussagen über unbekannte reale Anomalien.

Kapitel 1

Einführung

Passantenfrequenzen weisen wiederkehrende zeitliche und räumliche Muster auf. Typischerweise unterscheiden sich Tag- und Nachtstunden, Werktage und Wochenenden sowie stark und schwach frequentierte Standorte. Abweichungen vom zeit- und standortabhängig erwarteten Verhalten werden in dieser Arbeit als Anomaliekandidaten betrachtet. Sie sind nicht automatisch mit einem fachlich bestätigten realen Ereignis gleichzusetzen. Vollständig fehlende Übertragungen werden getrennt als Datenqualitätsereignisse behandelt.

Datengrundlage ist ein API-Snapshot des Smart-City-Portals der Stadt Bad Nauheim mit Messungen von 30 Sensorstandorten im halboffenen Zeitraum vom 30. Juni 2025, 00:00 Uhr, bis zum 1. Juli 2026, 00:00 Uhr UTC [20]. Der globale Zeitraum umfasst 366 Tage; die einzelnen Sensorreihen besitzen jedoch unterschiedliche Messbeginne und teilweise umfangreiche Lücken.

1.1 Motivation

Eine automatisierte Erkennung auffälliger Verläufe kann die manuelle Prüfung umfangreicher Sensordaten unterstützen. Erschwert wird sie durch fehlende vollständige reale Anomaliekennzeichnungen und ein Normalverhalten, das mit Tageszeit, Wochentag und Standort variiert. Ein einheitlicher statischer Grenzwert kann diese Unterschiede nur eingeschränkt berücksichtigen [5].

1.2 Zielsetzung

Ziel der Arbeit ist der Vergleich von vier getrennten Verfahren zur Erkennung auffälliger Passantenfrequenzen. Quantil-LSTM, Quantil-Transformer und LSTM-Autoencoder werden ohne reale Anomalieklassen selbstüberwacht trainiert; eine robuste saisonale $t - 24$-Methode dient als Baseline. Die Alarmregeln werden im Kalibrierungsabschnitt mit kontrollierten synthetischen Anomalien ausgewählt und anschließend mit identischen Kriterien verglichen.

Die zentrale Forschungsfrage lautet: Wie unterscheiden sich die vier Verfahren hinsichtlich der punkt- und ereignisbasierten Erkennung der fünf definierten synthetischen Anomaliearten in den stündlichen Passantenfrequenzen von Bad Nauheim?

Bewertet wird damit die technische Erkennungsfähigkeit für definierte Veränderungen; belastbare Erkennungsraten für unbekannte reale Anomalien lassen sich ohne vollständige reale Labels nicht ableiten.

Die folgenden Kapitel behandeln Grundlagen, Stand der Technik, Methode, Evaluation und Ergebnisse; eine Zusammenfassung schließt die Arbeit ab.

Kapitel 2

Hintergrund

2.1 Zeitreihen und Anomalien

Eine Zeitreihe ordnet Messwerte chronologisch. Bei Passantenfrequenzen hängen benachbarte Stunden zusammen; zusätzlich wiederholen sich Tagesmuster. Eine Anomalie ist deshalb nicht zwingend ein großer absoluter Wert, sondern eine Abweichung vom zeit- und ortsabhängig erwarteten Verhalten. Punktanomalien betreffen einzelne Stunden. Sprunghafte Niveauwechsel (Level-Shifts), schleichende Verschiebungen (Drifts) und festgefrorene Sensorwerte (Stuck-at) erstrecken sich dagegen über mehrere Stunden.

Im vorliegenden Datensatz fehlen vollständige reale Anomaliekennzeichnungen. Das Lernen des Normalverhaltens erfolgt daher selbstüberwacht: Aus vorhandenen Messwerten wird ein künstliches Lernziel erzeugt, ohne Klassen wie "normal" oder "anomal" vorzugeben. Erst der Fehler zwischen Modellschätzung und Messung wird als Anomaliesignal verwendet.

2.2 Erkennung mit Vorhersagen

Ein Vorhersagemodell erhält die letzten w Zeitpunkte und schätzt den nächsten Wert $\hat{x}_t$. Ein großer Prognosefehler $|x_t - \hat{x}_t|$ deutet darauf hin, dass die Beobachtung nicht zum erlernten Verlauf passt. Zusätzliche Messgrößen können beim Lernen als Kontext dienen, ohne selbst Teil der Alarmentscheidung zu sein. Vorhersagegüte und Erkennungsleistung sind dabei nicht gleichbedeutend: Ein kleiner mittlerer Fehler garantiert noch keine klare Trennung seltener Anomalien.

2.3 LSTM, Autoencoder und Transformer

Long Short-Term Memory (LSTM) ist eine rekurrente Netzstruktur mit steuerbaren Speicherzuständen und eignet sich zur Verarbeitung geordneter Sequenzen [4]. Ein LSTM kann ein Zeitfenster zu einem Zustandsvektor verdichten und daraus eine Prognose erzeugen.

Ein Autoencoder lernt dagegen, sein Eingabefenster zu rekonstruieren. Ein hoher Rekonstruktionsfehler kann eine unbekannte Struktur anzeigen. Prognose und Rekonstruktion beruhen somit auf unterschiedlichen Annahmen über normales Verhalten. Ein Transformer verarbeitet verschiedene Zeitpunkte mit Self-Attention und kann dadurch auch weiter auseinanderliegende Zusammenhänge direkt gewichten. Da der Mechanismus allein keine Reihenfolge kennt, wird die Position jedes Zeitpunkts zusätzlich kodiert [23]. Diese zusätzliche Freiheit ist vor allem bei längeren Reihen und einer größeren Datenbasis nützlich.

Kapitel 3

Stand der Technik

3.1 Prognosebasierte Anomalieerkennung

Hundman et al. verwenden LSTM-Prognosefehler und dynamische Schwellen zur Erkennung von Anomalien in Zeitreihen [5]. Globale rekurrente Prognosemodelle können Informationen über mehrere verwandte Zeitreihen teilen und zugleich reihenspezifische Merkmale berücksichtigen [15]. Quantilprognosen bilden zusätzlich die Unsicherheit einer Vorhersage ab, statt nur einen einzelnen Schätzwert auszugeben [3, 8]. Dropout kann die Anpassung eines Netzes an seine Trainingsbeispiele begrenzen [19].

Diese Arbeiten begründen die in dieser Arbeit untersuchten Bausteine Prognosefehler, gemeinsames Lernen, Sensorinformation, Quantilausgabe und Dropout. Sie bestimmen jedoch keine allgemein gültige optimale Schichtbreite für den vorliegenden Datensatz. Die konkreten Größen werden deshalb in Abschnitt 4.6.2 anhand des Datenumfangs und einer begrenzten Modellkomplexität festgelegt.

3.2 Transformer für Zeitreihenprognosen

Der ursprüngliche Transformer verbindet Multi-Head-Self-Attention mit Residualpfaden, positionsweisen Feedforward-Netzen und einer sinusförmigen Positionskodierung [23]. Xiong et al. zeigen, dass eine Layer-Normalisierung vor Attention und Feedforward-Netz stabilere Gradienten ermöglicht; diese Pre-LN-Anordnung reduziert zugleich die Notwendigkeit einer gesonderten Lernraten-Aufwärmphase [25].

Für lange Prognosefenster fasst PatchTST benachbarte Zeitpunkte zu Tokens zusammen und verkleinert dadurch die Attention-Matrix [13]. Das sequenzielle Eingabefenster der vorliegenden Arbeit umfasst jedoch nur 24 Stunden; ein getrenntes Wertepaar der Stunde $t - 168$ liefert zusätzlich eine Wochenreferenz, ohne die Attention-Sequenz zu verlängern. Damit einzelne Spikes und Dips erhalten bleiben, wird jede Stunde des Fensters als eigenes Token verwendet. Die guten Ergebnisse einfacher linearer Zeitreihenmodelle von Zeng et al. motivieren zusätzlich einen direkten linearen Pfad von den historischen Messwerten zur Prognose [26]. Er ergänzt die Attention, ersetzt sie aber nicht. Statische Sensorinformation, bekannte Kalendergrößen und Quantilausgaben orientieren sich an den Eingabearten probabilistischer Zeitreihen-Transformer [9]. Da der Datenumfang gegenüber großskaligen Benchmarkkorpora begrenzt ist, bleibt die konkrete Breite deutlich unter den Architekturen dieser Arbeiten und wird auf einem getrennten Tuningabschnitt gewählt.

3.3 Anomalieerkennung durch Rekonstruktion

Ein Autoencoder lernt, normale Eingabefolgen zu komprimieren und anschließend wiederherzustellen. Große Rekonstruktionsfehler dienen danach als Hinweis auf eine Abweichung. Malhotra et al. übertragen dieses

Prinzip auf mehrdimensionale Sensordaten. Ihr Modell verwendet jeweils eine LSTM-Schicht im Encoder und im Decoder und zeigt, dass ein solcher Aufbau sowohl periodische als auch weniger gut vorhersagbare Reihen verarbeiten kann [12]. Die Arbeit begründet den verwendeten Grundaufbau, gibt aber keine allgemein optimale Zahl von LSTM-Einheiten für andere Datensätze vor.

Denoising-Autoencoder erhalten beim Training eine teilweise verdeckte Eingabe und sollen trotzdem die unveränderten Werte rekonstruieren. Dadurch wird das reine Kopieren der Eingabe erschwert [24]. Neuere Verfahren verwenden ebenfalls zeitliche Maskierung, kombinieren diese jedoch teilweise mit mehreren Transformern, Frequenzdarstellungen und zusätzlichen Fehlerfunktionen [2]. Für den kontrollierten Vergleich und das 24-Stunden-Eingabefenster dieser Untersuchung wird ausschließlich das Maskierungsprinzip übernommen. Der Autoencoder rekonstruiert dabei die unverdeckte Sequenz. Bei den beiden Prognosemodellen dient eine kürzere Maskierung nur während des Trainings als Robustheitsaugmentation; deren Lernziel bleibt die nächste Stunde.

3.4 Komplexität und fairer Vergleich

Aktuelle Vergleichsarbeiten warnen davor, eine komplexere Architektur automatisch als besseren Anomaliedetektor zu betrachten. Sarfraz et al. zeigen, dass zusätzliche Komplexität häufig nur geringe Vorteile bringt, und empfehlen einfache, verständliche Vergleichsmodelle [16]. Der umfangreiche TSB-AD-Vergleich kommt ebenfalls zu dem Ergebnis, dass einfache neuronale und statistische Verfahren viele moderne Netze übertreffen können [10].

Deshalb wird kein Anspruch erhoben, mit einer bestimmten Schichtgröße einen allgemein besten Stand der Technik zu erreichen. Stattdessen werden Literaturbausteine auf kompakte LSTM-, Transformer- und Autoencoder-Modelle übertragen und mit denselben Zeitabschnitten, künstlichen Anomalien und Kennzahlen geprüft. Ein robuster saisonaler Detektor ohne trainierbare Parameter bildet zusätzlich die einfache Referenz. Eine zusätzliche Schicht wird nur dann gerechtfertigt, wenn sie für die jeweilige Lernaufgabe einen nachvollziehbaren Zweck erfüllt.

Kapitel 4

Entwickelte Methode

Dieses Kapitel beschreibt zunächst die reproduzierbare Aufbereitung der Rohdaten und anschließend die vier untersuchten Anomaliedetektoren. Methodische Entscheidungen werden von den später berichteten Ergebnissen getrennt dargestellt.

4.1 Datengrundlage

Die Rohdaten stammen aus dem Smart-City-Portal der Stadt Bad Nauheim und liegen als API-Abruf in Form einer JSON-Datei mit 537.810 Einzelmessungen vor [20]. Nach Angaben des Portals registrieren und zählen die Sensoren anonym bestimmte von Smartphones ausgesendete Funkfrequenzen; MAC-Adressen und andere personenbezogene Daten werden nicht ausgelesen. Die städtische Datenstrategie weist zudem darauf hin, dass wiederkehrende Besucher nur mit einer gewissen Unsicherheit erfasst werden [11]. `visitors` ist daher als aus Gerätesignalen abgeleiteter Proxy und nicht als direkte Personen-Ground-Truth zu interpretieren. Jede Messung gehört zu einem von 30 Sensorstandorten in der Innenstadt und im Kurpark von Bad Nauheim und enthält neben dem Zeitstempel diesen Proxy sowie die mittlere Verweildauer (`avgDuration`). Der API-Abruf enthält für `avgDuration` kein Einheitenfeld. Werte dieser Größe werden daher im Folgenden in der unveränderten numerischen API-Einheit angegeben, ohne sie unbelegt als Minuten oder Sekunden zu interpretieren. Der globale Erfassungszeitraum reicht vom 30. Juni 2025, 00:00 Uhr, bis zum exklusiven Endzeitpunkt 1. Juli 2026, 00:00 Uhr UTC und umfasst 8.784 Stunden. Da nicht alle Sensoren während des gesamten Zeitraums Messungen lieferten, gilt ein Sensor ab seiner ersten Messung bis zum globalen Datenende als aktiv. Dadurch entstehen 263.505 aktive Sensorstunden. Ein ausbleibender Datenstrom am Reihenende bleibt damit als möglicher Sensorausfall sichtbar.

4.2 Datenqualität

Die explorative Analyse untersucht zunächst Aufbau, Mehrfachmessungen, Verteilungen und Beziehungen der Messgrößen. Ein vollständiges Stundenraster macht zusätzlich vollständig fehlende Messstunden sichtbar. In vorhandenen Rohzeilen fehlen weder `visitors` noch `avgDuration`; eine ausgefallene Stunde fehlt jedoch als ganze Zeile und wäre mit einer reinen Suche nach leeren Einzelwerten nicht erkennbar.

Mehrfachmessungen: Für 139.027 Kombinationen aus Sensor und Stunde enthält der Datensatz mehrere Einträge, in der Spitze 34 Messungen für dieselbe Stunde (Abbildung 4.1). Die Werte dieser Einträge weichen teilweise voneinander ab, es handelt sich also nicht um exakte Kopien. Ohne Bereinigung gingen diese Stunden mehrfach und mit widersprüchlichen Werten in das Training ein.

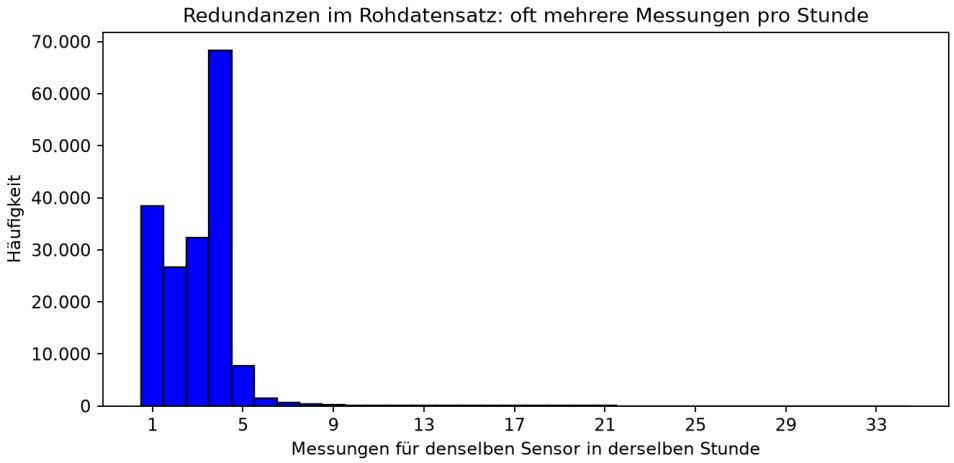


Abbildung 4.1: Häufigkeit von Mehrfachmessungen im Rohdatensatz. Für viele Stunden liegen mehrere, vereinzelt bis zu 34 Einträge desselben Sensors vor.

Messlücken: Nach der Zusammenfassung der Mehrfachmessungen liegen zunächst 177.414 eindeutige Sensorstunden vor. In 17 Stunden melden mindestens zehn aktive Sensoren gleichzeitig exakt null Passanten und null Verweildauer. Diese gemeinsamen Nullmeldungen mit insgesamt 410 Sensorwerten werden als Systemausfälle behandelt. Damit verbleiben 177.004 gemessene Sensorstunden. Innerhalb der 263.505 Sensorstunden unter der verwendeten Aktivitätsannahme fehlen 86.501 Werte, entsprechend 32,83 %. Sie bilden 15.364 zusammenhängende Lücken. Davon umfassen 10.157 höchstens zwei Stunden; die längste Lücke dauert wegen eines ausbleibenden Sensors 1.221 Stunden (Abbildung 4.2). Über alle Sensoren betrachtet gibt es 1.751 Stunden ohne verwertbaren Messwert. Darin enthalten sind die 17 als Systemausfälle behandelten Nullstunden; in den übrigen 1.734 Stunden liefert kein zu diesem Zeitpunkt aktiver Sensor einen Rohwert. Dies deutet auf gemeinsame Ausfälle der Übertragungsinfrastruktur hin. Trotz dieser Lücken besitzen alle 30 Sensoren mindestens 72 gemessene Trainingsziele und können in die globalen Modelle eingehen.

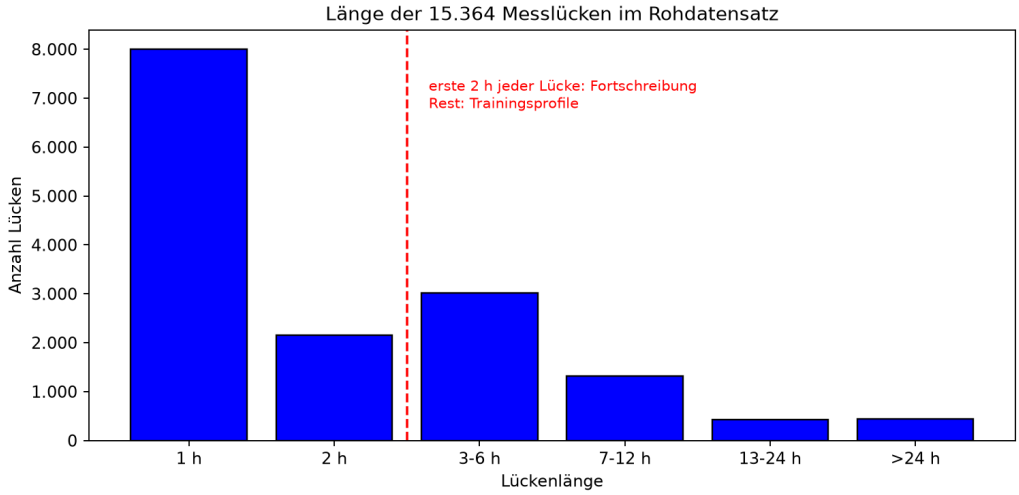


Abbildung 4.2: Längenverteilung der 15.364 Messlücken ab dem ersten Messwert eines Sensors. 10.157 Lücken umfassen höchstens zwei Stunden; Lücken über 24 Stunden sind in einer eigenen Klasse zusammengefasst.

Tabelle 4.1 fasst die wichtigsten Folgerungen der Analyse zusammen. Damit wird jede Aufbereitungsentscheidung aus einem beobachteten Datenmerkmal abgeleitet.

Tabelle 4.1: Aus der Datenanalyse abgeleitete Aufbereitung.

Analysebefund	Folgerung für die Aufbereitung
Bis zu 34 widersprüchliche Einträge je Sensorstunde	Zusammenfassung zu genau einem Messpunkt je Stunde
86.501 vollständig fehlende Stunden ab dem jeweiligen Messbeginn	Stundenraster, Imputation und dauerhafte Kennzeichnung der Ersatzwerte
17 gemeinsame Nullmeldungen von jeweils mindestens zehn aktiven Sensoren	Als gemeinsamen Systemausfall statt als echtes Passantenminimum behandeln
10.157 von 15.364 Lücken sind höchstens zwei Stunden lang	vergangenheitsbasierte Fortschreibung auf zwei Stunden begrenzen
Tages- und Wochenrhythmus sowie stark unterschiedliche Sensorniveaus	Kalendermerkmale, Zeitprofile und sensorweise Skalierung verwenden
Mittlere sensorweise Korrelation von nur 0,09 zwischen den Zielgrößen	`avgDuration` als zusätzliche Modellgröße beibehalten, den Alarm aber auf `visitors` ausrichten

4.3 Bereinigung der Mehrfachmessungen

Alle Einträge derselben Kombination aus Sensor und Stunde werden zu einem Messpunkt zusammengefasst. Für die Passantenzahl und die Verweildauer wird jeweils der arithmetische Mittelwert gebildet, da keine der mehrfachen Messungen als verlässlichere Quelle gekennzeichnet ist. Dadurch entstehen 177.414 eindeutige Sensorstunden. Die 410 Werte der 17 gemeinsamen Nullmeldungen werden anschließend als fehlend markiert, sodass 177.004 Stunden als gemessen gelten. Allgemein greift diese Regel, wenn mindestens zehn Sensoren Werte liefern und sämtliche vorhandenen Werte gleichzeitig null Passanten und null Verweildauer melden. Nach Abschluss der Imputation wird `visitors` auf ganzzahlige Zählwerte und die Verweildauer auf zwei Dezimalstellen gerundet.

4.4 Behandlung der Messlücken

Die für das Training verwendeten Zeitfenster setzen zusammenhängende Stundenreihen voraus. Eine Lücke innerhalb eines Fensters würde andernfalls unbemerkt Werte aus weit auseinanderliegenden Zeiträumen kombinieren. Die Lücken werden deshalb vor dem Training aufgefüllt, und zwar für jeden Sensor getrennt, damit jeder Standort sein individuelles Niveau und Tagesprofil behält. Die Datenaufbereitung verwendet keine lineare Interpolation. Sämtliche Profile werden ausschließlich aus ursprünglich gemessenen Werten vor dem 1. April 2026, 00:00 Uhr UTC, geschätzt; Tuning-, Kalibrierungs- und Testwerte gehen damit nicht in die Profilbildung ein. Wochentag und Stunde werden in der lokalen Zeitzone `Europe/Berlin` bestimmt. Das Verfahren arbeitet in vier aufeinanderfolgenden Stufen.

Stufe 1, vergangenheitsbasierte Fortschreibung: Da 10.157 der 15.364 Lücken und damit 66,1 % höchstens zwei Stunden dauern, wird die Fortschreibung auf genau diesen Zeitraum begrenzt. Für die ersten zwei Stunden jeder Lücke wird der letzte zuvor gemessene Wert desselben Sensors übernommen. Mit t^- als Zeitpunkt der letzten Messung gilt

$$\hat{x}_t = x_{t^-}, \qquad 0 < t - t^- \leq 2 \text{ Stunden}. \tag{4.1}$$

Diese Regel gilt auch für die ersten beiden Positionen einer längeren Lücke. Sie benötigt keinen nachfolgenden Messwert und verhindert dadurch, dass ein späteres Prognoseziel in einen früheren Modellkontext zurückgespiegelt wird. Dies führt kurzfristig zu einer konstanten Fortsetzung; die Regel stellt daher einen transparenten Kompromiss und kein allgemein optimales Imputationsverfahren dar. Auf diese Weise werden 22.731 Sensorstunden ergänzt.

Stufe 2, Wochentag-Stunden-Profil: Für die verbleibenden Lücken wird der Mittelwert desselben Sensors am gleichen lokalen Wochentag und zur gleichen lokalen Stunde aus gemessenen Trainingswerten eingesetzt. Historische Zeitprofile erhalten tages- und wochenzeitabhängige Strukturen und werden auch für fehlende Verkehrszähldaten untersucht [21]. Diese Stufe füllt 63.770 Sensorstunden.

Stufe 3, Stundenprofil: Existiert für eine Kombination aus Wochentag und Stunde keine Trainingsreferenz, wird der Mittelwert des Sensors zur gleichen lokalen Uhrzeit über alle Trainingstage verwendet. Im Jahresdatensatz ist diese Rückfallstufe nicht erforderlich.

Stufe 4, Sensormittel: Fehlt auch für die betreffende Uhrzeit eine Referenz, wird der Mittelwert sämtlicher gemessener Trainingswerte dieses Sensors eingesetzt. Auch diese Rückfallstufe ist nicht erforderlich. Damit werden alle 86.501 Lücken ab der ersten Messung geschlossen; Zeiten vor der ersten Messung bleiben außerhalb des Datensatzes. Ergänzte Werte nach der letzten Messung bleiben ausdrücklich als Datenqualitätsproblem markiert.

Abbildung 4.3 kennzeichnet für zwei Sensoren die ergänzten Stunden und zeigt auch einen längeren Endausfall. Abbildung 4.4 fasst den ergänzten Anteil innerhalb der aktiven Zeit jedes Sensors zusammen.

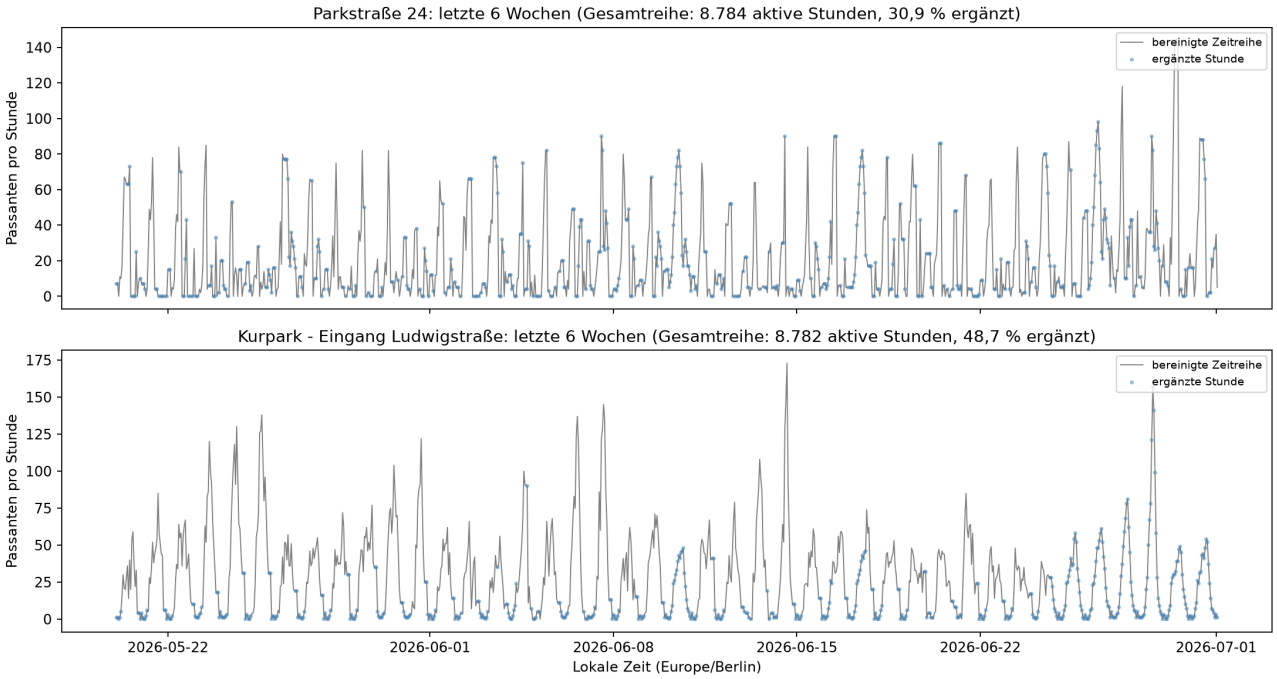


Abbildung 4.3: Sechswöchige Ausschnitte der bereinigten Zeitreihen eines typischen Sensors (oben) und des Sensors mit dem höchsten Imputationsanteil (unten), jeweils bis zum 30. Juni 2026. Markierte Punkte sind ergänzte Stunden.

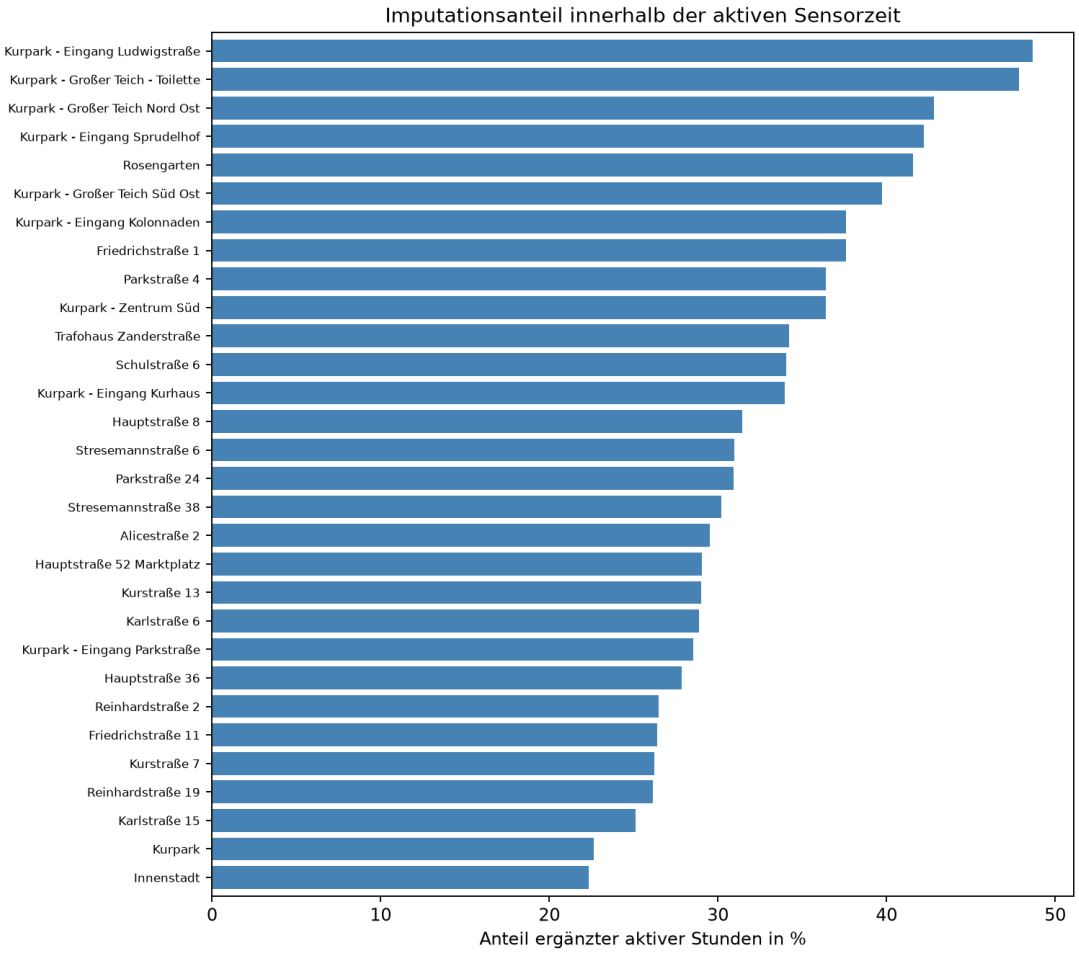


Abbildung 4.4: Anteil ergänzter Stunden innerhalb der aktiven Zeit jedes Sensors.

4.5 Kritische Betrachtung der Bereinigung

Jede Imputation verändert die Daten. Mittelwertbasierte Verfahren können den Verlauf glätten und die Varianz verringern [27, 18]. Im vorliegenden Datensatz ändert sich der Mittelwert der Passantenzahl je Sensor um höchstens 23,19 %. Die kleinste Korrelation zwischen dem ausschließlich aus gemessenen Werten und dem aus allen bereinigten Werten gebildeten stündlichen Tagesprofil beträgt 0,9983. Diese Kennzahlen prüfen Niveau und Profil, ersetzen aber keine Fehleranalyse gegen unbekannte wahre Werte in den Lücken.

Die zweistündige Fortschreibung verwendet zu jedem Zeitpunkt nur die Vergangenheit. Die statistischen Profile dürfen dagegen innerhalb des Trainingsabschnitts auch chronologisch spätere Trainingsmessungen enthalten. Die Aufbereitung ist damit für die Out-of-Sample-Auswertung frei von Validierungs- und Testdaten-Leakage, jedoch nicht als rein online-kausale Imputation jeder frühen Trainingslücke zu verstehen.

Ein verifizierter Betriebsplan lag für die Auswertung nicht vor. Daher gilt die erste vorhandene Messung als angenommener Aktivitätsbeginn und das globale Datenende als Aktivitätsende. Ein dauerhaft ausbleibender Stream bleibt damit als möglicher Ausfall sichtbar. Geplante Abschaltungen können unter dieser Annahme ebenfalls als Ausfälle erscheinen; diese Unsicherheit wird bei der Interpretation der Datenqualitätsereignisse berücksichtigt.

Unabhängig von der Imputation begrenzt das Messprinzip die Interpretation: Ohne eine externe Personenzählung lässt sich die Abweichung zwischen den erfassten Gerätesignalen und der tatsächlichen Perso-

nenanzahl nicht quantifizieren.

Ein zweiter Aspekt betrifft die Anomalieerkennung selbst. Ergänzte Stunden wirken per Konstruktion unauffällig, ein tatsächlicher Sensorausfall stellt jedoch selbst ein meldenswertes Ereignis dar. Das Fehlen von Werten folgt hier zudem eigenen, teils blockweisen Mustern und trägt damit selbst Information [27]. Das Feld `is_imputed` hält für jede Stunde fest, ob sie gemessen oder ergänzt wurde. Beide Prognosemodelle verwenden ergänzte Werte weiterhin als Kontext eines 24-Stunden-Fensters, überspringen jedoch Fenster mit einem ergänzten Zielwert beim Training, bei der Bestimmung des Schwellenwerts und bei der Testauswertung. Alle 30 Sensorreihen erfüllen im Jahresdatensatz die Mindestmenge gemessener Trainingsziele.

4.6 Forecast-basierter Anomaliedetektor

4.6.1 Lernaufgabe und Eingaberepräsentation

Der Forecaster lernt selbstüberwacht, aus den jeweils vorhergehenden 24 Stunden die nächste Stunde vorherzusagen. Das Modelltraining verwendet keine realen Anomalieklassen. Die nachgelagerte Alarmregel wird jedoch mit kontrollierten synthetischen Anomalien im Kalibrierungsabschnitt ausgewählt. Ein einziges globales Modell wird über alle 30 Sensoren trainiert. Jeder Sensor besitzt vor dem Ende des Trainingsabschnitts mindestens 72 gemessene Zielstunden. Fehlende Stunden werden unabhängig davon für alle Sensoren als Datenqualitätsereignisse ausgegeben.

Beide Zielgrößen werden zunächst mit $\log(1+x)$ transformiert. Danach erfolgt eine robuste Skalierung je Sensor s und Merkmal f:

$$z_{s,t,f} = \frac{\log(1+x_{s,t,f}) - \mathrm{Median}_{s,f}}{\max(\mathrm{IQR}_{s,f}, 0{,}05)}. \tag{4.2}$$

Median und Interquartilsabstand werden ausschließlich aus gemessenen Trainingswerten bestimmt. Die sensorweisen Mittelwerte von `visitors` reichen in der Analyse von etwa 12,2 bis 261,2 Zähleinheiten pro Stunde; die sensorweise Skalierung verhindert, dass diese Niveauunterschiede die Modellierung dominieren. Jedes historische Zeitfenster besitzt acht Kanäle: die beiden skalierten Messgrößen, eine Maske für gemessen beziehungsweise imputiert sowie Sinus und Kosinus von lokaler Stunde und Wochentag und einen Wochenendindikator. Eine Sensor-ID und zwölf Hilfsmerkmale der Zielstunde werden dem Modell getrennt übergeben: fünf Kalendermerkmale, die beiden skalierten Messwerte der Stunde $t-168$ mit gemeinsamer Beobachtungsmaske sowie Mittelwert und Standardabweichung beider skalierten Messgrößen im 24-Stunden-Fenster. Ist die Wochenreferenz noch nicht verfügbar, werden ihre Werte auf null gesetzt und durch die Beobachtungsmaske als fehlend gekennzeichnet. Beide Messgrößen unterstützen damit das Lernen des zeitlichen Kontexts. Das fachliche Untersuchungsziel dieser Arbeit ist jedoch ausschließlich die Passantenfrequenz.

Nur in den Trainingseingaben von LSTM-Forecaster und Transformer wird pro Fenster, sofern ein ausreichend langer ursprünglich gemessener Block vorhanden ist, ein zusammenhängender Block von einer bis vier Kontextstunden verdeckt. Bei 1,18 % der Prognosefenster fehlt ein geeigneter Block; sie bleiben unverändert. Beide Messwerte und ihre Beobachtungsmaske werden sonst auf null gesetzt; die Kalenderkanäle bleiben erhalten. Mittelwert und Standardabweichung des Fensters werden anschließend aus der verdeckten Eingabe neu berechnet. Tuning, Kalibrierung, Test und spätere Inferenz erhalten die unveränderten Kontexte. Diese deterministische Trainingsaugmentation soll die Abhängigkeit von einzelnen Kontextstunden begrenzen. Die saisonale Baseline und die MASE-Skalierung verwenden davon unabhängig weiterhin ausschließlich den gemessenen Vergleichswert $t-24$.

4.6.2 Architektur und Größenwahl

Die Architektur übernimmt aus den Literaturbefunden in Abschnitt 3.1 Quantilausgaben, ein kleines Sensor-Embedding, Kalendermerkmale und Dropout. Der Kern bleibt eine einzelne LSTM-Schicht.

Das LSTM verdichtet das 24-Stunden-Fenster in einen Zustandsvektor [4]. Dieser wird mit einem lernbaren Sensor-Embedding und den zwölf Hilfsmerkmalen der Zielstunde verbunden und durch eine dense Schicht geführt. Das globale Training und das Sensor-Embedding orientieren sich an probabilistischen globalen RNN-Forecastern [15].

Das Ausgabefeld enthält für `visitors` und `avgDuration` jeweils die Quantile $q_{0,1}$, $q_{0,5}$ und $q_{0,9}$. Trainiert wird mit der über beide Zielgrößen und Quantile gemittelten Pinball-Loss-Funktion [8]. Fünf vorab festgelegte Kandidaten variieren LSTM- und Dense-Breite, Embedding, Dropout und Lernrate. Der kleinste Tuning-Loss entscheidet, ohne den Testabschnitt zu verwenden. Tabelle 4.2 zeigt die ausgewählte Konfiguration. Die Prognose der Verweildauer bleibt eine Hilfsaufgabe; nur die `visitors`-Ausgabe wird später zur Alarmbildung verwendet.

Tabelle 4.2: Ausgewählte Forecaster-Architektur.

Baustein	Größe	Parameter	Begründung für diesen Datensatz
LSTM	64	18.688	Verdichtet ein Fenster aus 24 Stunden und acht Kanälen. Eine einzelne rekurrente Schicht hält die Architektur trotz 136.383 Trainingszielen kompakt.
Sensor-Embedding	4	120	Bildet 30 Sensoren mit $30 \cdot 4$ Werten als kleine Zusatzinformation ab.
Dense	32	2.592	Mischt den LSTM-Zustandsvektor, das Embedding und die zwölf Hilfsmerkmale und verkleinert sie auf 32 Werte.
Dropout	0,10	0	Begrenzt die Anpassung an die durch überlappende Fenster stark ähnlichen Trainingsbeispiele.
Ausgabe	6	198	Durch zwei Messgrößen und drei Quantile je Messgröße vollständig vorgegeben.

Insgesamt besitzt das ausgewählte Modell 21.598 trainierbare Parameter. Fünf Kombinationen reichen von 16 bis 128 LSTM-Einheiten und variieren zusätzlich Dense-Breite, Embedding, Dropout und Lernrate. Nach zunächst zehn Epochen reduziert Successive Halving die Menge von fünf auf drei und anschließend auf zwei Konfigurationen. Deren Training wird ausgehend von den bereits bestimmten Gewichten bis höchstens 80 Epochen mit Early-Stopping-Geduld acht fortgesetzt. Die ausgewählte Konfiguration wird für ihre beste Epochenzahl, hier 62, mit Batchgröße 512 auf Training und Tuning neu trainiert; Kalibrierungs- und Testdaten bleiben dabei unberührt.

4.6.3 Nichtkonformitätsscore und Intervallkalibrierung

Für Merkmal f wird die Abweichung einer Beobachtung $y_{t,f}$ vom vorhergesagten Quantilintervall relativ zu dessen Breite bewertet. Dazu seien $b_{t,f} = q_{0,9,t,f} - q_{0,1,t,f}$ und

$$w_{\min,f} = \max\{Q_{0,1}(b_{t,f}), 0{,}05\}, \qquad \widetilde{b}_{t,f} = \max\{b_{t,f}, w_{\min,f}\}. \tag{4.3}$$

Das 10-%-Quantil wird aus den Intervallbreiten des Kalibrierungsabschnitts bestimmt. Die Untergrenze verhindert, dass nahezu kollabierte Intervalle künstlich große Scores erzeugen. Der Nichtkonformitätsscore lautet

$$e_{t,f} = \frac{\max\{q_{0,1,t,f} - y_{t,f},\ y_{t,f} - q_{0,9,t,f}\}}{\widetilde{b}_{t,f}}, \qquad s_t = e_{t,\text{visitors}}. \tag{4.4}$$

Ein negativer Wert liegt innerhalb des ursprünglichen Quantilintervalls; ein positiver Wert misst die relative Überschreitung. Die Fehler beider Größen werden zur Diagnose ausgegeben; allein der Besucherfehler s_t

steuert den Alarm. Aus $n = 15.159$ gemessenen Punkten des getrennten Kalibrierungsabschnitts wird bei nominal $\alpha = 0{,}01$ eine endliche empirische Quantilschwelle bestimmt. Für die aufsteigend sortierten Scores $s_{(1)}, \ldots, s_{(n)}$ gilt

$$k(\alpha) = \min\{n, \lceil (n+1)(1-\alpha) \rceil\}, \qquad \tau_\alpha = s_{(k(\alpha))}. \tag{4.5}$$

Die kalibrierten Grenzen des Merkmals f sind damit $q_{0,1,t,f} - \tau_{\alpha,f}\widetilde{b}_{t,f}$ und $q_{0,9,t,f} + \tau_{\alpha,f}\widetilde{b}_{t,f}$. Das Verfahren ist an Conformalized Quantile Regression angelehnt [14] und verwendet zusätzlich eine Breitenstandardisierung. Die Intervalle beider Größen werden getrennt kalibriert; die Alarmschwelle beruht nur auf `visitors`. Wegen der zeitlichen Abhängigkeit der Fenster wird keine verteilungsfreie 99-%-Garantie beansprucht [1]; die tatsächliche Testabdeckung wird berichtet.

4.6.4 Kausale Alarmregel

Starke Einzelabweichungen werden unmittelbar erkannt. Als mögliche Erweiterung für moderate, aber anhaltende Abweichungen wird auch eine kausale Persistenzregel geprüft:

$$A_t = \mathbf{1}(s_t > \tau_{\text{hoch}}) \ \vee \ \mathbf{1}\left(\sum_{j=0}^{m-1} \mathbf{1}(s_{t-j} > \tau_{\text{niedrig}}) \geq k\right). \tag{4.6}$$

Eine solche Regel arbeitet je Sensor, betrachtet nur aktuelle und vergangene Scores und wird bei einer Zeitlücke oder einem imputierten Ziel zurückgesetzt. Die 18 vorab festgelegten Kombinationen bestehen aus zwei Direktschwellen mit $\alpha \in \{0{,}005, 0{,}01\}$ sowie $2 \cdot 2 \cdot 4$ Kombinationen dieser hohen Schwellen mit niedrigen Schwellen $\alpha \in \{0{,}05, 0{,}10\}$ und den vier Persistenzregeln $(m, k) \in \{(3,2), (4,3), (6,3), (6,4)\}$. Die hohen Schwellen entsprechen somit den empirischen 99,5- beziehungsweise 99-%-Rängen, die niedrigen den 95- beziehungsweise 90-%-Rängen. τ_{hoch}, τ_{niedrig}, m und k werden ausschließlich anhand synthetischer Anomalien im Kalibrierungsabschnitt gewählt. Zulässig sind nur Regeln mit höchstens 1 % Alarmen auf den unveränderten Kalibrierungswerten. Optimiert wird der über die Anomalietypen gleichgewichtete Ereignis-F1; die Injektionen des Testabschnitts beeinflussen diese Auswahl nicht.

4.6.5 Umgang mit imputierten Zielwerten

Imputierte Werte dürfen als markierter Kontext in ein Zeitfenster eingehen, werden aber nicht als Ziel für Training, Modellauswahl, Kalibrierung oder Forecast-Metriken verwendet. Eine fehlende Originalmessung wird unabhängig vom Forecast als Datenqualitätsereignis ausgegeben. Dadurch wird ein aus einem Zeitprofil erzeugter Ersatzwert weder als reguläre Beobachtung noch als bestätigte Verhaltensanomalie fehlinterpretiert. Ein Forecast-Alarm wird nicht nachträglich unterdrückt, erhält aber niedrige Konfidenz, wenn mehr als die Hälfte seines 24-Stunden-Kontexts imputiert ist oder die Besucherzahl die Intervallgrenze um weniger als eine Person überschreitet. Der jeweilige Grund wird in der Kandidatendatei ausgegeben.

4.7 Transformer-Forecaster

Der Transformer löst dieselbe selbstüberwachte Prognoseaufgabe wie der LSTM-Forecaster. Er erhält dieselben 24 historischen Stunden, Sensor-IDs, zwölf Hilfsmerkmale und Zielgrößen. Auch die Trainingsmaskierung, Skalierung, zeitlichen Teilmengen, Quantile, der Nichtkonformitätsscore und die Alarmkalibrierung bleiben unverändert. Dadurch prüft der spätere Vergleich die Architektur und nicht unterschiedliche Daten- oder Bewertungsregeln.

Jede Stunde bildet ein eigenes Token. Eine Dense-Projektion überführt dessen acht Eingabekanäle in 48 Merkmale; eine feste sinusförmige Positionskodierung erhält die Reihenfolge. Das achtdimensionale Sensor-Embedding wird auf dieselbe Breite projiziert und jedem Token hinzugefügt. Anschließend folgen zwei

Pre-LN-Encoderblöcke mit jeweils vier Attention-Köpfen, einem Feedforward-Netz der Breite 192, GELU-Aktivierung, Residualpfaden und 0,15 Dropout. Pre-LN folgt Xiong et al.; Attention, Residualpfade und Positionskodierung folgen dem ursprünglichen Transformer [25, 23].

Der Zustand des letzten Tokens wird mit dem Sensor-Embedding und den zwölf Hilfsmerkmalen der Zielstunde verbunden. Eine Dense-Schicht der Breite 48 erzeugt daraus die Prognose. Parallel bildet ein linearer Pfad die 24 historischen Werte beider Messgrößen direkt auf die zwei Mediane ab. Dieser einfache autoregressive Anteil ist durch die Ergebnisse linearer Zeitreihenmodelle motiviert [26]. Die beiden übrigen Ausgabewerte werden mit Softplus als nichtnegative Abstände vom Median dargestellt. Damit gilt konstruktiv $q_{0,1} \leq q_{0,5} \leq q_{0,9}$; ein nachträgliches Sortieren der Quantile ist nicht erforderlich.

Tabelle 4.3: Ausgewählte Transformer-Architektur.

Baustein	Größe	Parameter	Begründung für diesen Datensatz
Eingabeprojektion	48	432	Bewahrt alle 24 Stunden als einzelne, kompakte Tokens.
Sensorkontext	$8 \rightarrow 48$	624	Embedding und Projektion ergänzen standortspezifische Information in jedem Token.
Zwei Pre-LN-Blöcke	4 Köpfe, FFN 192	56.544	Vier Köpfe ergeben bei Modellbreite 48 je zwölf Merkmale; zwei Blöcke erlauben eine zweite zeitliche Verknüpfung bei einer begrenzten zusätzlichen Parameterzahl.
Prognosekopf	Dense 48	3.702	Verbindet letzten Token, Sensor und zwölf Hilfsmerkmale und erzeugt sechs Quantilwerte.
Linearer Pfad	$48 \rightarrow 2$	96	Hält einfache autoregressive Zusammenhänge direkt erreichbar.

Insgesamt besitzt das Modell 61.398 trainierbare Parameter. Sechs vorab festgelegte Kandidaten mit 3.186 bis 157.334 Parametern variieren Modellbreite, Kopf- und Blockzahl, Feedforward- und Dense-Breite, Embedding, Dropout und Lernrate. Successive Halving reduziert sie nach jeweils zehn und 20 Epochen auf zwei Konfigurationen. Deren Training wird ausgehend von den bereits bestimmten Gewichten bis höchstens 120 Epochen mit Early-Stopping-Geduld zwölf fortgesetzt. Trainiert wird mit AdamW, Gewichtsnachlass 10^{-4}, auf eins begrenzter Gradientennorm und Batchgröße 512. Der Tuning-Loss entscheidet wie beim LSTM ohne Nutzung von Kalibrierungs- oder Testdaten. Die ausgewählte Konfiguration erreicht ihr Loss-Minimum bei Epoche 79 und wird für diese Epochenzahl auf Training und Tuning neu trainiert. Patching wird nicht verwendet: Sein Vorteil betrifft vor allem lange Eingaben, während das 24-Stunden-Fenster kurz ist und einzelne Stundensprünge erhalten soll [13].

4.8 Denoising-Autoencoder

Der Autoencoder bildet eine von den Prognosemodellen getrennte Methode. Er erhält ein 24-Stunden-Fenster mit den beiden skalierten Messgrößen und der Beobachtungsmaske. Seine Ausgabe rekonstruiert die beiden Messgrößen für alle 24 Stunden. Der vollständige Aufbau lautet:

$$\mathrm{Input}(24, 3) \rightarrow \mathrm{LSTM}(64) \rightarrow \mathrm{RepeatVector}(24) \rightarrow \mathrm{LSTM}(64) \rightarrow \mathrm{Dense}(2). \tag{4.7}$$

Die einzelne LSTM-Schicht auf beiden Seiten des komprimierten Zustands folgt dem Grundaufbau von Malhotra et al. [12]. Die Literatur bestimmt damit die Form, während Tabelle 4.4 die an den vorliegenden Datensatz angepassten Größen begründet.

Das Netz besitzt insgesamt 50.562 trainierbare Parameter. Fünf vorab festgelegte Kandidaten variieren LSTM-Breite, Lernrate und maximale Maskierungslänge. Successive Halving reduziert sie nach zehn und 20 Epochen auf zwei Finalisten. Anhand des geringsten Tuning-Loss werden 64 Einheiten, eine Lernrate von 0,0003 und höchstens sechs maskierte Stunden ausgewählt. Beide Finalisten erreichen die Obergrenze der Architektursuche von 200 Epochen; Early Stopping wird nicht ausgelöst. Der ausgewählte Kandidat erreicht

sein Loss-Minimum bei Epoche 200. Das endgültige Modell wird deshalb für 200 Epochen auf Training und Tuning neu trainiert. Die Epochenwahl bleibt damit durch die festgelegte Obergrenze beschränkt. Eine zusätzliche versteckte Dense-Schicht ist nicht nötig, da die vorhandene Rekonstruktion bereits beide Messgrößen direkt aus dem Decoderzustand erzeugt.

Tabelle 4.4: Größenwahl des Autoencoders.

Baustein	Größe	Parameter	Begründung für diesen Datensatz
Eingabe	24×3	0	Ein Tag mit zwei Messgrößen und einer Beobachtungsmaske.
Encoder-LSTM	64	17.408	Verdichtet das 24-Stunden-Fenster auf 64 Zustandswerte.
RepeatVector	24	0	Stellt wieder genau die ursprüngliche Länge von 24 Stunden bereit.
Decoder-LSTM	64	33.024	Verwendet dieselbe Breite wie der Encoder und führt dadurch keine weitere frei gewählte Größe ein.
Dense	2	130	Durch die Rekonstruktion von `visitors` und `avgDuration` vollständig vorgegeben.

Während des Trainings wird in jedem Fenster ein zusammenhängender Block von einer bis sechs ursprünglich gemessenen Stunden verdeckt. Damit bleiben selbst im größten Fall 18 der 24 Stunden als zeitlicher Kontext erhalten. Die zugehörigen Eingabewerte und ihre Maske werden auf null gesetzt, das Rekonstruktionsziel bleibt jedoch unverändert. Diese einfache Datenerweiterung folgt dem Denoising-Prinzip [24]. Künstliche Spikes, Dips oder andere Testanomalien werden nicht für das Training verwendet.

Trainiert wird mit Adam, Batchgröße 512 und Early-Stopping-Geduld 15. Der Suchlauf ist auf höchstens 200 Epochen begrenzt. Die Huber-Fehlerfunktion verringert den Einfluss einzelner großer, im unbeschrifteten Training möglicherweise bereits vorhandener Abweichungen. Ergänzte Werte dürfen als markierter Kontext eingehen, besitzen im Rekonstruktionsfehler aber das Gewicht null. Das Modell lernt sie daher nicht als echte Zielwerte.

Für jede Stunde wird der absolute Rekonstruktionsfehler der letzten Position des Fensters verwendet. Der Besucherfehler wird durch sein 75-%-Quantil im Kalibrierungsabschnitt geteilt und bildet den Anomaliewert $s_t = e_t / \max\{Q_{0,75}(e_{\text{Kalibrierung}}), 0{,}05\}$. Die Untergrenze von 0,05 verhindert eine instabile Division bei nahezu fehlerfreier Kalibrierung und ist beim finalen Modell nicht aktiv. Ein Score von eins entspricht dort daher dem 75-%-Quantil der Kalibrierungsfehler, ein Score von drei dem Dreifachen davon. Die Division macht den Fehler dimensionslos; sie verändert seine Rangfolge nicht. Die Rekonstruktion von `avgDuration` bleibt eine Hilfsaufgabe und wird zur Diagnose ausgegeben, kann aber keinen Alarm auslösen. Die Alarmregel wird anschließend mit demselben Kalibrierungsverfahren wie beim Forecaster festgelegt. Dadurch unterscheiden sich die Modelle, während Datenabschnitte, Besucher-Injektionen und Entscheidungskriterien gleich bleiben.

4.9 Robuste saisonale Baseline

Als einfachste Vergleichsmethode wird kein weiteres Netz trainiert. Für jede gemessene Stunde wird der sensorweise robust skalierte Besucherwert von dem ebenfalls gemessenen Wert 24 Stunden zuvor abgezogen. Median und Interquartilsabstand dieser Residuen werden nur aus gemessenen Trainingspaaren bestimmt. Der absolute Abstand zum Trainingsmedian, geteilt durch $\max\{\mathrm{IQR}, 0{,}05\}$, bildet den Score; die Untergrenze verhindert auch hier einen instabil kleinen Nenner. Ein saisonaler Score von fünf bezeichnet folglich eine Abweichung um fünf dieser robusten Skaleneinheiten vom medianen $t-24$-Residuum. Die Baseline besitzt damit keine trainierbaren Parameter. Sie verwendet dieselbe Kalibrierung, dieselben Besucher-Injektionen und dieselben Entscheidungskriterien wie die neuronalen Modelle. Sie liefert nur für Stunden mit einem gemessenen $t-24$-Vergleichswert einen Score und enthält sich an den übrigen Stunden eines Alarms.

Kapitel 5

Evaluation der Methode

5.1 Zeitliche Datentrennung

Alle Teilmengen werden chronologisch und nicht zufällig gebildet. Dies verhindert, dass spätere Stunden als Lernbeispiele für frühere Prognosen verwendet werden. Tabelle 5.1 nennt die Grenzen und die Anzahl ursprünglich gemessener Zielpunkte nach dem 24-Stunden-Windowing.

Tabelle 5.1: Chronologische Teilmengen aller Verfahren. Alle Grenzen sind in UTC angegeben.

Teilmenge	Beginn	Ende (exklusiv)	Zielpunkte
Training	erster möglicher Zielwert	01.04.2026	136.383
Tuning	01.04.2026	01.05.2026	11.662
Kalibrierung	01.05.2026	01.06.2026	15.159
Test	01.06.2026	01.07.2026	13.142

Der Juni bildet den letzten Monat des finalen Snapshots. Seine 21.600 aktiven Sensorstunden umfassen 13.142 gemessene Zielpunkte; alle 30 Sensoren sind mit Messungen vertreten. Die Wahl dieses Monats erfolgte jedoch retrospektiv: In einem zuvor untersuchten, bis Ende Juli reichenden Abruf besaßen neun Sensoren im Juli keine einzige Messung. Daraufhin wurden das Datenende und sämtliche Zeitabschnitte um einen Monat vorgezogen sowie alle Modelle und Alarmregeln neu geschätzt. Der Juni ist deshalb ein chronologischer Testblock, aber kein unberührt festgelegter konfirmatorischer Holdout. Die automatisierte Modellauswahl verwendet seine Werte nicht; die manuelle Entscheidung über den Auswertungszeitraum beruhte hingegen auf bereits betrachteter Sensorabdeckung.

Für LSTM-Forecaster und Autoencoder werden jeweils fünf, für den Transformer sechs vorab festgelegte Architektur- und Lernratenkombinationen verglichen. Die Kandidaten umfassen Netze unterschiedlicher Größe. Jeder Kandidat lernt nur auf dem Trainingsabschnitt; ausschließlich der chronologische Tuning-Loss bestimmt Kombination und Epochenzahl. Um die Suche zu verkürzen, erhalten zunächst alle Kandidaten zehn Epochen. Danach wird die Hälfte mit den höheren Tuning-Loss-Werten ausgeschlossen, bis zwei Konfigurationen verbleiben. Deren Training wird mit den bereits bestimmten Gewichten bis zur jeweiligen Obergrenze und mit Early Stopping fortgesetzt. Dieses gestufte Verfahren reduziert den Rechenaufwand, kann jedoch nicht ausschließen, dass ein früh ausgeschiedener Kandidat bei vollständigem Training einen geringeren Loss erreicht.

Der LSTM-Forecaster erhält höchstens 80 Epochen bei einer Geduld von acht, der Transformer 120 bei einer Geduld von zwölf. Die Autoencoder-Architektursuche ist bei einer Geduld von 15 auf 200 Epochen begrenzt. Die Batchgröße beträgt einheitlich 512. Das jeweils ausgewählte Modell wird anschließend für seine beste Epochenzahl auf Training und Tuning gemeinsam, also auf 148.045 Fenstern mit identischen Zielzeitpunkten, neu trainiert. Erst danach bestimmt der Kalibrierungsabschnitt die Schwellen und gegebe-

nenfalls eine Persistenzregel. Der Testabschnitt geht nicht in die automatisierte Auswahl von Architektur, Epochenzahl, Schwellenwerten oder Persistenzregel ein. Die vorausgegangene menschliche Wahl des Monats bleibt davon zu unterscheiden und begrenzt die Aussagekraft als unabhängige Prüfung.

5.2 Bewertung der Prognosegüte

Die Medianprognose $q_{0,5}$ beider Prognosemodelle wird mit MAE und RMSE bewertet. Zusätzlich wird die saisonal skalierte mittlere absolute Abweichung (MASE) nach Hyndman und Koehler berichtet [6]:

$$\mathrm{MASE} = \frac{H^{-1}\sum_{h=1}^{H}|y_{T+h} - \hat{y}_{T+h}|}{(T-24)^{-1}\sum_{t=25}^{T}|y_t - y_{t-24}|}. \tag{5.1}$$

In der Implementierung werden Zähler und Nenner je Zielgröße über alle zulässigen Sensorstunden des jeweiligen Abschnitts gepoolt; es wird also nicht zunächst ein MASE je Sensor berechnet und anschließend gemittelt. Der Nenner wird ausschließlich aus Paaren berechnet, bei denen sowohl das Trainingsziel als auch sein $t-24$-Vergleichswert gemessen wurden. Damit ist MASE von dem ergänzend angegebenen Verhältnis $\mathrm{MAE}_{\mathrm{Modell,Test}} \,/\, \mathrm{MAE}_{t-24,\mathrm{Test}}$ zu unterscheiden. Werte unter eins bedeuten jeweils eine Verbesserung gegenüber der zugehörigen Skalierung beziehungsweise Testbaseline. Auch der direkte Testvergleich verwendet nur die 10.716 Testpunkte mit gemessenem aktuellem Wert und gemessenem $t-24$-Wert.

Für die empirisch kalibrierten Intervalle werden die marginale Abdeckung je Zielgröße, die gemeinsame Abdeckung beider Zielgrößen und die mittlere Intervallbreite ausgewiesen. Eine hohe Abdeckung allein ist nicht hinreichend, da sie durch sehr breite und damit wenig trennscharfe Intervalle erreichbar wäre. Diese Werte beschreiben die Prognosen beider Größen. Für die Alarmentscheidung wird ausschließlich der kalibrierte Besucher-Score verwendet.

Als einfache robuste Vergleichsmethode wird zusätzlich die Abweichung vom gemessenen Wert derselben Stunde des Vortags verwendet. Nach der sensorweisen robusten Skalierung werden die Residuen durch Median und Interquartilsabstand der gemessenen Trainingspaare standardisiert; Schwelle und Persistenzregel werden anschließend genauso wie bei den drei neuronalen Modellen kalibriert. Der Detektor besitzt keine trainierbaren Parameter und kann nur Punkte bewerten, für die der aktuelle Wert und der $t-24$-Wert tatsächlich gemessen wurden. Fehlt der Vergleichswert, enthält sich die Baseline eines binären Alarms; ein dort injizierter Punkt bleibt damit gegebenenfalls ein False Negative.

5.3 Synthetische Anomalieinjektion

Reale Anomalieklassen liegen nicht vor. Deshalb wird die technische Erkennungsfähigkeit ergänzend mit kontrollierten Injektionen geprüft. Dieses Vorgehen liefert eindeutige Labels für genau definierte Fehlertypen, ersetzt aber keine Evaluation realer Ereignisse [17]. Die Anomalien werden ausschließlich in ursprünglich gemessene Werte injiziert, bevor Zeitfenster erzeugt und Prognosen berechnet werden. Damit beeinflussen mehrstündige Ereignisse den nachfolgenden Modellkontext wie reale Messwerte. Alle vier Detektoren erhalten dieselben ausgewählten Sensoren, Zeitpunkte, Richtungen und Stärken. Verändert wird ausschließlich `visitors`, weil die gesuchte Anomalie eine Abweichung der Passantenfrequenz ist.

Untersucht werden ein einstündiger positiver Spike, ein einstündiger Dip, ein vierstündiger Level-Shift, ein über vier Stunden ansteigender Drift und ein sechsstündiger Stuck-at-Fehler. Bei den mehrstündigen Typen werden beide Richtungen abgedeckt. Die Stärken 0,5, 1,0 und 2,0 beziehen sich auf sensor- und besucherspezifische robuste $\log(1+x)$-IQR-Einheiten. Stuck-at friert die Passantenzahl auf die letzte vorherige Messung ein; Ereignisse mit weniger als 0,5 realisierter IQR-Abweichung werden verworfen, weil sie keine belastbare künstliche Veränderung darstellen. Ein Punkt erhält erst nach Rundung und Begrenzung auf nichtnegative Zählwerte ein Label, wenn sich sein Wert tatsächlich geändert hat. Wirkungslos gewordene Dips und Stuck-at-Ereignisse werden dadurch nicht fälschlich als positive Beispiele bewertet.

Die Auswahl der Alarmregel verwendet drei feste Zufallsstartwerte im Kalibrierungsabschnitt und nur die Stärken 1,0 und 2,0. Der endgültige Vergleichstest verwendet drei andere feste Zufallsstartwerte im Testabschnitt und schließt 0,5 als Sensitivitätsanalyse ein. Pro Lauf wird höchstens ein Ereignis je Sensor erzeugt. Jede injizierte Reihe wird mit einem identischen unveränderten Gegenlauf gepaart. Ein Treffer zählt nur, wenn die Injektion einen zusätzlichen Alarm hervorruft; ein bereits am gleichen Zeitpunkt bestehender Alarm wird nicht nachträglich als Erfolg der Injektion gewertet.

5.4 Punkt- und Ereignismetriken

Auf Punktebene werden aus den binären zusätzlichen Alarmen Konfusionsmatrix, Precision, Recall, F1 und zeitliche Intersection over Union berechnet. Die Konfusionswerte werden zunächst über alle Läufe summiert und erst danach in Kennzahlen umgerechnet. ROC-AUC und Average Precision (AP) bewerten davon getrennt die kontinuierlichen Rohscores; eine binäre Alarmentscheidung wird nicht als Rankingkurve ausgegeben. Für eine gemeinsame Testpopulation werden fehlende Baseline-Scores bei den Rankingmetriken unterhalb aller endlichen Scores eingeordnet und ihre Anzahl separat gespeichert. Precision und Recall sind durch

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN} \tag{5.2}$$

definiert. AP ist wegen des starken Ungleichgewichts zwischen Normal- und Anomaliepunkten besonders informativ; ROC-AUC wird ergänzend ausgegeben.

Zusammenhängende stündliche Alarme desselben Sensors werden zusätzlich als Ereignisse gruppiert. Ein vorhergesagtes Ereignis darf höchstens einem injizierten Ereignis zugeordnet werden; Fragmentierung kann dadurch den Ereignis-F1 nicht künstlich erhöhen. Berichtet werden Ereignis-Precision, Ereignis-Recall, Ereignis-F1, mittlere zeitliche IoU und die Verzögerung bis zum ersten überlappenden Alarm. Diese Existenz- und Überlappungsdefinition ist eine bewusst einfache ereignisorientierte Auswertung und nicht das vollständige Metriksystem von Tatbul et al. [22]. Die ursprünglichen Punktvorhersagen werden nicht verändert. Insbesondere wird kein Point Adjustment verwendet, da es die gemessene Leistung stark überschätzen kann [7].

Ergänzend prüft ein reproduzierbarer Rauschtest die Alarmstabilität. Für gemessene Besucherwerte wird bei 5 % und 15 % Stärke mittelwerttreues, nichtnegatives Zählwertrauschen aus binomialem Ausdünnen und einer Poisson-Ersetzung erzeugt. Berichtet wird der Anteil zusätzlicher Alarme gegenüber dem nicht injizierten Testlauf. Der einmonatige Testblock wird nicht noch einmal in kürzere Teilblöcke zur Rolling-Origin-Neuschätzung zerlegt, weil dann pro Ursprung nur wenige Ereignisse und Sensorstunden verblieben.

5.5 Reproduzierbarkeit

Der untersuchte Datenstand umfasst den halboffenen Abrufzeitraum vom 30. Juni 2025, 00:00 Uhr, bis zum 1. Juli 2026, 00:00 Uhr UTC sowie 30 Karten-Feature-IDs. Sämtliche Aufbereitungsregeln, chronologischen Teilungsgrenzen, Modellkonfigurationen, Trainingsdauern und Kalibrierungskriterien sind in den vorangegangenen Abschnitten angegeben. Für das Modelltraining und die synthetischen Injektionen werden feste, voneinander getrennte Zufallsstartwerte verwendet; bei den neuronalen Modellen sind deterministische TensorFlow-Operationen aktiviert.

Da die städtische API historische Werte nachträglich verändern kann, ist ein späterer Neuabruf nicht zwingend bitgleich mit dem untersuchten Snapshot.

Kapitel 6

Ergebnisse

6.1 Training und Detektorkalibrierung

Beim LSTM-Forecaster erreicht Kandidat 3 aus fünf Konfigurationen den kleinsten Tuning-Loss. Er verwendet 64 LSTM-, 32 Dense- und vier Embedding-Einheiten, 0,10 Dropout und eine Lernrate von 0,001. Sein Tuning-Loss beträgt 0,1308 bei Epoche 62. Das fortgesetzte Suchtraining endet nach 70 Epochen. Das endgültige Modell wird für 62 Epochen auf 148.045 gemessenen Zielen aus Training und Tuning neu trainiert und besitzt 21.598 Parameter. Kalibrierungs- und Testabschnitt werden dabei nicht zum Anpassen der Modellgewichte verwendet. Abbildung 6.1 stellt für alle neuronalen Verfahren Training und Tuning gegenüber.

Beim Transformer weist Kandidat 4 aus sechs Konfigurationen den geringsten Tuning-Loss auf und wird ausgewählt. Er verwendet Modellbreite 48, vier Attention-Köpfe, zwei Encoderblöcke, Feedforward-Breite 192 und 0,15 Dropout. Sein Tuning-Loss beträgt 0,1216. Das fortgesetzte Training endet nach 91 Epochen; der geringste Loss tritt bei Epoche 79 auf. Das für 79 Epochen neu trainierte Modell besitzt 61.398 Parameter.

Beim Autoencoder weist Kandidat 4 mit jeweils 64 LSTM-Einheiten in Encoder und Decoder, einer Lernrate von 0,0003 und höchstens sechs zusammenhängend maskierten Stunden den geringsten Tuning-Loss auf und wird ausgewählt. Beide verbleibenden Konfigurationen werden für die maximal vorgesehenen 200 Epochen trainiert; Early Stopping wird nicht ausgelöst. Der gewählte Kandidat erreicht seinen geringsten Tuning-Loss von 0,0368 bei Epoche 200. Das endgültige Modell wird deshalb für 200 Epochen auf den 148.045 Fenstern aus Training und Tuning neu trainiert und besitzt 50.562 Parameter. Die Epochenwahl bleibt damit durch die festgelegte Obergrenze beschränkt. Dieser Rekonstruktionsloss ist wegen einer anderen Zielfunktion nicht direkt mit den Pinball-Loss-Werten der Forecaster vergleichbar.

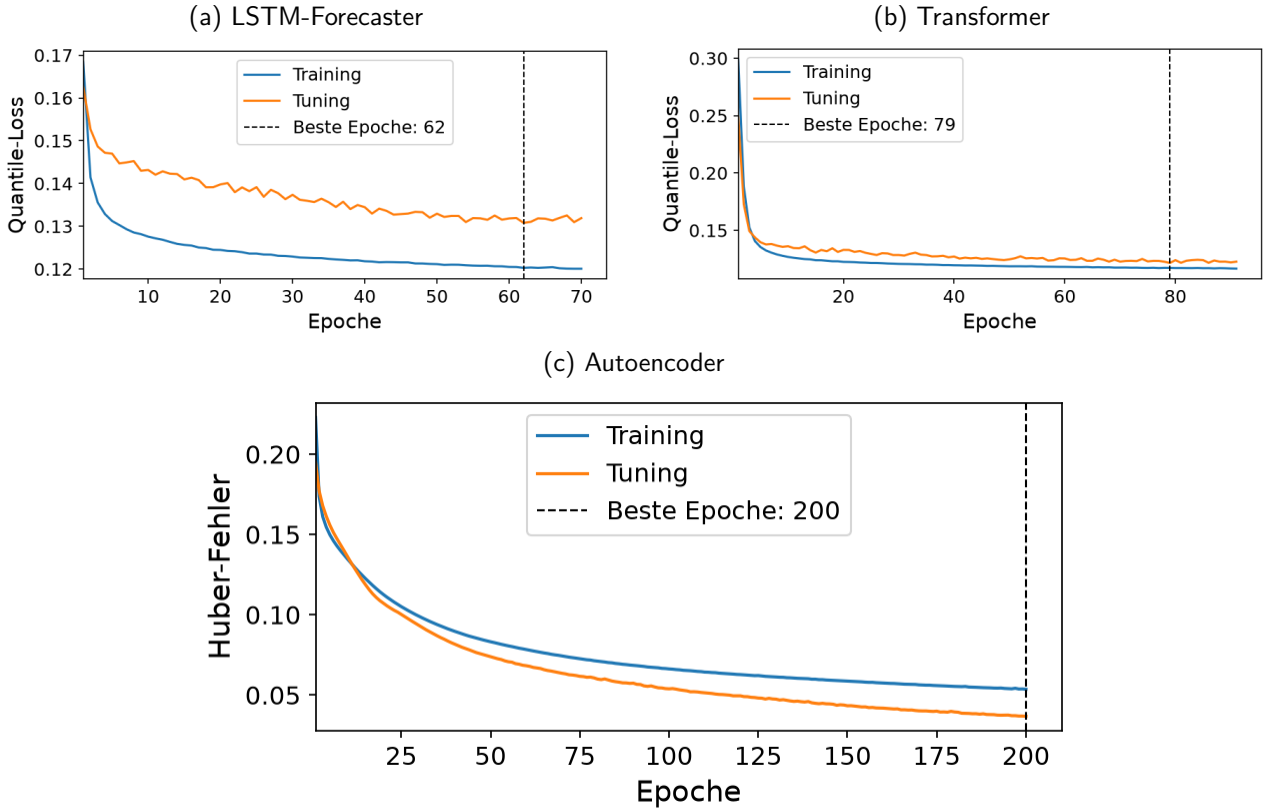


Abbildung 6.1: Trainings- und Tuning-Loss der ausgewählten Kandidaten während der Modellauswahl. Die gestrichelte Linie markiert die gewählte Epoche. Die Trainingskurven enthalten die beschriebenen maskierten Kontexte, während der Tuningabschnitt unverändert bleibt; ein niedrigerer Tuning-Loss ist deshalb möglich. Die Prognosemodelle verwenden den Pinball-Loss, der Autoencoder den Huber-Fehler; die absoluten Niveaus sind daher nicht modellübergreifend vergleichbar.

Die Kalibrierung des LSTM wählt eine hohe Besucher-Schwelle von 1,4372 und eine kausale Drei-von-vier-Regel oberhalb der niedrigeren Schwelle 0,3758. Beim Transformer wird dagegen nur die direkte Schwelle 1,1659 ausgewählt; eine Persistenzregel verbessert das Kalibrierungsziel dort nicht. Auf den 15.159 nicht injizierten Kalibrierungspunkten erzeugen die Regeln 95 beziehungsweise 150 Alarme, also 0,627 % beziehungsweise 0,990 %. Damit halten sie die vorab festgelegte maximale Kalibrierungsalarmrate von 1 % ein. Der Makro-Ereignis-F1 der Kalibrierungsinjektionen beträgt 0,823 für den LSTM und 0,750 für den Transformer. Autoencoder und saisonale Baseline verwenden ebenfalls reine Direktschwellen; ihre Kalibrierungswerte betragen 3,6330 beziehungsweise 5,0205. Sie erzeugen 150 beziehungsweise 132 Alarme, also 0,990 % beziehungsweise 0,871 %, und erreichen einen Makro-Ereignis-F1 von 0,443 beziehungsweise 0,344. Diese Werte sind Auswahlkriterien und keine Testergebnisse. Die saisonale Schwelle wird aus den 13.387 Kalibrierungspaaren mit gemessenem aktuellem und gemessenem $t - 24$-Wert bestimmt; ihre Alarmrate bezieht sich wie bei den übrigen Verfahren auf alle 15.159 gemessenen Kalibrierungsziele, wobei sie sich ohne Vergleichswert eines Alarms enthält.

Die Zahlenwerte der Schwellen besitzen modellabhängige Bedeutungen und sind nicht direkt miteinander vergleichbar. Beim LSTM bedeutet 1,4372, dass die Messung das ursprüngliche $q_{0,1}$–$q_{0,9}$-Intervall um mehr als 1,4372 der standardisierten Breiten $\widetilde{b}$ überschreitet; 0,3758 gilt entsprechend für drei der vier letzten Stunden. Die Transformer-Schwelle 1,1659 besitzt dieselbe Einheit, löst aber bereits bei einer einzelnen Überschreitung aus. Der Autoencoderwert 3,6330 bezeichnet das 3,6330-Fache seines 75-%-Kalibrierungsfehlers. Der saisonale Wert 5,0205 wird dagegen in Trainings-IQR des $t - 24$-Residuums gemessen.

Bei 1.077 Kalibrierungsfenstern (7,10 %) sind 13 bis 24 der vorhergehenden 24 Kontextstunden imputiert, obwohl das kalibrierte Ziel selbst gemessen ist. Bei 92,90 % ist mindestens die Hälfte des Kontexts ursprünglich gemessen.

6.2 Prognosegüte im Testabschnitt

Tabelle 6.1: Prognosegüte auf 13.142 gemessenen Testzielen. Die Abdeckung und Breite beziehen sich auf die empirisch kalibrierten Intervalle. Eigene Darstellung.

Modell	Ziel	MAE	RMSE	MASE	rel. MAE	Abdeckung	Breite
LSTM	Visitors	12,399	21,213	0,720	0,581	99,01 %	161,04
Transformer	Visitors	11,748	19,941	0,682	0,546	98,93 %	161,30
LSTM	AvgDuration	3,020	5,786	0,677	0,716	99,00 %	39,44
Transformer	AvgDuration	2,964	5,748	0,664	0,708	98,93 %	41,49

MAE, RMSE und Intervallbreite sind nach der Rücktransformation in der Originalskala des jeweiligen API-Felds angegeben: für `visitors` in stündlichen Proxy-Zähleinheiten, für `avgDuration` in der von der API gelieferten, dort nicht eigens bezeichneten Einheit. MASE und relativer MAE sind dimensionslos.

Alle MASE-Werte liegen unter eins. Der Transformer erzielt bei beiden Zielgrößen kleinere MAE- und RMSE-Werte als der LSTM. Auf den 10.716 vollständig gemessenen $t-24$-Paaren verbessert er den Besucher-MAE um etwa 45,4 % gegenüber der saisonalen Prognose; beim LSTM sind es etwa 41,9 %. Die gemeinsame empirische Abdeckung beider Zielgrößen beträgt 98,42 % beim Transformer und 98,53 % beim LSTM. Die Transformer-Intervalle sind dabei etwas breiter. Bei `visitors` ist die mittlere Intervallbreite von ungefähr 161 zudem rund 13- bis 14-mal so groß wie der jeweilige MAE. Die annähernd 99-%-Abdeckung wird folglich mit vergleichsweise breiten Grenzen erreicht. Abdeckung und Breite sind daher gemeinsam zu interpretieren und belegen allein keine hohe Trennschärfe des Anomaliedetektors. Die Werte für `avgDuration` und die gemeinsame Abdeckung sind Prognosediagnosen; der Alarm verwendet nur den Besucher-Score.

6.3 Anomaliekandidaten im nicht injizierten Testabschnitt

Die endgültig kalibrierte LSTM-Regel markiert 79 der 13.142 gemessenen Testpunkte. Sie bilden 75 zusammenhängende Forecast-Ereignisse. 32 Punkte (40,5 %) erhalten wegen stark imputierter Kontexte oder einer absoluten Überschreitung unter einer Proxy-Zähleinheit niedrige Konfidenz. Abbildung 6.2 zeigt einen automatisch ausgewählten siebentägigen Ausschnitt mit vier Forecast-Kandidaten eines Sensors. Die Markierungen bedeuten statistische Abweichungen und keine fachlich bestätigten Anomalien.

Der Transformer markiert 140 Testpunkte in 140 Ereignissen; 67 Punkte (47,9 %) besitzen niedrige Konfidenz. Bei nahezu der Hälfte der Kandidaten ist somit der Kontext stark imputiert oder die absolute Intervallüberschreitung kleiner als eine Proxy-Zähleinheit; diese Markierungen erfordern eine besonders vorsichtige fachliche Prüfung. Beide Modelle weisen zusätzlich 8.458 nicht gemessene Teststunden in 2.016 Datenqualitätsereignissen aus. Alle 30 Sensoren erfüllen im Jahresdatensatz die Mindestmenge für die Modellierung. Forecast- und Datenqualitätsereignisse bleiben getrennt, damit ein fehlender Datenstrom nicht als bestätigte Abweichung der Passantenfrequenz erscheint.

Unter der Annahme, dass jeder Sensor von seiner ersten Messung bis zum globalen Datenende aktiv ist, umfasst der Juni-Test 21.600 mögliche Sensorstunden. Davon sind 13.142 Stunden gemessen (60,8 %) und 8.458 nicht gemessen (39,2 %). Alle 30 Sensoren besitzen im Test gemessene Zielstunden, jedoch in unterschiedlichem Umfang: Beim Sensor "Kurpark – Großer Teich – Toilette" sind 97 von 720 möglichen Stunden gemessen. Die Prognosekennzahlen beschreiben daher nur die beobachtbaren Testziele und nicht alle Sensoren gleichmäßig.

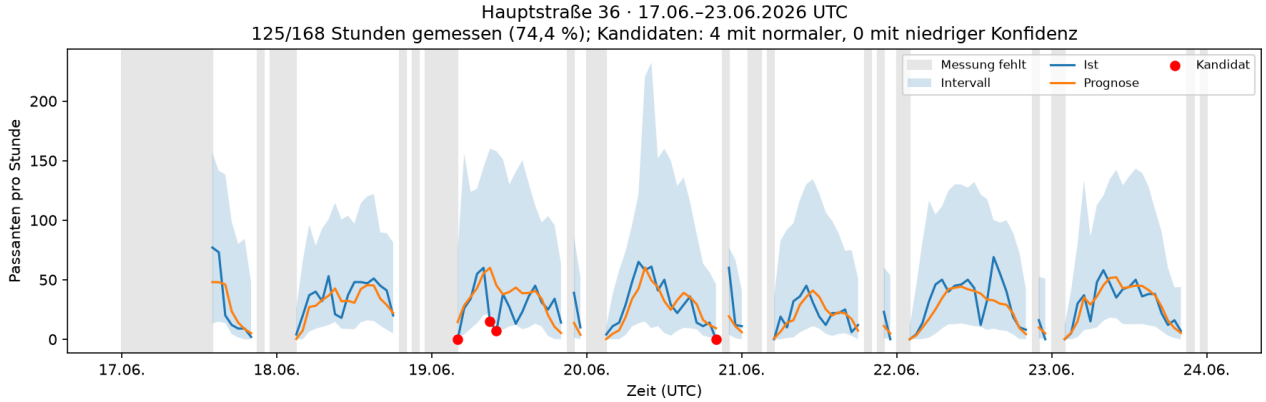


Abbildung 6.2: Automatisch ausgewählter siebentägiger Ausschnitt mit Messung, Medianprognose, empirisch kalibriertem Intervall und Forecast-Kandidaten. Graue Flächen kennzeichnen fehlende Stunden und unterbrechen die Linien; rote Punkte markieren die vier Kandidaten mit normaler Konfidenz. Kandidaten mit niedriger Konfidenz treten in diesem Ausschnitt nicht auf.

Für die 75 LSTM- und 140 Transformer-Ereignisse liegen keine vollständigen fachlichen Bewertungen vor. Daher werden daraus keine realen Precision-, Recall-, F1- oder AUC-Werte berechnet.

6.4 Ergebnisse der Anomalieinjektion

Tabelle 6.2 fasst für den LSTM-Forecaster die starken Besucher-Injektionen der Stärke 2,0 und den gefilterten sechs Stunden langen Stuck-at-Test über drei festgelegte Zufallsstartwerte des Testabschnitts zusammen. Sämtliche Treffer sind inkrementell gegenüber dem jeweils gepaarten nicht injizierten Vergleichsdurchlauf.

Tabelle 6.2: Punkt-, Ranking- und Ereignisergebnisse der LSTM-Testinjektionen. Pos. bezeichnet die positiven Stunden in drei Läufen mit zusammen 39.426 bewerteten Punkten je Typ; R = Recall.

Typ	Pos.	Anteil	AP	Punkt-R	Punkt-F1	Ereignis-R	Ereignis-F1
Spike, 2,0	60	0,152 %	0,684	0,933	0,644	0,933	0,933
Dip, 2,0	54	0,137 %	0,582	0,870	0,913	0,870	0,922
Level-Shift, 2,0	144	0,365 %	0,497	0,938	0,736	1,000	0,878
Drift, 2,0	143	0,363 %	0,278	0,608	0,582	0,917	0,943
Stuck-at, 6 h	60	0,152 %	0,020	0,367	0,494	0,600	0,706

Die positiven Stunden bilden je Typ nur 0,137 bis 0,365 % der Testpopulation. Die No-Skill-Präzision entspricht dem jeweiligen Positivanteil; das gleichgewichtete Niveau über die fünf Typen beträgt daher nur etwa 0,0023. Auch die AP einer zufälligen endlichen Rangfolge liegt näherungsweise auf diesem Niveau. Eine AP von 0,412 ist folglich nicht als 41,2 % korrekt klassifizierter Stunden zu lesen. Die Unterschiede innerhalb der Tabelle zeigen zugleich, dass die Rankinggüte stark vom Anomalietyp abhängt.

Die starken Level-Shifts werden vollständig auf Ereignisebene gefunden. Auch der Drift erreicht einen Ereignis-Recall von 0,917: 33 von 36 injizierten Drift-Ereignissen werden mindestens einmal überlappt, aber nur 87 von 143 betroffenen Stunden alarmiert (Punkt-Recall 0,608). Der Ereignis-F1 verbindet Ereignis-Recall und Ereignis-Precision und bestraft damit auch zusätzliche Alarmereignisse; ungedeckte Stunden innerhalb eines bereits zugeordneten Ereignisses bewertet er jedoch nicht. Bei mehrstündigen Veränderungen kann außerdem das bereits veränderte Signal in den nachfolgenden Modellkontext eingehen und die Prognose teilweise an das neue Niveau anpassen. Da bewusst kein nachträgliches Point-Adjustment verwendet

wird, bleibt die punktweise Bewertung streng. Stuck-at bleibt mit einem Ereignis-F1 von 0,706 am schwierigsten. Bei Stärke 0,5 beträgt der Ereignis-Recall 0,100 für Spike, 0,130 für Dip, 0,361 für Level-Shift und 0,139 für Drift. Der Detektor erkennt folglich nicht jede definierte schwache Anomalie. Die vollständigen Ergebnisse aller Stärken einschließlich Precision, Average Precision (AP), IoU und Verzögerung sind im digitalen Begleitmaterial dokumentiert.

6.5 Vergleich der finalen Modelle

Tabelle 6.3 vergleicht LSTM-Forecaster, Transformer-Forecaster, Autoencoder und robuste saisonale Baseline auf den starken Testinjektionen. Für die binären Metriken werden die Konfusionswerte der drei Zufallsstartwerte zunächst je Typ zusammengeführt; für ROC-AUC und AP gilt dies analog für die Label-Score-Paare. Anschließend werden die fünf Typmetriken gleich gewichtet gemittelt. Es handelt sich damit um Makromittel und nicht um eine gemeinsame Berechnung über alle 461 positiven Stunden. Bei den Ereignismetriken erhält Stuck-at mit zehn wahren Ereignissen dasselbe Gewicht wie Spike mit 60; sein Ergebnis ist daher weniger stabil, verhindert aber zugleich eine Dominanz häufigerer Typen. Die künstlichen Testereignisse wurden für kein Verfahren zur Architektur- oder Regelauswahl verwendet.

Tabelle 6.3: Gemeinsamer Vergleich auf starken künstlichen Anomalien. Eigene Darstellung.

Modell	Parameter	Makro-ROC-AUC	Makro-AP	Makro-Punkt-F1	Makro-Ereignis-R	Makro-Ereignis-F1
LSTM-Forecaster	21.598	0,948	0,412	0,674	0,864	0,876
Transformer	61.398	0,949	0,422	0,670	0,853	0,824
Autoencoder	50.562	0,880	0,110	0,534	0,699	0,653
Saisonal $t-24$	0	0,795	0,071	0,436	0,579	0,498

Der Transformer erreicht die knapp höchste ROC-AUC und AP. Der LSTM besitzt dagegen den knapp höheren Punkt-F1 sowie den höchsten Ereignis-Recall und Ereignis-F1. Der AP-Vorsprung des Transformers ist nicht über alle Typen einheitlich: Bei Spike und Dip erreicht er 0,805 gegenüber 0,684 beziehungsweise 0,655 gegenüber 0,582. Der LSTM liegt dagegen bei Level-Shift, Drift und Stuck-at mit 0,497, 0,278 und 0,020 vor den Transformerwerten 0,389, 0,250 und 0,012.

ROC-AUC und AP bewerten die schwellenfreie Rangfolge der Rohscores, der Punkt-F1 dagegen die fest ausgewählte binäre Alarmregel. Eine hohe ROC-AUC bei niedrigerer AP ist wegen der sehr seltenen positiven Stunden kein Widerspruch: Bereits wenige hoch bewertete Hintergrundstunden senken die Precision an der Spitze der Rangfolge. Im synthetischen Benchmark gelten alle nicht injizierten Stunden als negativ. Darunter können mangels realer Labels auch natürlich auffällige Stunden liegen; die AP misst daher die Trennung der definierten Injektionen vom unveränderten Testhintergrund und keine reale fachliche Anomalieprecision.

Die gemeinsame Testpopulation umfasst 13.142 gemessene Zielpunkte je Testdurchlauf; die saisonale Baseline kann davon 10.716 mit einer ebenfalls gemessenen $t-24$-Referenz bewerten. An den übrigen Punkten enthält sie sich eines Alarms und fehlende Scores werden für die Rankingmetriken als niedrigste Priorität eingeordnet. Ohne synthetische Injektionen alarmieren LSTM, Transformer, Autoencoder und saisonale Baseline bei 0,601 %, 1,065 %, 1,301 % beziehungsweise 0,928 % der gemessenen Testziele. Diese Werte sind Kandidatenraten und mangels realer Negativlabels keine False-Positive-Raten. Das Kalibrierungsbudget von 1 % gilt zudem nur für den Kalibrierungsabschnitt und garantiert keine identische Rate im späteren Test.

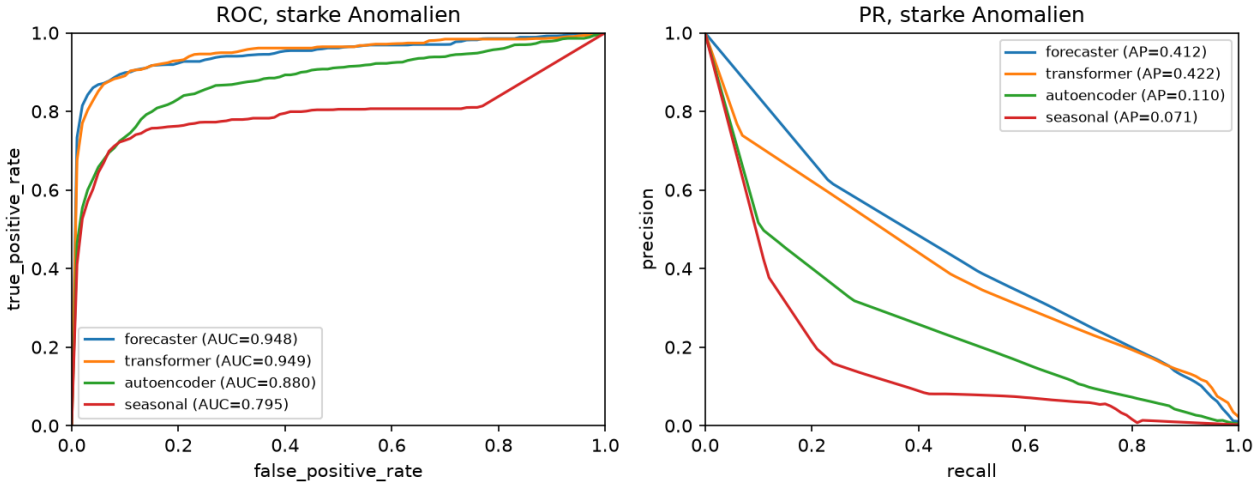


Abbildung 6.3: Mittlere ROC- und PR-Kurven der starken synthetischen Anomalien.

Im Rauschtest erzeugt der LSTM-Forecaster bei 5 % und 15 % Stärke acht und 15 zusätzliche Alarme, entsprechend 0,061 % und 0,114 % der gemessenen Testpunkte. Beim Transformer sind es elf und 27 (0,084 % und 0,205 %), beim Autoencoder 15 und 22 (0,114 % und 0,167 %) und bei der saisonalen Baseline vier und zwölf (0,030 % und 0,091 %). Die Baseline ohne trainierbare Modellparameter ist in diesem Test somit am stabilsten, besitzt aber die schwächeren Erkennungskennzahlen.

6.6 Diskussion und Limitationen

Die Ergebnisse beantworten die Forschungsfrage differenziert. Der Transformer prognostiziert beide Messgrößen genauer und erzielt die minimal höhere ROC-AUC und die höhere Average Precision. Die auf dem Kalibrierungsabschnitt ausgewählte LSTM-Regel liefert auf den starken synthetischen Testinjektionen jedoch den knapp höheren Punkt-F1 sowie den höheren Ereignis-Recall und Ereignis-F1. Die zusätzliche Attention ist damit keine allgemeine Garantie für bessere binäre Alarme. Die saisonale Methode zeigt den Wert einer einfachen Baseline. Der Autoencoder übertrifft sie in den zusammengefassten Erkennungskennzahlen, bleibt aber trotz 200 Trainingsepochen hinter beiden Prognosemodellen.

Die synthetischen Referenzlabels gelten ausschließlich für die definierten Transformationen der Passantenfrequenz. Sie belegen weder den Recall unbekannter realer Anomalien noch die fachliche Richtigkeit der 75 LSTM- beziehungsweise 140 Transformer-Kandidatenereignisse. Der Datensatz umfasst zwar rund zwölf Monate, aber nur einen Ort und ungefähr einen Jahreszyklus. Es fehlt eine zeitlich und räumlich unabhängige externe Bestätigung. Zudem wurden 32,83 % der Sensorstunden unter der verwendeten Aktivitätsannahme imputiert; diese Werte werden nicht als Ziele verwendet, können aber den Kontext beeinflussen. Zeitliche Abhängigkeit verhindert eine klassische verteilungsfreie Conformal-Garantie. Der feste einmonatige Testzeitraum war während der retrospektiven Modellentwicklung bereits einsehbar. Die Ergebnisse sind daher nicht als vollständig unabhängige konfirmatorische Evaluation zu interpretieren. Neue Zufallsstartwerte trennen die Testinjektionen von der Kalibrierung, ersetzen aber keine Studie mit realen Labels und mehreren Rolling-Origin-Ursprüngen.

Kapitel 7

Zusammenfassung und Ausblick

Die aufbereiteten Sensordaten wurden mit vier getrennten Verfahren untersucht: Ein LSTM und ein kompakter Transformer bewerten Abweichungen von ihrer Prognose, ein Autoencoder bewertet Rekonstruktionsfehler und eine robuste Baseline ohne trainierbare Modellparameter die Abweichung vom gemessenen Wert 24 Stunden zuvor. Die drei neuronalen Modelle lernen zusätzlich die Verweildauer; sämtliche Alarme und künstlichen Testanomalien beziehen sich aber ausschließlich auf die Passantenfrequenz. Die Verfahren verwenden dieselben Zeitabschnitte und Entscheidungskriterien, ohne ihre Anomaliewerte miteinander zu vermischen.

Von den beiden Prognosemodellen erzielt der Transformer auf den gemessenen Testzielen für beide Zielgrößen die geringeren Fehler und erreicht auf starken synthetischen Anomalien die knapp höchste mittlere ROC-AUC und Average Precision. Der LSTM erreicht mit der kalibrierten Alarmregel dagegen den knapp höheren Punkt-F1 sowie den höchsten Ereignis-Recall und Ereignis-F1. Die saisonale Baseline reagiert am robustesten auf zusätzliches Zählwertrauschen, bleibt bei der Erkennung der injizierten Ereignisse aber hinter den drei neuronalen Modellen. Der Autoencoder übertrifft die saisonale Baseline, erreicht jedoch trotz 200 Trainingsepochen nicht die Gesamtkennzahlen der Prognosemodelle. Zusätzliche Attention geht damit mit geringeren Prognosefehlern sowie einer nahezu identischen, minimal höheren ROC-AUC und AP einher, verbessert die binäre Alarmregel aber nicht durchgehend. Die zusammengefassten Werte verdecken dabei eine klare Typabhängigkeit: Beide Prognosemodelle ordnen abrupte Spikes und Dips wesentlich zuverlässiger als Drift und insbesondere Stuck-at. Der Ereignis-F1 kombiniert dabei Precision und Recall zusammenhängender Ereignisse, bewertet jedoch nicht die vollständige stündliche Abdeckung innerhalb eines bereits zugeordneten Ereignisses.

Für weiterführende Untersuchungen sind verifizierte Sensorlaufzeiten sowie eine zeitlich und möglichst räumlich unabhängige Datenquelle mit fachlich bestätigten Ereignislabels erforderlich. Eine Rolling-Origin-Auswertung über mehrere Zeitabschnitte könnte zusätzlich prüfen, ob Modellrangfolge und kalibrierte Alarmregeln gegenüber zeitlichen Veränderungen stabil bleiben. Erst reale Ereignislabels erlauben belastbare Aussagen zur Erkennung unbekannter fachlicher Anomalien.

Literatur

[1] Rina Foygel Barber u. a. "Conformal Prediction Beyond Exchangeability". In: *The Annals of Statistics* 51.2 (2023), S. 816–845. DOI: 10.1214/23-AOS2276.

[2] Yuchen Fang u. a. "Temporal-Frequency Masked Autoencoders for Time Series Anomaly Detection". In: *2024 IEEE 40th International Conference on Data Engineering*. 2024, S. 1228–1241. DOI: 10.1109/ICDE60146.2024.00099.

[3] Jan Gasthaus u. a. "Probabilistic Forecasting with Spline Quantile Function RNNs". In: *Proceedings of the Twenty-Second International Conference on Artificial Intelligence and Statistics*. Bd. 89. Proceedings of Machine Learning Research. 2019, S. 1901–1910. URL: https://proceedings.mlr.press/v89/gasthaus19a.html.

[4] Sepp Hochreiter und Jürgen Schmidhuber. "Long Short-Term Memory". In: *Neural Computation* 9.8 (1997), S. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.

[5] Kyle Hundman u. a. "Detecting Spacecraft Anomalies Using LSTMs and Nonparametric Dynamic Thresholding". In: *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2018, S. 387–395. DOI: 10.1145/3219819.3219845.

[6] Rob J. Hyndman und Anne B. Koehler. "Another Look at Measures of Forecast Accuracy". In: *International Journal of Forecasting* 22.4 (2006), S. 679–688. DOI: 10.1016/j.ijforecast.2006.03.001.

[7] Siwon Kim u. a. "Towards a Rigorous Evaluation of Time-Series Anomaly Detection". In: *Proceedings of the AAAI Conference on Artificial Intelligence* 36.7 (2022), S. 7194–7201. DOI: 10.1609/aaai.v36i7.20680.

[8] Roger Koenker und Gilbert Bassett Jr. "Regression Quantiles". In: *Econometrica* 46.1 (1978), S. 33–50. DOI: 10.2307/1913643.

[9] Bryan Lim u. a. "Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting". In: *International Journal of Forecasting* 37.4 (2021), S. 1748–1764. DOI: 10.1016/j.ijforecast.2021.03.012.

[10] Qinghua Liu und John Paparrizos. "The Elephant in the Room: Towards a Reliable Time-Series Anomaly Detection Benchmark". In: *Advances in Neural Information Processing Systems*. Bd. 37. 2024. DOI: 10.52202/079017-3437.

[11] Magistrat der Stadt Bad Nauheim. *Datenstrategie: Wege zur digitalen Stadt*. Version 1.0. Stadt Bad Nauheim, Fachdienst Digitalisierung & IT, 1. Juli 2024. URL: https://www.bad-nauheim.de/frontend/0_dokumente/3_lebenswert/digitalisierung/Bad_Nauheim_Datenstrategie_1.0.pdf (besucht am 27. 08. 2026).

[12] Pankaj Malhotra u. a. "LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection". In: *ICML 2016 Anomaly Detection Workshop*. 2016. DOI: 10.48550/arXiv.1607.00148.

[13] Yuqi Nie u. a. "A Time Series is Worth 64 Words: Long-term Forecasting with Transformers". In: *The Eleventh International Conference on Learning Representations*. 2023. URL: https://openreview.net/forum?id=Jbdc0vTOcol.

[14] Yaniv Romano, Evan Patterson und Emmanuel J. Candès. "Conformalized Quantile Regression". In: *Advances in Neural Information Processing Systems*. Bd. 32. 2019, S. 3543–3553. URL: https://proceedings.neurips.cc/paper_files/paper/2019/hash/5103c3584b063c431bd1268e9b5e76fb-Abstract.html.

[15] David Salinas u. a. "DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks". In: *International Journal of Forecasting* 36.3 (2020), S. 1181–1191. DOI: 10.1016/j.ijforecast.2019.07.001.

[16] M. Saquib Sarfraz u. a. "Position: Quo Vadis, Unsupervised Time Series Anomaly Detection?" In: *Proceedings of the 41st International Conference on Machine Learning*. Bd. 235. Proceedings of Machine Learning Research. 2024, S. 43461–43476. URL: https://proceedings.mlr.press/v235/sarfraz24a.html.

[17] Sebastian Schmidl, Phillip Wenig und Thorsten Papenbrock. "Anomaly Detection in Time Series: A Comprehensive Evaluation". In: *Proceedings of the VLDB Endowment* 15.9 (2022), S. 1779–1797. DOI: 10.14778/3538598.3538602.

[18] Muhammad Awais Shafique. "Imputing Missing Data in Hourly Traffic Counts". In: *Sensors* 22.24 (2022), S. 9876. DOI: 10.3390/s22249876.

[19] Nitish Srivastava u. a. "Dropout: A Simple Way to Prevent Neural Networks from Overfitting". In: *Journal of Machine Learning Research* 15.56 (2014), S. 1929–1958. URL: https://www.jmlr.org/papers/v15/srivastava14a.html.

[20] Stadt Bad Nauheim. *Smart-City-Cockpit: Passantenfrequenz*. URL: https://smartes.bad-nauheim.de/#!/map/pedestrianFrequencyCQM (besucht am 27. 08. 2026).

[21] Tuo Sun u. a. "Traffic Missing Data Imputation: A Selective Overview of Temporal Theories and Algorithms". In: *Mathematics* 10.14 (2022), S. 2544. DOI: 10.3390/math10142544.

[22] Nesime Tatbul u. a. "Precision and Recall for Time Series". In: *Advances in Neural Information Processing Systems*. Bd. 31. 2018, S. 1920–1930. URL: https://proceedings.neurips.cc/paper_files/paper/2018/hash/8f468c873a32bb0619eaeb2050ba45d1-Abstract.html.

[23] Ashish Vaswani u. a. "Attention is All you Need". In: *Advances in Neural Information Processing Systems*. Bd. 30. Curran Associates, Inc., 2017, S. 5998–6008. URL: https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.

[24] Pascal Vincent u. a. "Extracting and Composing Robust Features with Denoising Autoencoders". In: *Proceedings of the 25th International Conference on Machine Learning*. 2008, S. 1096–1103. DOI: 10.1145/1390156.1390294.

[25] Ruibin Xiong u. a. "On Layer Normalization in the Transformer Architecture". In: *Proceedings of the 37th International Conference on Machine Learning*. Bd. 119. Proceedings of Machine Learning Research. PMLR, 2020, S. 10524–10533. URL: https://proceedings.mlr.press/v119/xiong20b.html.

[26] Ailing Zeng u. a. "Are Transformers Effective for Time Series Forecasting?" In: *Proceedings of the AAAI Conference on Artificial Intelligence* 37.9 (2023), S. 11121–11128. DOI: 10.1609/aaai.v37i9.26317.

[27] Yimei Zhang u. a. "A Comprehensive Survey on Traffic Missing Data Imputation". In: *IEEE Transactions on Intelligent Transportation Systems* 25.12 (2024), S. 19252–19275. DOI: 10.1109/TITS.2024.3478816.