

Frankfurt University
of Applied Sciences

– Fachbereich 2: Informatik und Ingenieurwissenschaften –

Deep-Learning-basierte Anomalieerkennung in Passantenfrequenzen

Projektarbeit im Rahmen des Bachelorstudiums

Bachelor of Science (B.Sc.)

vorgelegt am 21. Juli 2026 von

Sherwin Nourinfar, Wassim Hanane

Matrikelnummer: 1552887, 1583937

Referent	:	Daniel Helmer
Korreferent	:	–

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich die vorliegende Arbeit selbständig verfasst und keine anderen als die im Literaturverzeichnis angegebenen Quellen benutzt habe.

Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder noch nicht veröffentlichten Quellen entnommen sind, sind als solche kenntlich gemacht.

Die Zeichnungen oder Abbildungen in dieser Arbeit sind von mir selbst erstellt worden oder mit einem entsprechenden Quellennachweis versehen.

Diese Arbeit ist in gleicher oder ähnlicher Form noch bei keiner anderen Prüfungsbehörde eingereicht worden.

Frankfurt, 21. Juli 2026



Sherwin Nourinfar, Wassim Hanane

Inhaltsverzeichnis

1 Einführung **2**

1.1 Motivation . . . 2

1.2 Zielsetzung . . . 2

1.3 Aufbau der Arbeit . . . 2

2 Hintergrund **3**

2.1 Zeitreihen und Anomalien . . . 3

2.2 Erkennung mit Vorhersagen . . . 3

2.3 LSTM, Autoencoder und Transformer . . . 3

3 Stand der Technik **4**

3.1 Prognosen mit fehlenden und auffälligen Werten . . . 4

3.2 Kleine rekurrente Modelle . . . 4

3.3 Bewertung der Anomalieerkennung . . . 4

3.4 Prognose und Rekonstruktion . . . 5

4 Entwickelte Methode **6**

4.1 Datengrundlage . . . 6

4.2 Datenqualität . . . 6

4.3 Bereinigung der Mehrfachmessungen . . . 7

4.4 Behandlung der Messlücken . . . 8

4.5 Kritische Betrachtung . . . 8

4.6 Prognosemodell . . . 9

4.6.1 Lernaufgabe und Eingaberepräsentation . . . 9

4.6.2 Modellarchitektur und Training . . . 10

4.6.3 Anomaliewert aus dem Prognosefehler . . . 11

4.6.4 Umgang mit imputierten Zielwerten . . . 11

4.6.5 Vergleichsverfahren . . . 12

5 Evaluation der Methode **13**

5.1 Zeitliche Datentrennung . . . 13

5.2 Vergleich mit dem Basismodell . . . 13

5.3 Kennzahlen für Prognose und Modellgröße . . . 14
5.4 Prüfung mit künstlichen Anomalien . . . 14
5.5 Evaluation der Imputation . . . 14
5.6 Rauschrobustheit und reale Fallprüfung . . . 14
5.7 Reproduzierbarkeit . . . 14

6 Ergebnisse **16**
6.1 Vergleich der beiden LSTM-Modelle . . . 16
6.2 Prognosegüte und einfache Referenzen . . . 16
6.3 Kandidaten im unveränderten Datensatz . . . 16
6.4 Ergebnisse der starken Testinjektionen . . . 17
6.5 Imputations- und Rauschprüfung . . . 17
6.6 Manuelle Fallprüfung und Limitationen . . . 18

7 Zusammenfassung und Ausblick **19**

A Programmcode **20**

Literatur **23**

Kurzfassung

Diese Arbeit entwickelt ein unüberwachtes Verfahren zur Erkennung auffälliger Passanten- und Verweildauerdaten aus Bad Nauheim. Die Datenaufbereitung fasst Mehrfachmessungen zusammen, kennzeichnet Ausfälle und ergänzt interne Lücken, ohne Informationen aus dem späteren Testzeitraum zu verwenden. Ein einfaches LSTM sagt aus den vorhergehenden 24 Stunden die nächste Stunde voraus. Große Abweichungen zwischen Vorhersage und Messung gelten als mögliche Anomalien. Unter gleichen Testbedingungen benötigt das aktuelle LSTM 5.170 statt 17.282 Parameter. Bei starken künstlichen Anomalien steigt der mittlere F1-Wert gegenüber dem Basismodell von 0,401 auf 0,491. Die normale Besucherprognose wird dabei etwas schlechter. Der Vorteil liegt daher in der Erkennung der geprüften Anomalien und nicht in jeder einzelnen Kennzahl. Die nur zweiwöchige Datenbasis und fehlende vollständige reale Markierungen begrenzen die Aussagekraft.

Kapitel 1

Einführung

Wie viele Menschen zu einer bestimmten Zeit an einem Ort unterwegs sind, folgt meist einem klaren Rhythmus. Tagsüber sind es mehr als nachts, und unter der Woche andere Zahlen als am Wochenende. Auch der Ort spielt eine Rolle, denn an einem belebten Platz ist mehr los als in einer ruhigen Seitenstraße. Wenn man dieses regelmäßige Verhalten kennt, fallen Abweichungen davon auf. Eine solche Abweichung vom gewohnten Muster nennt man Anomalie.

Grundlage dieser Arbeit ist ein realer Datensatz der Stadt Bad Nauheim. An 30 Standorten wurde vom 30. Juni bis zum 13. Juli 2025 stündlich gezählt, wie viele Passanten unterwegs waren. Für jeden Sensor entsteht so eine eigene Zeitreihe über zwei Wochen.

1.1 Motivation

Mit diesem Projekt wollen wir herausfinden, ob sich solche Anomalien mit Methoden des Deep Learnings zuverlässig erkennen lassen und welche Modellart sich dafür am besten eignet. Die Schwierigkeit dabei ist, dass die Daten nicht beschriftet sind. Es ist nirgends vermerkt, welche Stunde normal war und welche nicht. Ein Modell muss das normale Verhalten also selbst aus den Daten lernen und melden, wenn die Realität davon abweicht. Feste Schwellenwerte helfen hier kaum, weil sich das Normalverhalten je nach Tageszeit, Wochentag und Standort verändert.

1.2 Zielsetzung

Das Ziel ist ein System, das für jeden Sensor das normale Passantenaufkommen lernt und auffällige Stunden meldet. Der erste Ansatz ist ein bewusst einfaches LSTM, das die nächste Stunde vorhersagt. Bewertet wird es im Vergleich mit einem Basismodell und drei leicht verständlichen statistischen Regeln. Dabei zählt nicht nur die Genauigkeit der Vorhersage, sondern vor allem, wie gut künstlich erzeugte Anomalien erkannt werden. Eine weitere Architektur wird in einem späteren Projektschritt getrennt trainiert und bewertet.

1.3 Aufbau der Arbeit

Kapitel 2 erklärt die nötigen Grundlagen zu Zeitreihen, neuronalen Netzen und den verwendeten Architekturen. Anschließend ordnet der Stand der Technik die Arbeit in bestehende Verfahren ein. Danach folgen die entwickelte Methode mit Datenaufbereitung und Training, die Evaluation der Modelle und die Ergebnisse. Den Abschluss bildet eine Zusammenfassung mit Ausblick.

Kapitel 2

Hintergrund

2.1 Zeitreihen und Anomalien

Eine Zeitreihe ordnet Messwerte chronologisch. Bei Passantenfrequenzen hängen benachbarte Stunden zusammen; zusätzlich wiederholen sich Tagesmuster. Eine Anomalie ist deshalb nicht zwingend ein großer absoluter Wert, sondern eine Abweichung vom zeit- und ortsabhängig erwarteten Verhalten. Punktanomalien betreffen einzelne Stunden. Sprunghafte Niveauwechsel (Level-Shifts), schleichende Verschiebungen (Drifts) und festgefrorene Sensorwerte (Stuck-at) erstrecken sich dagegen über mehrere Stunden.

Im vorliegenden Datensatz fehlen vollständige reale Anomaliekennzeichnungen. Das Lernen des Normalverhaltens erfolgt daher selbstüberwacht: Aus vorhandenen Messwerten wird ein künstliches Lernziel erzeugt, ohne Klassen wie "normal" oder "anomal" vorzugeben. Erst der Fehler zwischen Modellschätzung und Messung wird als Anomaliesignal verwendet.

2.2 Erkennung mit Vorhersagen

Ein Vorhersagemodell erhält die letzten w Zeitpunkte und schätzt den nächsten Wert $\hat{x}_t$. Ein großer Prognosefehler $|x_t - \hat{x}_t|$ deutet darauf hin, dass die Beobachtung nicht zum erlernten Verlauf passt. Unterschiedlich skalierte Messgrößen müssen vor einer gemeinsamen Entscheidung auf eine vergleichbare Skala gebracht werden. Vorhersagegüte und Erkennungsleistung sind dabei nicht gleichbedeutend: Ein kleiner mittlerer Fehler garantiert noch keine klare Trennung seltener Anomalien.

2.3 LSTM, Autoencoder und Transformer

Long Short-Term Memory (LSTM) ist eine rekurrente Netzstruktur mit steuerbaren Speicherzuständen und eignet sich zur Verarbeitung geordneter Sequenzen [4]. Ein LSTM kann ein Zeitfenster zu einem Zustandsvektor verdichten und daraus eine Prognose erzeugen.

Ein Autoencoder lernt dagegen, sein Eingabefenster zu rekonstruieren. Ein hoher Rekonstruktionsfehler kann eine unbekannte Struktur anzeigen. Prognose und Rekonstruktion beruhen somit auf unterschiedlichen Annahmen über normales Verhalten. Ein Transformer verarbeitet verschiedene Zeitpunkte mit einem Aufmerksamkeitsmechanismus und kann dadurch auch weiter auseinanderliegende Zusammenhänge direkt gewichten. Diese zusätzliche Freiheit ist vor allem bei längeren Reihen und einer größeren Datenbasis nützlich.

Kapitel 3

Stand der Technik

3.1 Prognosen mit fehlenden und auffälligen Werten

Die Anomalieerkennung mit Vorhersagen setzt voraus, dass ein Modell das Normalverhalten ausreichend lernt. In unbeschrifteten Trainingsdaten können jedoch bereits unbekannte Anomalien enthalten sein. RobustTSF zeigt für mehrere dort definierte Zielanomalien Vorteile des absoluten gegenüber dem quadratischen Fehler [2]. DCFF-MTAD berichtet in drei Vergleichstests Verbesserungen durch die Huber-Fehlerfunktion, die große Abweichungen weniger stark gewichtet als MSE [11]. Daraus folgt keine allgemein beste Fehlerfunktion, wohl aber die Notwendigkeit, Vorhersagegüte und Anomalieerkennung getrennt zu bewerten.

Fehlende Werte tragen außerdem selbst Information. GRU-D verwendet deshalb unter anderem eine Beobachtungsmaske und zeigt, dass ein rekurrentes Modell Muster fehlender Messungen nutzen kann [1]. Eine solche Maske ist deutlich einfacher als die vollständige GRU-D-Struktur und eignet sich daher auch für ein kleines Modell.

3.2 Kleine rekurrente Modelle

Das LSTM wurde entwickelt, um längerfristige Abhängigkeiten in Sequenzen zu lernen [4]. Für die nur zwei Wochen langen Sensorreihen ist ein großes Netz jedoch nicht automatisch geeigneter. Dropout setzt während des Trainings zufällig Aktivierungen auf null und wurde als einfache Maßnahme gegen Überanpassung eingeführt [9]. Das spricht für ein kleines Netz mit mäßigem Dropout, legt aber keine bestimmte Anzahl von Einheiten fest.

3.3 Bewertung der Anomalieerkennung

Eine hohe Vorhersagegenauigkeit allein garantiert keine gute Anomalieerkennung. AFMF zeigt, dass unter anderem Skalierungsunterschiede und Anomalien im Eingabefenster die Unterscheidung zwischen normalem und auffälligem Verhalten erschweren können [8]. Goswami et al. untersuchen künstlich erzeugte Anomalien als Vergleichsmöglichkeit ohne reale Kennzeichnungen und finden einen deutlichen Zusammenhang mit der Bewertung auf beschrifteten Daten [3]. Reale Anomalien können von den künstlichen Typen abweichen; solche Tests ersetzen deshalb keine fachliche Prüfung.

mTSBench vergleicht 24 Verfahren auf 344 mehrdimensionalen Zeitreihen aus 19 Datensätzen. Kein Verfahren dominiert auf allen Datensätzen [14]. Ein Modell muss daher auf den konkreten Daten geprüft werden; gute Ergebnisse auf einem fremden Datensatz lassen sich nicht einfach übertragen.

3.4 Prognose und Rekonstruktion

MTAD-GAT optimiert Prognose und Rekonstruktion gemeinsam [13]. Im Vergleich innerhalb dieser Studie ist die gemeinsame Nutzung beider Aufgaben auf drei Datensätzen besser als jeweils nur eine Aufgabe. Das garantiert keinen Gewinn für Bad Nauheim, zeigt aber, dass Prognose- und Rekonstruktionsfehler unterschiedliche Hinweise auf Anomalien liefern können.

Kapitel 4

Entwickelte Methode

Dieses Kapitel beschreibt zunächst die nachvollziehbare Aufbereitung der Rohdaten und anschließend die Anomalieerkennung anhand von Prognosefehlern. Methodische Entscheidungen werden von den später berichteten Ergebnissen getrennt dargestellt.

4.1 Datengrundlage

Die Rohdaten liegen in Form einer JSON-Datei mit 17.578 Einzelmessungen vor. Jede Messung gehört zu einem von 30 Sensorstandorten in der Innenstadt und im Kurpark von Bad Nauheim und enthält neben dem Zeitstempel die Anzahl der erfassten Passanten (`visitors`) sowie deren mittlere Verweildauer (`avgDuration`). Der globale Erfassungszeitraum reicht vom 30. Juni bis zum 13. Juli 2025 und umfasst 335 Stunden. Sensorindividuelle Soll-Laufzeiten liegen nicht vor. Deshalb wird konservativ nur der Zeitraum zwischen erster und letzter beobachteter Messung als Laufzeit verwendet. Dadurch entstehen 9.460 aktive Sensorstunden; 590 Kombinationen des globalen Rasters werden vorläufig nicht als Messlücke behandelt. Diese Annahme verhindert künstliche Randwerte, kann einen frühen oder späten Ausfall aber fälschlich als Inaktivität deuten. Beobachtete und noch zu bestätigende Grenzen stehen deshalb getrennt in `data/sensor_activity_periods.csv`.

4.2 Datenqualität

Bei der Sichtung der Rohdaten sind zwei Probleme aufgefallen, die vor dem Training behandelt werden müssen.

Mehrfachmessungen: Für 4.770 Kombinationen aus Sensor und Stunde enthält der Datensatz mehrere Einträge, in der Spitze zehn Messungen für dieselbe Stunde (Abbildung 4.1). Die Werte dieser Einträge weichen teilweise voneinander ab, es handelt sich also nicht um exakte Kopien. Ohne Bereinigung gingen diese Stunden mehrfach und mit widersprüchlichen Werten in das Training ein.

Messlücken: Nach der Zusammenfassung und Qualitätsprüfung liegen 6.814 gültig gemessene Sensorstunden vor. Innerhalb der 9.460 aktiven Sensorstunden fehlen damit 2.646 Werte, entsprechend 28,0 %. Sie bilden 830 zusammenhängende Lücken. Davon umfassen 641 höchstens zwei Stunden; die längste Lücke innerhalb einer aktiven Sensorperiode dauert 18 Stunden (Abbildung 4.2). In 63 Stunden liegt von keinem der zu diesem Zeitpunkt aktiven Sensoren eine Messung vor. Dies deutet auf gemeinsame Ausfälle der Übertragungsinfrastruktur hin. Die Sensoren Kurpark–Eingang Ludwigstraße und Friedrichstraße 1 besitzen mit 36 beziehungsweise 59 Stunden lediglich kurze aktive Erfassungszeiträume. Zeiten nach ihrem letzten Messwert werden nicht künstlich ergänzt. Ob ihr früher Abbruch eine geplante Deaktivierung oder einen Ausfall darstellt, muss durch Betreiberinformationen geklärt werden.

Am 5. Juli 2025 um 08:00 Uhr UTC meldeten alle 28 zu diesem Zeitpunkt aktiven Sensoren gleichzeitig exakt null Besucher und null Verweildauer. Dieses stadtweite identische Muster wird als gemeinsamer Erfassungs- oder Übertragungsfehler

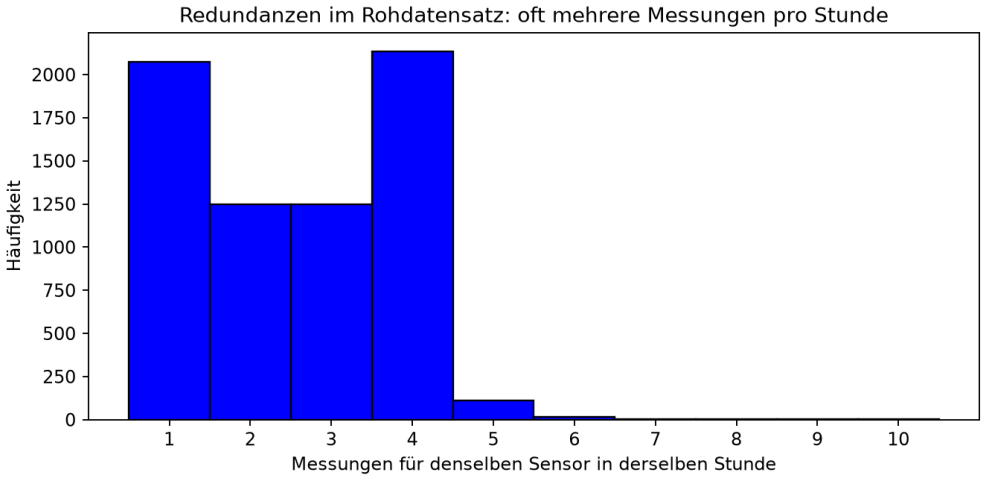


Abbildung 4.1: Häufigkeit von Mehrfachmessungen im Rohdatensatz. Für viele Stunden liegen zwei bis vier, vereinzelt bis zu zehn Einträge desselben Sensors vor.

behandelt. Die 28 Werte bleiben über die Quellenanzahl nachvollziehbar, gelten aber für Modellierung und Evaluation als fehlend.

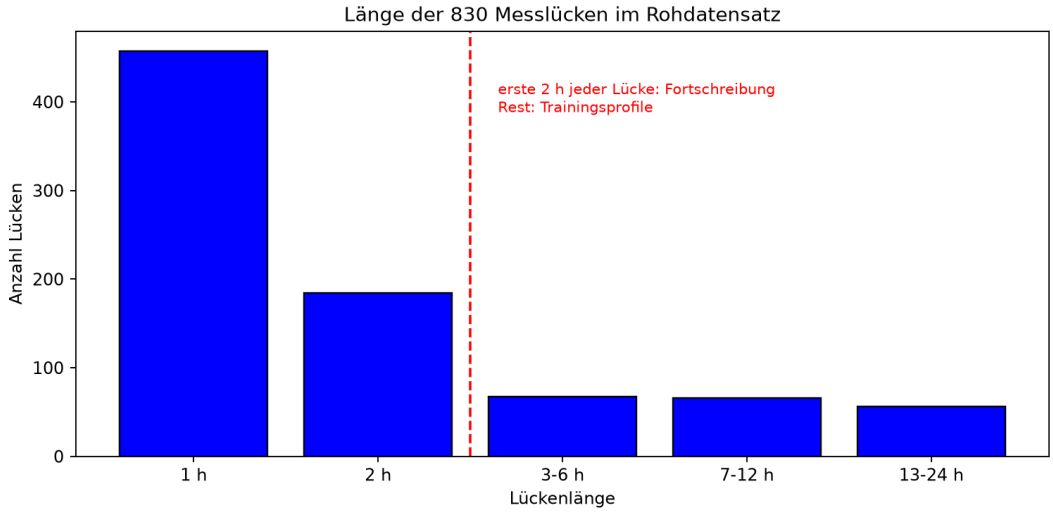


Abbildung 4.2: Längenverteilung der 830 Messlücken innerhalb der angenommenen Sensorperioden. 641 Lücken umfassen höchstens zwei Stunden.

4.3 Bereinigung der Mehrfachmessungen

Alle Einträge derselben Kombination aus Sensor und Stunde werden zu einem Messpunkt zusammengefasst. Für die Passantenzahl und die Verweildauer wird jeweils der arithmetische Mittelwert gebildet. Dadurch verbleiben zunächst 6.842 eindeutige Stundenwerte. Nach Ausschluss der 28 gemeinsamen Nullmeldungen gelten 6.814 davon als gemessen. Nach Abschluss der Imputation wird die Passantenzahl auf ganze Personen und die Verweildauer auf zwei Dezimalstellen gerundet.

4.4 Behandlung der Messlücken

Die für das Training verwendeten Zeitfenster setzen zusammenhängende Stundenreihen voraus. Eine Lücke innerhalb eines Fensters würde andernfalls unbemerkt Werte aus weit auseinanderliegenden Zeiträumen kombinieren. Die Lücken werden deshalb vor dem Training aufgefüllt, und zwar für jeden Sensor getrennt, damit jeder Standort sein individuelles Niveau und Tagesprofil behält. Die zentrale Datenaufbereitung verwendet keine lineare Interpolation. Sämtliche Profile werden ausschließlich aus ursprünglich gemessenen Werten vor dem 8. Juli 2025, 00:00 Uhr UTC, geschätzt; Validierungs-, Kalibrierungs- und Testwerte gehen damit nicht in die Profilbildung ein. Wochentag und Stunde werden in der lokalen Zeitzone `Europe/Berlin` bestimmt. Das Verfahren arbeitet in vier aufeinanderfolgenden Stufen.

Stufe 1, vergangenheitsbasierte Fortschreibung: Für die ersten zwei Stunden jeder Lücke wird der letzte zuvor gemessene Wert desselben Sensors übernommen. Mit t^- als Zeitpunkt der letzten Messung gilt

$$\hat{x}_t = x_{t^-}, \qquad 0 < t - t^- \leq 2 \text{ Stunden}. \tag{4.1}$$

Diese Regel gilt auch für die ersten beiden Positionen einer längeren Lücke. Sie benötigt keinen nachfolgenden Messwert und verhindert dadurch, dass ein späteres Prognoseziel in einen früheren Modellkontext zurückgespiegelt wird. Der Preis ist eine kurzfristig konstante Fortsetzung; die Regel stellt daher einen transparenten Kompromiss und kein allgemein optimales Imputationsverfahren dar. Auf diese Weise werden 1.203 Sensorstunden ergänzt.

Stufe 2, Wochentag-Stunden-Profil: Für die verbleibenden Lücken wird der Mittelwert desselben Sensors am gleichen lokalen Wochentag und zur gleichen lokalen Stunde aus gemessenen Trainingswerten eingesetzt. Historische Zeitprofile erhalten tages- und wochenzeitabhängige Strukturen und werden auch für fehlende Verkehrszähldaten untersucht [10]. Diese Stufe füllt 1.298 Sensorstunden.

Stufe 3, Stundenprofil: Existiert für eine Kombination aus Wochentag und Stunde keine Trainingsreferenz, wird der Mittelwert des Sensors zur gleichen lokalen Uhrzeit über alle Trainingstage verwendet. Dies betrifft 140 Sensorstunden.

Stufe 4, Sensormittel: Fehlt auch für die betreffende Uhrzeit eine Referenz, wird der Mittelwert sämtlicher gemessener Trainingswerte dieses Sensors eingesetzt. Diese Rückfallstufe betrifft fünf Sensorstunden. Damit werden alle 2.646 Lücken innerhalb der angenommenen Sensorperioden geschlossen; Zeiten vor der ersten und nach der letzten Messung eines Sensors bleiben außerhalb des Datensatzes.

Der untere Teil von Abbildung 4.3 kennzeichnet die ergänzten Stunden. Abbildung 4.4 stellt eine typische Reihe und den Sensor mit der kürzesten aktiven Erfassungszeit gegenüber. Sie zeigt zugleich, dass die Reihe nach dem Ende des Sensors nicht künstlich fortgeschrieben wird. Abbildung 4.5 fasst den ergänzten Anteil innerhalb der aktiven Zeit jedes Sensors zusammen.

4.5 Kritische Betrachtung der Bereinigung

Jede Imputation verändert die Daten. Mittelwertbasierte Verfahren können den Verlauf glätten und die Varianz verringern [12, 7]. Im vorliegenden Datensatz ändert sich der Mittelwert der Passantenzahl je Sensor um höchstens 10,29 %. Die kleinste Korrelation zwischen dem ausschließlich aus gemessenen Werten und dem aus allen bereinigten Werten gebildeten stündlichen Tagesprofil beträgt 0,9843. Diese Kennzahlen prüfen Niveau und Profil, ersetzen aber keine Fehleranalyse gegen unbekannte wahre Werte in den Lücken.

Gemessene Werte werden nicht zusätzlich geglättet. Eine Glättung könnte kurzzeitige echte Abweichungen abschwächen und damit gerade das gesuchte Signal entfernen. Die Stabilisierung beschränkt sich deshalb auf Aggregation, Transformation und Skalierung; die Folgen der Imputation werden separat durch künstliches Entfernen bekannter Messwerte geprüft.

Die zweistündige Fortschreibung verwendet zu jedem Zeitpunkt nur die Vergangenheit. Die statistischen Profile dürfen dagegen innerhalb des Trainingsabschnitts auch chronologisch spätere Trainingsmessungen enthalten. Für die Aufbereitung werden keine Validierungs- oder Testwerte verwendet. Innerhalb des Trainingsabschnitts können jedoch spätere Trainingsmessungen in die Profile einfließen; die Ergänzung ist dort also nicht zu jedem Zeitpunkt ausschließlich vergangenheitsbasiert.

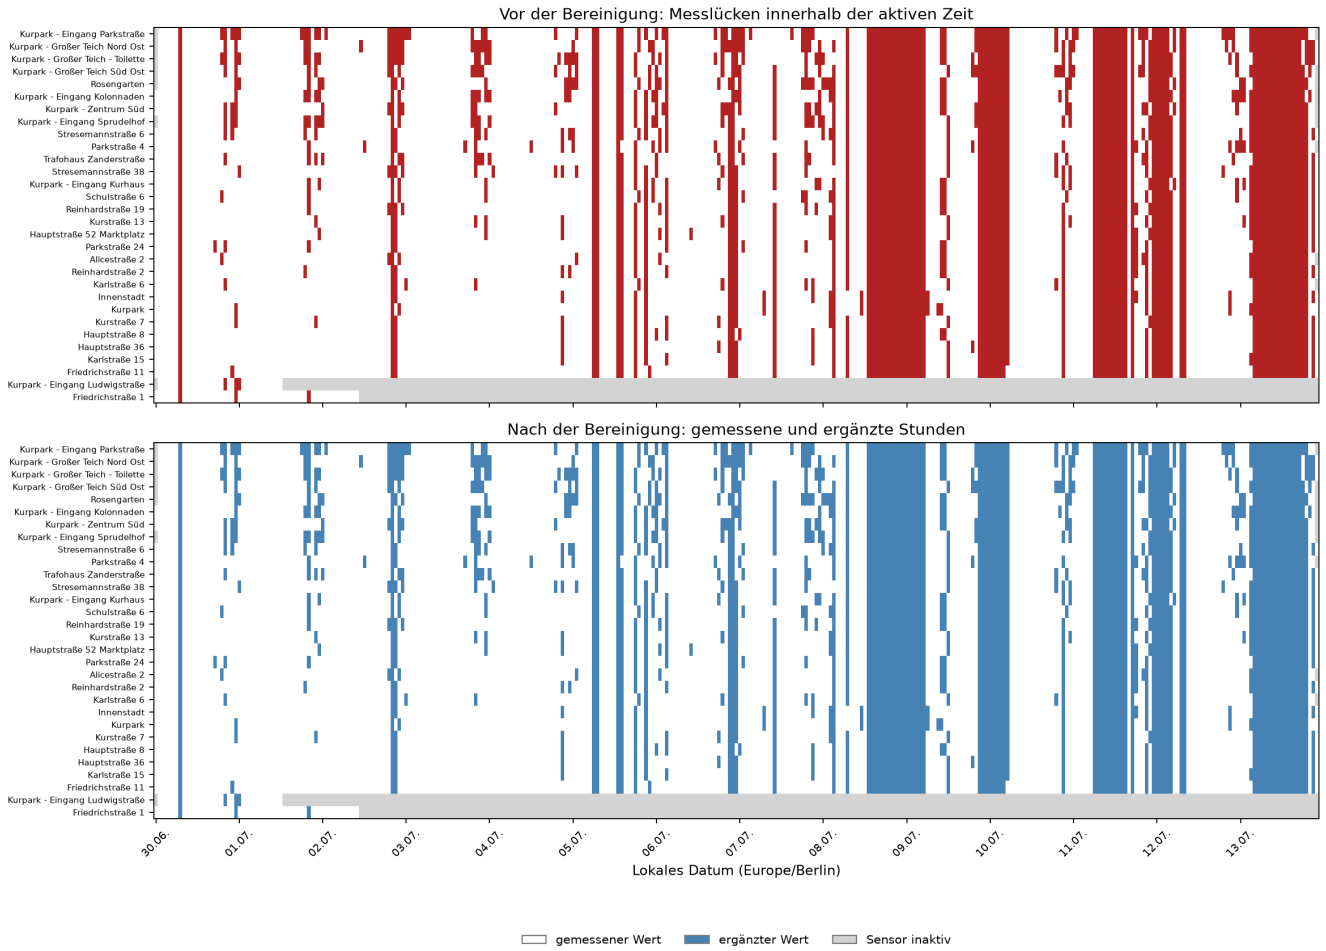


Abbildung 4.3: Messstatus vor der Bereinigung (oben) und danach (unten). Rot zeigt Lücken innerhalb der aktiven Sensorzeit, Blau ergänzte Werte und Grau Zeiträume, in denen der betreffende Sensor nicht aktiv war. Eigene Darstellung.

Ein zweiter Aspekt betrifft die Anomalieerkennung selbst. Ergänzte Stunden wirken per Konstruktion unauffällig, ein tatsächlicher Sensorausfall stellt jedoch selbst ein meldenswertes Ereignis dar. Das Fehlen von Werten folgt hier zudem eigenen, teils blockweisen Mustern und trägt damit selbst Information [12]. Das Feld `is_imputed` hält für jede Stunde fest, ob sie gemessen oder ergänzt wurde. Das Prognosemodell verwendet ergänzte Werte weiterhin als Kontext eines 24-Stunden-Fensters, überspringt jedoch Fenster mit einem ergänzten Zielwert beim Training, bei der Bestimmung des Schwellenwerts und bei der Testauswertung. Die beiden besonders kurzen Sensorreihen werden wegen ihrer geringen aktiven Länge nicht verwendet.

4.6 Anomalieerkennung anhand von Prognosefehlern

4.6.1 Lernaufgabe und Eingaberepräsentation

Das Prognosemodell lernt selbstüberwacht, aus den jeweils vorhergehenden 24 Stunden die nächste Stunde vorherzusagen. Die nachgelagerte Anomalieentscheidung ist unüberwacht, da weder das Modelltraining noch die Kalibrierung reale Anomalieklassen verwenden. Ein einziges gemeinsames Modell wird über 28 Sensoren trainiert. Zwei Sensoren werden ausgeschlossen, weil vor dem Ende des Trainingsabschnitts weniger als 72 gemessene Zielstunden vorliegen.

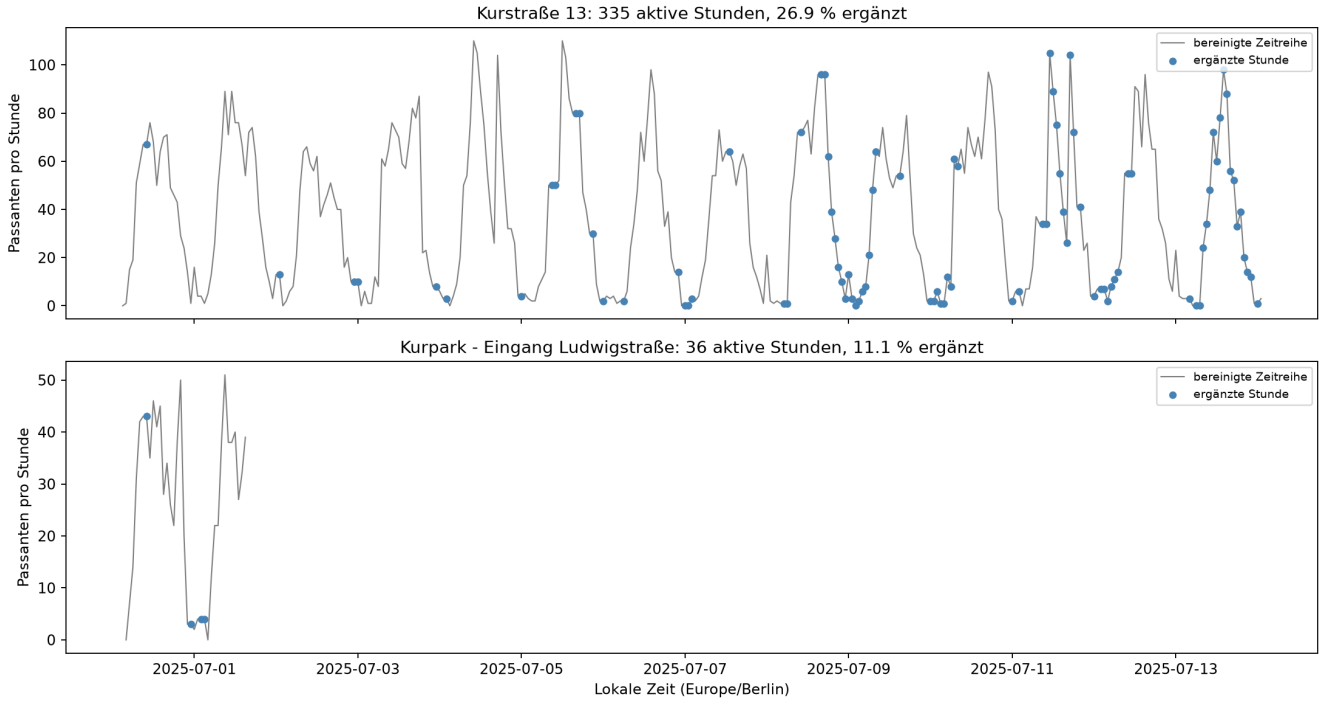


Abbildung 4.4: Bereinigte Zeitreihen eines typischen Sensors (oben) und des Sensors mit der kürzesten aktiven Erfassungszeit (unten). Markierte Punkte sind ergänzte Stunden. Eigene Darstellung.

Beide Zielgrößen werden zunächst mit $\log(1+x)$ transformiert. Danach erfolgt eine globale Standardisierung je Merkmal f:

$$z_{t,f} = \frac{\log(1 + x_{t,f}) - \mu_f}{\sigma_f}. \tag{4.2}$$

Mittelwert und Standardabweichung werden ausschließlich aus gemessenen Trainingswerten bestimmt. Jedes Zeitfenster besitzt genau drei Kanäle: `visitors`, `avgDuration` und eine Maske, die gemessene von imputierten Kontextwerten unterscheidet. Die Ausgabe enthält zwei Vorhersagewerte. Zusätzliche Kalendermerkmale und eine vom Netz gelernte Sensorcodierung werden wegen der kurzen Einzelreihen und der gewünschten Einfachheit nicht verwendet.

4.6.2 Modellarchitektur und Training

Das LSTM [4] folgt derselben einfachen `Sequential`-Struktur wie die Übungsnetze:

$$\text{Input}(24, 3) \to \text{LSTM}(32) \to \text{Dropout}(0{,}1) \to \text{Dense}(16, \text{ReLU}) \to \text{Dense}(2). \tag{4.3}$$

Das Modell besitzt 5.170 Parameter. Der lineare `Dense(2)`-Ausgang gibt die zwei Zielgrößen aus. `LSTM(32)` und `Dense(16)` halten das Netz klein; Dropout wirkt einer zu starken Anpassung an die kurzen Trainingsreihen entgegen [9].

Trainiert wird mit Adam, MSE und Batchgröße 128 für 54 Epochen auf Training plus Validierung. Die Daten für Schwellenbestimmung und Test werden dabei nicht zum Trainieren verwendet.

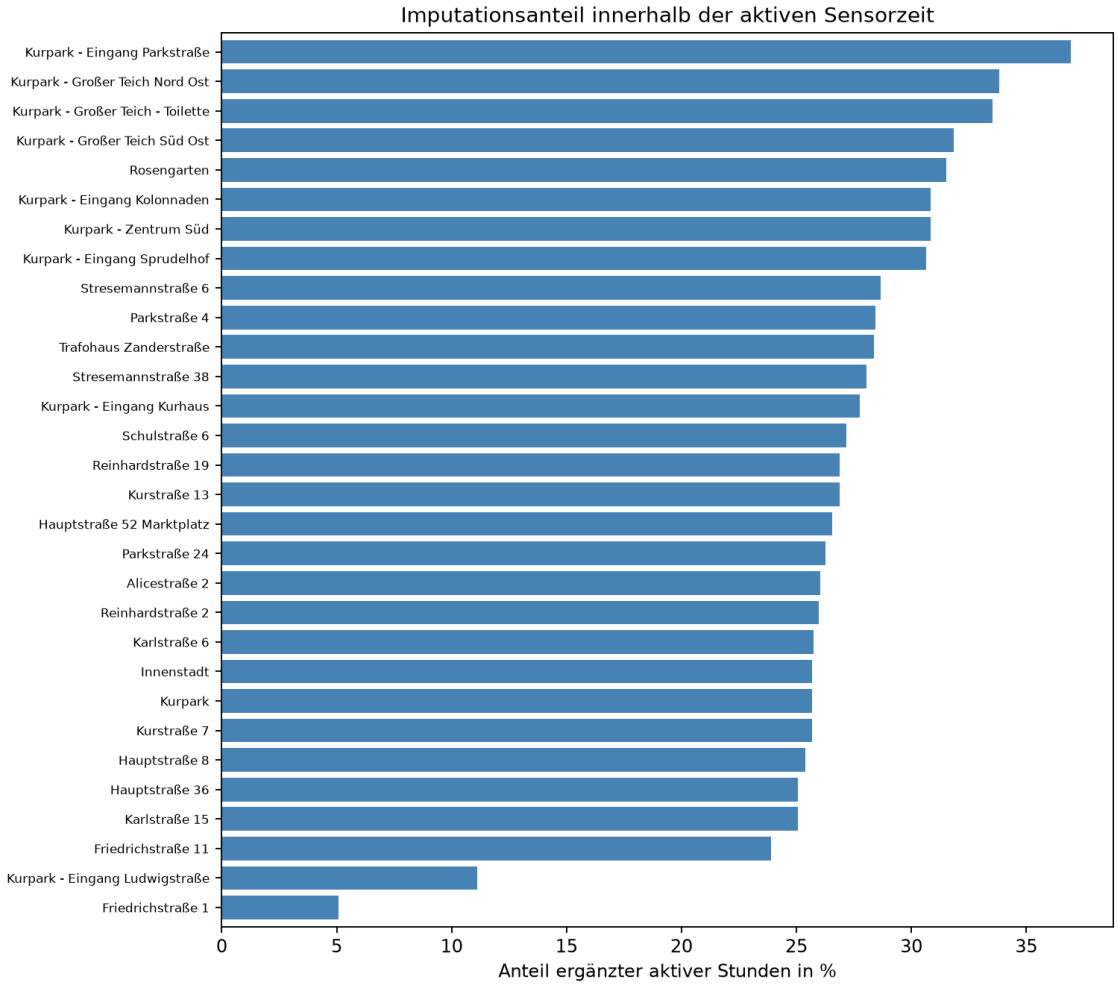


Abbildung 4.5: Anteil ergänzter Stunden innerhalb der aktiven Zeit jedes Sensors. Eigene Darstellung.

4.6.3 Anomaliewert aus dem Prognosefehler

Der absolute Prognosefehler jedes Merkmals wird durch seinen medianen absoluten Fehler im Kalibrierungsabschnitt geteilt:

$$r_{t,f} = \frac{|z_{t,f} - \hat{z}_{t,f}|}{\max\{\mathrm{Median}_{\mathrm{Kal}}(|z_f - \hat{z}_f|), 0{,}05\}}, \tag{4.4}$$

Die zwei Fehlerverteilungen sind unterschiedlich breit. Deshalb erhält jedes Merkmal eine eigene Grenze

$$\tau_f = Q^{\mathrm{Kal}}_{0,99}(r_f), \qquad s_t = \max_f \frac{r_{t,f}}{\tau_f}, \qquad A_t = \mathbf{1}(s_t > 1). \tag{4.5}$$

Ein Alarm entsteht, sobald `visitors` oder `avgDuration` seine eigene 99-%-Grenze überschreitet. Der Gesamtwert s_t hat für beide Messgrößen dieselbe Alarmgrenze eins. Die Grenze wird nur aus den vorhandenen Kalibrierungsfehlern geschätzt; eine feste spätere Fehlalarmrate ist dadurch nicht garantiert.

4.6.4 Umgang mit imputierten Zielwerten

Imputierte Werte dürfen als markierter Kontext in ein Zeitfenster eingehen, werden aber nicht als Ziel für Training, Modellauswahl, Kalibrierung oder Prognosekennzahlen verwendet. Eine fehlende Originalmessung wird unabhängig von

der Prognose als Datenqualitätsereignis ausgegeben. Dadurch wird ein aus einem Zeitprofil erzeugter Ersatzwert weder als reguläre Beobachtung noch als bestätigte Verhaltensanomalie fehlinterpretiert.

4.6.5 Vergleichsverfahren

Zur Einordnung werden drei einfache Verfahren ohne neuronales Netz verwendet: der Wert 24 Stunden zuvor, ein Sensor-Stundenmittel ausschließlich aus gemessenen Trainingswerten und der Median der vorhergehenden 24 Stunden. Alle vier Verfahren erhalten dieselben Testzeitpunkte. Damit zeigt der Vergleich, ob das LSTM gegenüber leicht erklärbaren Regeln einen Mehrwert liefert.

Kapitel 5

Evaluation der Methode

5.1 Zeitliche Datentrennung

Alle Teilmengen werden chronologisch statt zufällig gebildet. Imputierte Zielwerte werden in keiner Teilmenge als Lern- oder Bewertungsbeispiel gezählt. Tabelle 5.1 zeigt die Grenzen nach der Bildung der Zeitfenster.

Tabelle 5.1: Chronologische Teilmengen des Prognosemodells; Grenzen in UTC.

Teilmenge	Beginn	Ende (exklusiv)	gemessene Ziele
Training	erster Zielwert	08.07.2025	4.083
Validierung	08.07.2025	09.07.2025	318
Kalibrierung	09.07.2025	10.07.2025	368
Test	10.07.2025	Reihenende	1.346

Skalierungswerte und Modellparameter verwenden nur Training beziehungsweise Training plus Validierung. Der Kalibrierungsabschnitt dient ausschließlich zur Bestimmung der Alarmgrenzen. Da der Testzeitraum in früheren Entwicklungsschritten bereits betrachtet wurde, dient er als zeitlich abgetrennter Rückblickstest und nicht als völlig unangetasteter Zukunftstest.

5.2 Vergleich mit dem Basismodell

Als Basismodell wird der erste einfache LSTM-Aufbau des Projekts bezeichnet:

$$\mathrm{Input}(24, 2) \to \mathrm{LSTM}(64) \to \mathrm{Dense}(2).$$

Sein damaliger Trainingslauf ist nicht unmittelbar mit dem aktuellen Stand vergleichbar. Die erste Fensterbildung arbeitete auf 17.578 Rohzeilen und erzeugte im Test 3.406 Ausgaben für nur 1.346 unterschiedliche Sensorstunden, weil Mehrfachmessungen noch nicht zusammengefasst waren. Modell, Skalierungswerte und Schwellen wurden außerdem nicht gemeinsam gespeichert.

Für den fairen Vergleich wird deshalb der Aufbau des Basismodells auf die heutige korrigierte Datenaufbereitung übertragen. Beide Netze erhalten dieselben zusammenhängenden 24-Stunden-Fenster, Zielwerte, Zeitgrenzen, $\log(1+x)$-Standardisierung, den Zufallsstartwert 42, Batchgröße 128 und 54 Epochen. Das Basismodell sieht die beiden Messwerte; das aktuelle LSTM erhält zusätzlich die Beobachtungsmaske. Jedes Netz bestimmt aus demselben Abschnitt eine eigene 99-%-Alarmgrenze für jede Messgröße.

Damit werden die beiden vollständigen Modelle verglichen. Der Versuch zeigt nicht, welchen Anteil eine einzelne Schicht am Unterschied hat.

5.3 Kennzahlen für Prognose und Modellgröße

Für beide LSTM-Modelle sowie $t-24$, Sensor-Stundenmittel und den Median der vorhergehenden 24 Stunden werden MAE, RMSE und MASE berechnet. Der MASE-Nenner ist der mittlere absolute Fehler einer saisonalen $t-24$-Prognose auf gemessenen Trainingszielen [5]:

$$\mathrm{MASE} = \frac{H^{-1}\sum_{h=1}^{H}|y_{T+h}-\hat{y}_{T+h}|}{(T-24)^{-1}\sum_{t=25}^{T}|y_t-y_{t-24}|}. \tag{5.1}$$

MAE und RMSE messen die durchschnittliche beziehungsweise quadratisch stärker gewichtete Abweichung. Beim MASE bedeutet ein Wert unter eins, dass das Verfahren besser als die saisonale Trainingsreferenz ist. Zusätzlich zeigt die Parameterzahl die Größe des Netzes.

5.4 Prüfung mit künstlichen Anomalien

Vollständige reale Kennzeichnungen liegen nicht vor. Deshalb werden bekannte Messwerte gezielt verändert; diese künstlichen Anomalien ersetzen aber keine fachliche Prüfung [6, 3]. Untersucht werden kurze Ausschläge nach oben und unten (Spikes und Dips), sprunghafte Niveauänderungen (Level-Shifts), schleichende Verschiebungen (Drifts) und festgefrorene Werte (Stuck-at). Die Ereignisse werden unabhängig vom Modell aus zusammenhängenden gemessenen Abschnitten gewählt. Drei festgelegte Zufallsstartwerte sorgen bei beiden Modellen für dieselbe Auswahl.

Der direkte Modellvergleich verwendet die starken künstlichen Veränderungen mit Stärke 2,0; für Stuck-at gibt es nur eine Variante. Jede veränderte Reihe wird mit derselben unveränderten Reihe verglichen, damit bereits vorhandene Alarme nicht als Treffer zählen. Precision bezeichnet den Anteil richtiger Alarme, Recall den Anteil erkannter Anomalien und F1 fasst beide Werte zusammen. Die PR-AUC bewertet die Trennung über verschiedene Alarmgrenzen. Zusätzlich wird angegeben, bei wie vielen zusammenhängenden Ereignissen mindestens eine Stunde erkannt wurde. Weitere Stärken sowie ROC-AUC und die zeitliche Überlappung werden nur in den ausführlichen Ergebnisdateien geführt.

5.5 Evaluation der Imputation

Da die wahren Werte realer Lücken unbekannt sind, werden ursprünglich gemessene interne Trainingssegmente von einer, zwei, vier und acht Stunden künstlich entfernt. Vor und nach jeder Testlücke bleibt eine echte Messung erhalten. Dieselbe Datenaufbereitung rekonstruiert die verdeckten Werte. Drei Wiederholungen mit festgelegter Zufallsauswahl und jeweils zwölf Ereignissen je Länge ergeben 540 verdeckte Sensorstunden. Berichtet werden MAE und RMSE gegen die gesicherten Originalwerte.

5.6 Rauschrobustheit und reale Fallprüfung

Auf die skalierten Eingabewerte wird zufälliges Rauschen mit Normalverteilung und Standardabweichung 0,1 beziehungsweise 0,25 gegeben. Der resultierende MAE wird mit dem Grundlauf verglichen. Die elf Ereignisse eines früheren Prognoselaufs bleiben als manuelle Fallstudie erhalten. Sieben wurden als plausibel normal, eines als extern gestütztes Rosengarten-Ereignis und drei als offen eingeordnet. Da diese Stunden durch ein früheres Verfahren vorausgewählt wurden, ersetzen sie keine vollständige Prüfung aller Teststunden.

5.7 Reproduzierbarkeit

Die vollständige Auswertung wird in der Projektumgebung `.venv` in dieser Reihenfolge ausgeführt: Datenaufbereitung, Imputationsprüfung, Training, Auswertung und Prüfung mit künstlichen Anomalien. Für den Modellvergleich wird das

oben beschriebene Basismodell einmal unter denselben Bedingungen wie das aktuelle LSTM trainiert. Ergebnisse aus zwischenzeitlichen Suchläufen werden nicht berichtet.

Kapitel 6

Ergebnisse

6.1 Vergleich der beiden LSTM-Modelle

Tabelle 6.1 zeigt den in Kapitel 5 beschriebenen Vergleich. F1, PR-AUC und Ereignis-Recall werden zunächst für jede der fünf Anomaliearten getrennt berechnet und anschließend gleich gewichtet gemittelt.

Tabelle 6.1: Größe und Anomalieerkennung der beiden LSTM-Modelle. R = Recall. Eigene Darstellung.

Modell	Parameter	F1	PR-AUC	Ereignis-R
Basismodell	17.282	0,401	0,594	0,466
Aktuelles LSTM	5.170	0,491	0,657	0,599

Das aktuelle LSTM benötigt 70,1 % weniger Parameter und erreicht bei allen drei Kennzahlen zur Anomalieerkennung bessere Werte. Sein F1 steigt gegenüber dem Basismodell relativ um 22,4 %. Ob dieser Vorteil auch bei realen Anomalien besteht, lässt sich ohne vollständige reale Kennzeichnungen noch nicht feststellen.

6.2 Prognosegüte und einfache Referenzen

Tabelle 6.2 vergleicht beide Netze mit drei einfachen statistischen Regeln.

Tabelle 6.2: Prognosegüte auf 1.346 gemessenen Testzielen. V = Visitors, D = AvgDuration. Eigene Darstellung.

Verfahren	MAE V	RMSE V	MASE V	MAE D	RMSE D	MASE D
Basismodell	11,807	21,918	0,635	4,033	7,601	0,852
Aktuelles LSTM	12,691	24,103	0,682	4,031	7,384	0,851
Wert bei $t-24$	16,260	35,016	0,874	5,022	8,640	1,061
Stundenmittel	13,674	29,415	0,735	3,833	6,701	0,809
24-h-Median	35,184	62,133	1,891	4,629	7,501	0,978

Beide LSTM-Varianten schlagen $t-24$ und den gleitenden Median bei beiden Zielgrößen. Das Stundenmittel ist bei der Verweildauer sogar genauer als beide Netze. Eine gute Vorhersage allein entscheidet deshalb nicht über die Güte der Anomalieerkennung; hierfür sind die Tests mit bekannten künstlichen Veränderungen maßgeblich.

6.3 Kandidaten im unveränderten Datensatz

Das aktuelle LSTM markiert 101 der 1.346 gemessenen Testpunkte. Daraus entstehen 91 zusammenhängende Ereignisse. 62 Punkte überschreiten die Besuchergrenze und 61 die Grenze der Verweildauer; an einigen Stunden lösen beide Merk-

male aus. Die 101 Punkte entsprechen 7,5 % des kurzen Testabschnitts. Sie sind ohne vollständige manuelle Prüfung ausschließlich statistische Kandidaten und nicht 101 bestätigte reale Anomalien.

Abbildung 6.1 zeigt den Sensor mit den meisten Kandidaten. Zusätzlich besitzen 1.333 Testziele keine Originalmessung. Diese werden zu 275 Datenlücken-Ereignissen gruppiert und separat ausgewiesen.

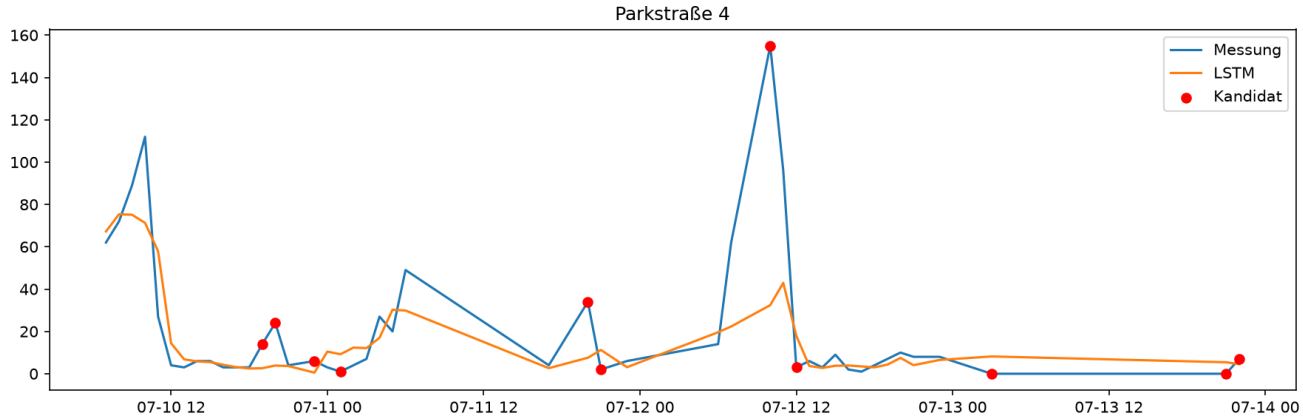


Abbildung 6.1: Messung, LSTM-Prognose und markierte Kandidaten eines Beispielsensors. Rot bedeutet eine statistische Abweichung und keine fachlich bestätigte Anomalie. Eigene Darstellung.

6.4 Ergebnisse der starken Testinjektionen

Tabelle 6.3 schlüsselt das aktuelle LSTM nach Anomalieart auf. Bewertet werden nur zusätzliche Alarme gegenüber dem unveränderten Gegenlauf.

Tabelle 6.3: Aktuelles LSTM bei starken künstlichen Anomalien, gemittelt über drei Wiederholungen. Eigene Darstellung.

Typ	Precision	Recall	F1	PR-AUC	Ereignis-R
Spike	0,719	0,683	0,701	0,804	0,683
Dip	0,885	0,550	0,674	0,806	0,550
Level-Shift	0,725	0,451	0,556	0,673	0,917
Drift	0,565	0,188	0,281	0,504	0,556
Stuck-at	0,869	0,148	0,246	0,496	0,292

Spikes und Dips werden am zuverlässigsten erkannt. Bei Level-Shifts reicht mindestens ein Treffer für 91,7 % der Ereignisse, obwohl nicht jede Stunde eines Ereignisses markiert wird. Langsame Drifts und konstante Stuck-at-Phasen bleiben die deutlichsten Schwächen.

6.5 Imputations- und Rauschprüfung

Beim künstlichen Entfernen bekannter Messwerte steigt der Besucherfehler mit der Lückenlänge, wie Tabelle 6.4 zeigt. Die Werte je Länge fassen die tatsächlich verwendeten Rückfallstufen der Datenaufbereitung zusammen.

Zusätzlich erhöht Rauschen mit Standardabweichung 0,1 den MAE um 0,08 % bei Visitors und 0,48 % bei AvgDuration. Bei 0,25 betragen die Zunahmen 8,82 % und 1,55 %. Das Modell reagiert damit auf mäßiges Eingaberauschen vergleichsweise stabil; die Imputation langer Besucherlücken bleibt jedoch unsicher.

Tabelle 6.4: Imputation auf künstlich verdeckten Trainingswerten. Eigene Darstellung.

Länge	Punkte	MAE V	RMSE V	MAE D	RMSE D
1 h	36	11,194	16,832	4,342	6,040
2 h	72	18,944	32,458	4,709	6,735
4 h	144	18,201	36,089	3,164	4,606
8 h	288	20,955	32,081	3,759	7,145
Gesamt	540	19,302	32,490	3,766	6,426

6.6 Manuelle Fallprüfung und Limitationen

Von den elf Ereignissen des früheren Prognoselaufs wurden sieben als plausibel normal, drei als offen und eines als extern gestütztes Ereignis eingeordnet. Das gestützte Ereignis umfasst am Rosengarten vier Stunden im Umfeld einer Veranstaltung. Das aktuelle LSTM überschreitet seine Alarmgrenze in diesen vier Stunden nicht; um 19:00 Uhr liegt der Anomaliewert mit 0,983 nur knapp unter eins. Die manuelle Prüfung zeigt damit eine bekannte Anomalie, die das Modell übersieht. Die Ergebnisse der künstlichen Tests dürfen deshalb nicht zu stark verallgemeinert werden.

Die Daten decken nur zwei Wochen ab, die 91 aktuellen Kandidaten sind noch nicht vollständig geprüft und der Testabschnitt wurde während der Entwicklung bereits betrachtet. Die besseren Ergebnisse bei künstlichen Veränderungen garantieren daher nicht, dass unbekannte reale Anomalien erkannt werden.

Kapitel 7

Zusammenfassung und Ausblick

Die Datenaufbereitung fasst Mehrfachmessungen zusammen, behandelt einen stadtweiten Nullmelde-Ausfall als fehlend und ergänzt interne Lücken, ohne Validierungs- oder Testwerte zur Profilbildung zu verwenden. Ergänzte Werte dürfen als gekennzeichneter Eingang in das LSTM eingehen, werden aber nicht als Ziel beim Training oder bei der Bewertung verwendet. Das künstliche Entfernen von 540 bekannten Messwerten zeigt, wie unsicher diese Ergänzung besonders bei längeren Lücken bleibt.

Im direkten Vergleich erkennt das aktuelle LSTM die geprüften künstlichen Anomalien besser als das Basismodell. Bei der normalen Besucherprognose ist das Basismodell dagegen etwas genauer. Das aktuelle LSTM ist somit für die untersuchten Anomalien geeigneter, aber noch kein zuverlässig geprüftes Verfahren für reale Ereignisse.

Auf dem unveränderten Testabschnitt entstehen 91 noch nicht vollständig geprüfte Ereignisse. Außerdem übersieht das aktuelle LSTM die vier bekannten Stunden des Rosengarten-Ereignisses. Die künstlichen Tests sind deshalb nur ein erster Leistungsnachweis und ersetzen keine vollständige manuelle Prüfung.

Als nächster Schritt soll ein einfacher Autoencoder als eigenständiges zweites Modell trainiert und getrennt mit dem LSTM verglichen werden. Danach haben vollständige reale Kennzeichnungen, bestätigte Sensorlaufzeiten und längere Zeitreihen Vorrang. Erst mit deutlich mehr Daten ist ein Vergleich mit einem Transformer sinnvoll.

Anhang A

Programmcode

Literatur

[1] Zhengping Che u. a. "Recurrent Neural Networks for Multivariate Time Series with Missing Values". In: *Scientific Reports* 8 (2018), S. 6085. DOI: 10.1038/s41598-018-24271-9.

[2] Hao Cheng u. a. "RobustTSF: Towards Theory and Design of Robust Time Series Forecasting with Anomalies". In: *The Twelfth International Conference on Learning Representations*. 2024. URL: https://openreview.net/forum?id=ltZ9ianMth.

[3] Mononito Goswami u. a. "Unsupervised Model Selection for Time Series Anomaly Detection". In: *The Eleventh International Conference on Learning Representations*. 2023. URL: https://openreview.net/forum?id=gOZ_pKANaPW.

[4] Sepp Hochreiter und Jürgen Schmidhuber. "Long Short-Term Memory". In: *Neural Computation* 9.8 (1997), S. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.

[5] Rob J. Hyndman und Anne B. Koehler. "Another Look at Measures of Forecast Accuracy". In: *International Journal of Forecasting* 22.4 (2006), S. 679–688. DOI: 10.1016/j.ijforecast.2006.03.001.

[6] Sebastian Schmidl, Phillip Wenig und Thorsten Papenbrock. "Anomaly Detection in Time Series: A Comprehensive Evaluation". In: *Proceedings of the VLDB Endowment* 15.9 (2022), S. 1779–1797. DOI: 10.14778/3538598.3538602.

[7] Muhammad Awais Shafique. "Imputing Missing Data in Hourly Traffic Counts". In: *Sensors* 22.24 (2022), S. 9876. DOI: 10.3390/s22249876.

[8] Li Shen u. a. "AFMF: Time Series Anomaly Detection Framework with Modified Forecasting". In: *Knowledge-Based Systems* 296 (2024), S. 111912. DOI: 10.1016/j.knosys.2024.111912.

[9] Nitish Srivastava u. a. "Dropout: A Simple Way to Prevent Neural Networks from Overfitting". In: *Journal of Machine Learning Research* 15.56 (2014), S. 1929–1958. URL: https://www.jmlr.org/papers/v15/srivastava14a.html.

[10] Tuo Sun u. a. "Traffic Missing Data Imputation: A Selective Overview of Temporal Theories and Algorithms". In: *Mathematics* 10.14 (2022), S. 2544. DOI: 10.3390/math10142544.

[11] Zheng Xu u. a. "DCFF-MTAD: A Multivariate Time-Series Anomaly Detection Model Based on Dual-Channel Feature Fusion". In: *Sensors* 23.8 (2023), S. 3910. DOI: 10.3390/s23083910.

[12] Yimei Zhang u. a. "A Comprehensive Survey on Traffic Missing Data Imputation". In: *IEEE Transactions on Intelligent Transportation Systems* 25.12 (2024), S. 19252–19275. DOI: 10.1109/TITS.2024.3478816.

[13] Hang Zhao u. a. "Multivariate Time-Series Anomaly Detection via Graph Attention Network". In: *2020 IEEE International Conference on Data Mining (ICDM)*. IEEE, 2020, S. 841–850. DOI: 10.1109/ICDM50108.2020.00093.

[14] Xiaona Zhou, Constantin Brif und Ismini Lourentzou. "mTSBench: Benchmarking Multivariate Time Series Anomaly Detection and Model Selection at Scale". In: *Transactions on Machine Learning Research* (2026). URL: https://openreview.net/forum?id=8LfB8HD1WU.