

Frankfurt University
of Applied Sciences

– Fachbereich 2: Informatik und Ingenieurwissenschaften –

Deep-Learning-basierte Anomalieerkennung in Passantenfrequenzen

Projektarbeit im Rahmen des Bachelorstudiums

Bachelor of Science (B.Sc.)

vorgelegt am 19. Juli 2026 von

Sherwin Nourinfar, Wassim Hanane

Matrikelnummer: 1552887, 1583937

Referent	:	Daniel Helmer
Korreferent	:	–

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich die vorliegende Arbeit selbständig verfasst und keine anderen als die im Literaturverzeichnis angegebenen Quellen benutzt habe.

Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder noch nicht veröffentlichten Quellen entnommen sind, sind als solche kenntlich gemacht.

Die Zeichnungen oder Abbildungen in dieser Arbeit sind von mir selbst erstellt worden oder mit einem entsprechenden Quellennachweis versehen.

Diese Arbeit ist in gleicher oder ähnlicher Form noch bei keiner anderen Prüfungsbehörde eingereicht worden.

Frankfurt, 19. Juli 2026



Sherwin Nourinfar, Wassim Hanane

Inhaltsverzeichnis

1 Einführung **2**

1.1 Motivation . . . 2

1.2 Zielsetzung . . . 2

1.3 Aufbau der Arbeit . . . 2

2 Hintergrund **3**

3 Zielstellung **4**

3.1 Forschungsfrage . . . 4

3.2 Szenarien . . . 4

4 Entwickelte Methode **5**

4.1 Datengrundlage . . . 5

4.2 Datenqualität . . . 5

4.3 Bereinigung der Mehrfachmessungen . . . 5

4.4 Behandlung der Messlücken . . . 6

4.5 Kritische Betrachtung . . . 7

4.6 Forecast-basierter Anomaliedetektor . . . 7

4.6.1 Lernaufgabe und Eingaberepräsentation . . . 8

4.6.2 Modellarchitektur und Training . . . 9

4.6.3 Nichtkonformitätsscore und Intervallkalibrierung . . . 9

4.6.4 Kausale Hybridregel . . . 10

4.6.5 Umgang mit imputierten Zielwerten . . . 10

5 Evaluation der Methode **12**

5.1 Zeitliche Datentrennung . . . 12

5.2 Bewertung der Prognosegüte . . . 12

5.3 Synthetische Anomalieinjektion . . . 13

5.4 Punkt- und Ereignismetriken . . . 13

5.5 Reproduzierbarkeit . . . 13

6 Ergebnisse **14**

6.1 Modellauswahl und Detektorkalibrierung 14
6.2 Prognosegüte im Testabschnitt 15
6.3 Kandidaten im unveränderten Datensatz 15
6.4 Ergebnisse der Anomalieinjektion 16
6.5 Diskussion und Limitationen 16

7 Zusammenfassung und Ausblick **17**

A Programmcode **18**

Literatur **21**

Kurzfassung

Kapitel 1

Einführung

Wie viele Menschen zu einer bestimmten Zeit an einem Ort unterwegs sind, folgt meist einem klaren Rhythmus. Tagsüber sind es mehr als nachts, und unter der Woche andere Zahlen als am Wochenende. Auch der Ort spielt eine Rolle, denn an einem belebten Platz ist mehr los als in einer ruhigen Seitenstraße. Wenn man dieses regelmäßige Verhalten kennt, fallen Abweichungen davon auf. Eine solche Abweichung vom gewohnten Muster nennt man Anomalie.

Grundlage dieser Arbeit ist ein realer Datensatz der Stadt Bad Nauheim. An 30 Standorten wurde vom 30. Juni bis zum 13. Juli 2025 stündlich gezählt, wie viele Passanten unterwegs waren. Für jeden Sensor entsteht so eine eigene Zeitreihe über zwei Wochen.

1.1 Motivation

Mit diesem Projekt wollen wir herausfinden, ob sich solche Anomalien mit Methoden des Deep Learnings zuverlässig erkennen lassen und welche Modellart sich dafür am besten eignet. Die Schwierigkeit dabei ist, dass die Daten nicht beschriftet sind. Es ist nirgends vermerkt, welche Stunde normal war und welche nicht. Ein Modell muss das normale Verhalten also selbst aus den Daten lernen und melden, wenn die Realität davon abweicht. Feste Schwellenwerte helfen hier kaum, weil sich das Normalverhalten je nach Tageszeit, Wochentag und Standort verändert.

1.2 Zielsetzung

Das Ziel ist ein System, das für jeden Sensor das normale Passantenaufkommen lernt und auffällige Stunden meldet. Dafür setzen wir mehrere Deep-Learning-Architekturen um, darunter LSTM/GRU, Autoencoder und Transformer, und vergleichen sie anhand nachvollziehbarer Kennzahlen. So können wir begründen, welcher Ansatz für diese Art von Daten am besten funktioniert.

1.3 Aufbau der Arbeit

Kapitel 2 erklärt die nötigen Grundlagen zu Zeitreihen, neuronalen Netzen und den verwendeten Architekturen. Anschließend ordnet der Stand der Technik die Arbeit in bestehende Verfahren ein. Danach folgen die entwickelte Methode mit Datenaufbereitung und Training, die Evaluation der Modelle und die Ergebnisse. Den Abschluss bildet eine Zusammenfassung mit Ausblick.

Kapitel 2

Hintergrund

Kapitel 3

Zielstellung

3.1 Forschungsfrage

3.2 Szenarien

Kapitel 4

Entwickelte Methode

Dieses Kapitel beschreibt zunächst die reproduzierbare Aufbereitung der Rohdaten und anschließend den entwickelten forecast-basierten Anomaliedetektor. Methodische Entscheidungen werden von den später berichteten Ergebnissen getrennt dargestellt.

4.1 Datengrundlage

Die Rohdaten liegen in Form einer JSON-Datei mit 17.578 Einzelmessungen vor. Jede Messung gehört zu einem von 30 Sensorstandorten in der Innenstadt und im Kurpark von Bad Nauheim und enthält neben dem Zeitstempel die Anzahl der erfassten Passanten (`visitors`) sowie deren mittlere Verweildauer (`avgDuration`). Der globale Erfassungszeitraum reicht vom 30. Juni bis zum 13. Juli 2025 und umfasst 335 Stunden. Da nicht alle Sensoren während des gesamten Zeitraums aktiv waren, wird jede Reihe nur zwischen ihrer ersten und letzten Messung betrachtet. Dadurch entstehen 9.460 aktive Sensorstunden; weitere 590 Kombinationen des globalen Rasters liegen außerhalb der jeweiligen Sensorlaufzeit und werden nicht als Messlücke behandelt.

4.2 Datenqualität

Bei der Sichtung der Rohdaten sind zwei Probleme aufgefallen, die vor dem Training behandelt werden müssen.

Mehrfachmessungen: Für 4.770 Kombinationen aus Sensor und Stunde enthält der Datensatz mehrere Einträge, in der Spitze zehn Messungen für dieselbe Stunde (Abbildung 4.1). Die Werte dieser Einträge weichen teilweise voneinander ab, es handelt sich also nicht um exakte Kopien. Ohne Bereinigung gingen diese Stunden mehrfach und mit widersprüchlichen Werten in das Training ein.

Messlücken: Nach der Zusammenfassung der Mehrfachmessungen liegen 6.842 gemessene Sensorstunden vor. Innerhalb der 9.460 aktiven Sensorstunden fehlen damit 2.618 Werte, entsprechend 27,7 %. Sie bilden 830 zusammenhängende Lücken. Davon umfassen 641 höchstens zwei Stunden; die längste Lücke innerhalb einer aktiven Sensorperiode dauert 18 Stunden (Abbildung 4.2). In 62 Stunden liegt von keinem der zu diesem Zeitpunkt aktiven Sensoren eine Messung vor. Dies deutet auf gemeinsame Ausfälle der Übertragungsinfrastruktur hin. Die Sensoren Kurpark–Eingang Ludwigstraße und Friedrichstraße 1 besitzen mit 36 beziehungsweise 59 Stunden lediglich kurze aktive Erfassungszeiträume. Zeiten nach ihrem letzten Messwert werden nicht künstlich ergänzt.

4.3 Bereinigung der Mehrfachmessungen

Alle Einträge derselben Kombination aus Sensor und Stunde werden zu einem Messpunkt zusammengefasst. Für die Passantenzahl und die Verweildauer wird jeweils der arithmetische Mittelwert gebildet. Dadurch verbleiben 6.842 ein-

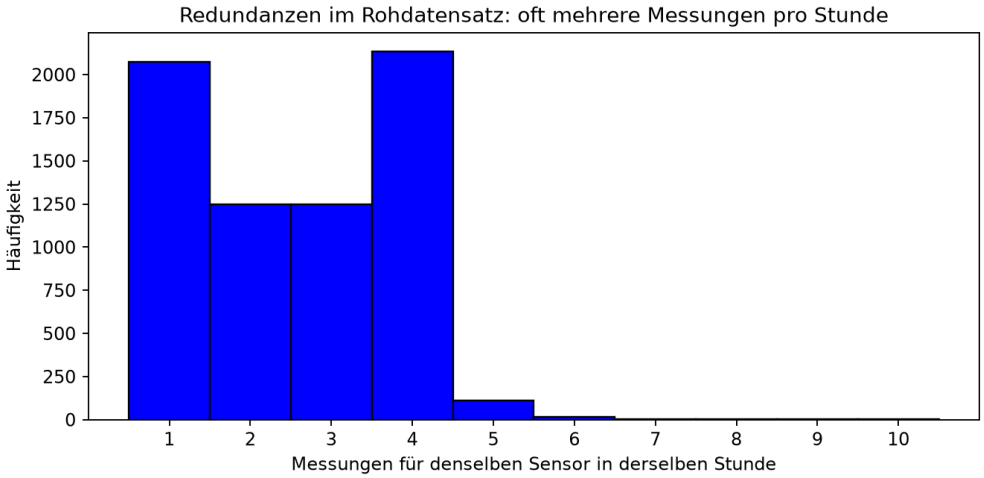


Abbildung 4.1: Häufigkeit von Mehrfachmessungen im Rohdatensatz. Für viele Stunden liegen zwei bis vier, vereinzelt bis zu zehn Einträge desselben Sensors vor.

deutige gemessene Sensorstunden. Nach Abschluss der Imputation wird die Passantenzahl auf ganze Personen und die Verweildauer auf zwei Dezimalstellen gerundet.

4.4 Behandlung der Messlücken

Die für das Training verwendeten Zeitfenster setzen zusammenhängende Stundenreihen voraus. Eine Lücke innerhalb eines Fensters würde andernfalls unbemerkt Werte aus weit auseinanderliegenden Zeiträumen kombinieren. Die Lücken werden deshalb vor dem Training aufgefüllt, und zwar für jeden Sensor getrennt, damit jeder Standort sein individuelles Niveau und Tagesprofil behält. Die zentrale Pipeline verwendet keine lineare Interpolation. Sämtliche Profile werden ausschließlich aus ursprünglich gemessenen Werten vor dem 8. Juli 2025, 00:00 Uhr UTC, geschätzt; Validierungs-, Kalibrierungs- und Testwerte gehen damit nicht in die Profilbildung ein. Wochentag und Stunde werden in der lokalen Zeitzone `Europe/Berlin` bestimmt. Das Verfahren arbeitet in vier aufeinanderfolgenden Stufen.

Stufe 1, vergangenheitsbasierte Fortschreibung: Für die ersten zwei Stunden jeder Lücke wird der letzte zuvor gemessene Wert desselben Sensors übernommen. Mit t^- als Zeitpunkt der letzten Messung gilt

$$\hat{x}_t = x_{t^-}, \qquad 0 < t - t^- \leq 2 \text{ Stunden}. \tag{4.1}$$

Diese Regel gilt auch für die ersten beiden Positionen einer längeren Lücke. Sie benötigt keinen nachfolgenden Messwert und verhindert dadurch, dass ein späteres Prognoseziel in einen früheren Modellkontext zurückgespiegelt wird. Der Preis ist eine kurzfristig konstante Fortsetzung; die Regel stellt daher einen transparenten Kompromiss und kein allgemein optimales Imputationsverfahren dar. Auf diese Weise werden 1.175 Sensorstunden ergänzt.

Stufe 2, Wochentag-Stunden-Profil: Für die verbleibenden Lücken wird der Mittelwert desselben Sensors am gleichen lokalen Wochentag und zur gleichen lokalen Stunde aus gemessenen Trainingswerten eingesetzt. Historische Zeitprofile erhalten tages- und wochenzeitabhängige Strukturen und werden auch für fehlende Verkehrszähldaten untersucht [11]. Diese Stufe füllt 1.298 Sensorstunden.

Stufe 3, Stundenprofil: Existiert für eine Kombination aus Wochentag und Stunde keine Trainingsreferenz, wird der Mittelwert des Sensors zur gleichen lokalen Uhrzeit über alle Trainingstage verwendet. Dies betrifft 140 Sensorstunden.

Stufe 4, Sensormittel: Fehlt auch für die betreffende Uhrzeit eine Referenz, wird der Mittelwert sämtlicher gemessener Trainingswerte dieses Sensors eingesetzt. Diese Rückfallstufe betrifft fünf Sensorstunden. Damit werden alle 2.618 Lücken innerhalb der aktiven Sensorperioden geschlossen; Zeiten vor der ersten und nach der letzten Messung eines Sensors bleiben außerhalb des Datensatzes.

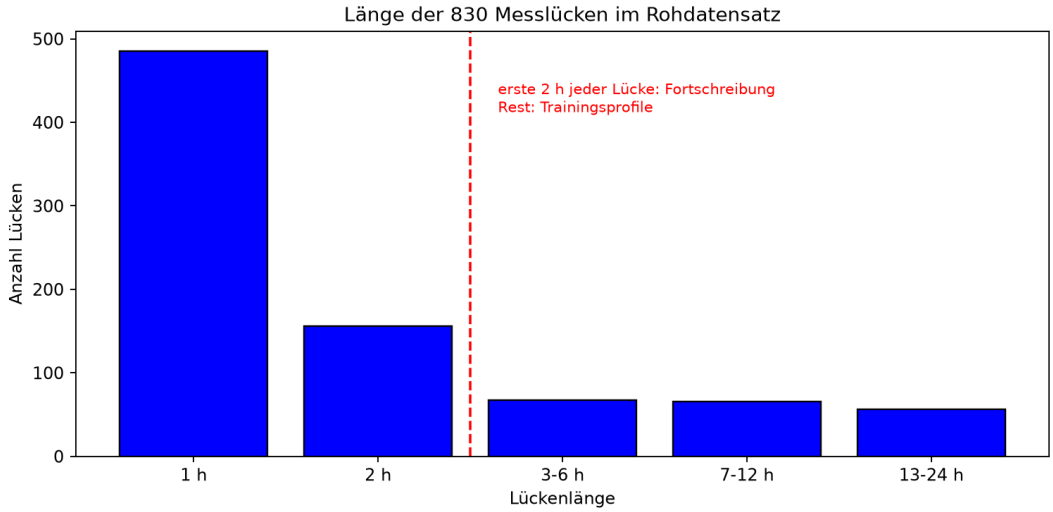


Abbildung 4.2: Längenverteilung der 830 Messlücken innerhalb der aktiven Sensorperioden. 641 Lücken umfassen höchstens zwei Stunden.

Der untere Teil von Abbildung 4.3 kennzeichnet die ergänzten Stunden. Abbildung 4.4 stellt eine typische Reihe und den Sensor mit der kürzesten aktiven Erfassungszeit gegenüber. Sie zeigt zugleich, dass die Reihe nach dem Ende des Sensors nicht künstlich fortgeschrieben wird. Abbildung 4.5 fasst den ergänzten Anteil innerhalb der aktiven Zeit jedes Sensors zusammen.

4.5 Kritische Betrachtung der Bereinigung

Jede Imputation verändert die Daten. Mittelwertbasierte Verfahren können den Verlauf glätten und die Varianz verringern [13, 10]. Im vorliegenden Datensatz ändert sich der Mittelwert der Passantenzahl je Sensor um höchstens 9,92 %. Die kleinste Korrelation zwischen dem ausschließlich aus gemessenen Werten und dem aus allen bereinigten Werten gebildeten stündlichen Tagesprofil beträgt 0,9838. Diese Kennzahlen prüfen Niveau und Profil, ersetzen aber keine Fehleranalyse gegen unbekannte wahre Werte in den Lücken.

Die zweistündige Fortschreibung verwendet zu jedem Zeitpunkt nur die Vergangenheit. Die statistischen Profile dürfen dagegen innerhalb des Trainingsabschnitts auch chronologisch spätere Trainingsmessungen enthalten. Die Aufbereitung ist damit für die Out-of-Sample-Auswertung frei von Validierungs- und Testdaten-Leakage, jedoch nicht als rein online-kausale Imputation jeder frühen Trainingslücke zu verstehen.

Ein zweiter Aspekt betrifft die Anomalieerkennung selbst. Ergänzte Stunden wirken per Konstruktion unauffällig, ein tatsächlicher Sensorausfall stellt jedoch selbst ein meldenswertes Ereignis dar. Das Fehlen von Werten folgt hier zudem eigenen, teils blockweisen Mustern und trägt damit selbst Information [13]. Das Feld `is_imputed` hält für jede Stunde fest, ob sie gemessen oder ergänzt wurde. Der Forecaster verwendet ergänzte Werte weiterhin als Kontext eines 24-Stunden-Fensters, überspringt jedoch Fenster mit einem ergänzten Zielwert beim Training, bei der Bestimmung des Schwellenwerts und bei der Testauswertung. Die beiden besonders kurzen Sensorreihen werden wegen ihrer geringen aktiven Länge nicht verwendet.

4.6 Forecast-basierter Anomaliedetektor

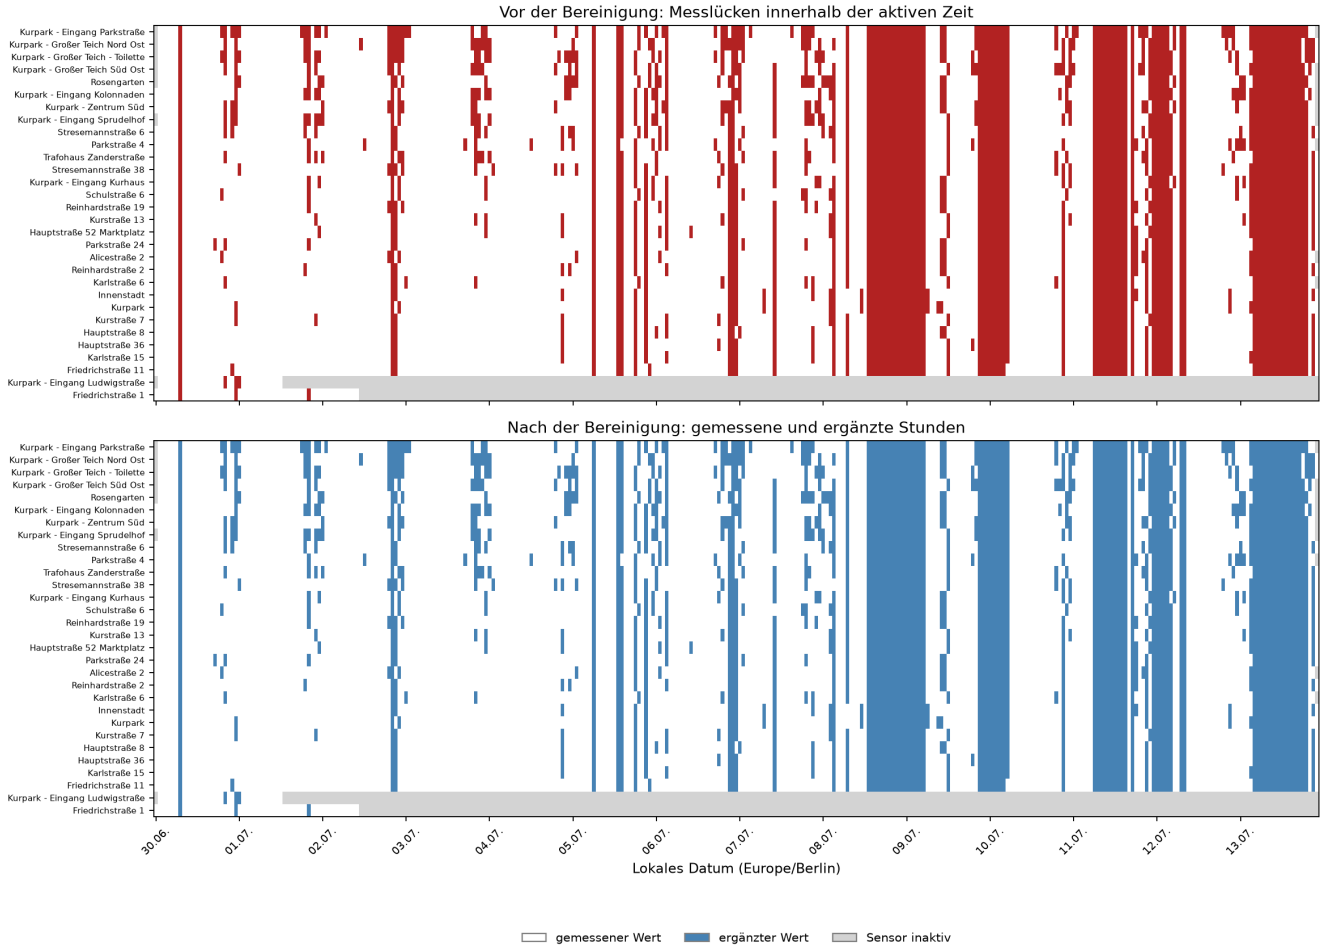


Abbildung 4.3: Messstatus vor der Bereinigung (oben) und danach (unten). Rot zeigt Lücken innerhalb der aktiven Sensorzeit, Blau ergänzte Werte und Grau Zeiträume, in denen der betreffende Sensor nicht aktiv war. Eigene Darstellung.

4.6.1 Lernaufgabe und Eingaberepräsentation

Der Forecaster lernt selbstüberwacht, aus den jeweils vorhergehenden 24 Stunden die nächste Stunde vorherzusagen. Die nachgelagerte Anomalieentscheidung ist unüberwacht, da weder das Modelltraining noch die Kalibrierung reale Anomalieklassen verwenden. Ein einziges globales Modell wird über 28 Sensoren trainiert. Zwei Sensoren werden ausgeschlossen, weil vor dem Ende des Trainingsabschnitts weniger als 72 gemessene Zielstunden vorliegen.

Beide Zielgrößen werden zunächst mit $\log(1+x)$ transformiert. Danach erfolgt eine robuste Skalierung je Sensor s und Merkmal f:

$$z_{s,t,f} = \frac{\log(1+x_{s,t,f}) - \mathrm{Median}_{s,f}}{\max(\mathrm{IQR}_{s,f}, 0{,}05)}. \tag{4.2}$$

Median und Interquartilsabstand werden ausschließlich aus gemessenen Trainingswerten bestimmt. Jedes historische Zeitfenster besitzt acht Kanäle: die beiden skalierten Messgrößen, eine Maske für gemessen beziehungsweise imputiert sowie Sinus und Kosinus von lokaler Stunde und Wochentag und einen Wochenendindikator. Die fünf Kalendermerkmale der Zielstunde und eine Sensor-ID werden dem Modell zusätzlich übergeben.

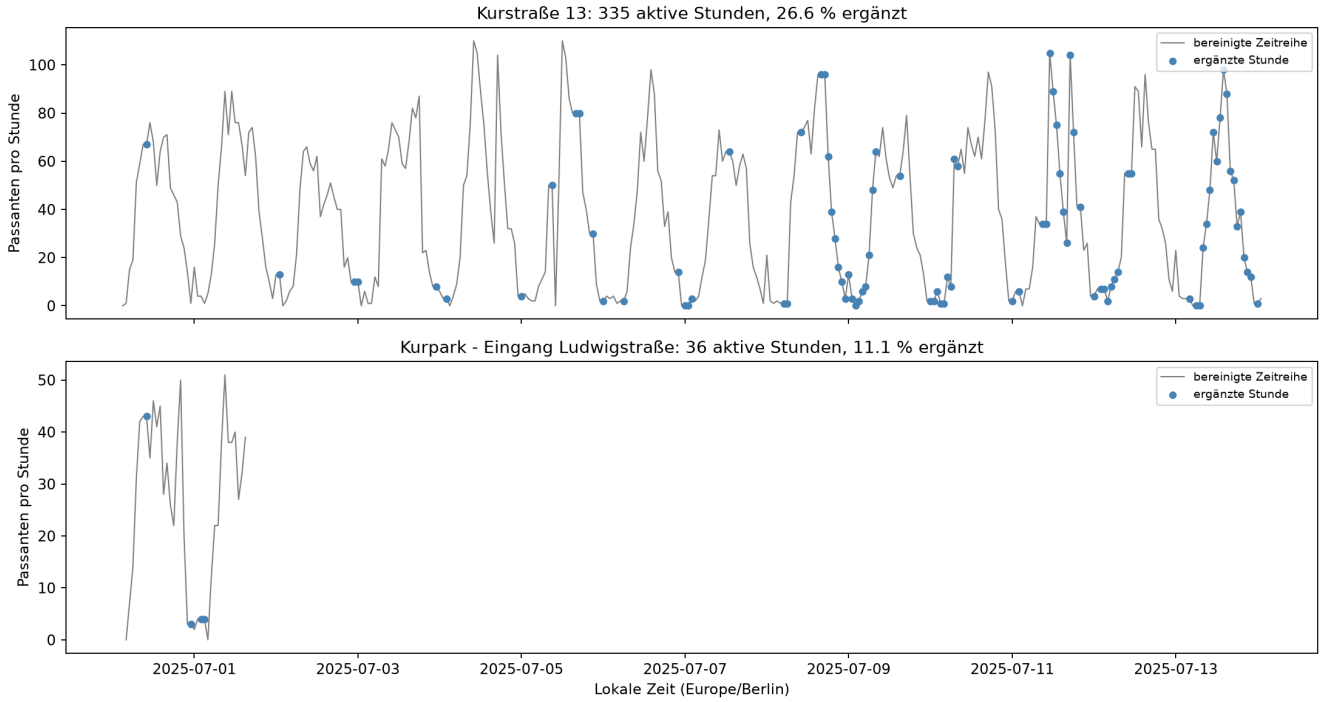


Abbildung 4.4: Bereinigte Zeitreihen eines typischen Sensors (oben) und des Sensors mit der kürzesten aktiven Erfassungszeit (unten). Markierte Punkte sind ergänzte Stunden. Eigene Darstellung.

4.6.2 Modellarchitektur und Training

Das LSTM verdichtet das 24-Stunden-Fenster in einen Zustandsvektor [3]. Dieser wird mit einem lernbaren Sensor-Embedding und den Kalendermerkmalen der Zielstunde verbunden und durch eine dichte Schicht geführt. Das globale Training und das Sensor-Embedding orientieren sich an probabilistischen globalen RNN-Forecastern [8]; aufgrund der Quantilausgabe handelt es sich jedoch nicht um eine DeepAR-Implementierung.

Das Ausgabefeld enthält für `visitors` und `avgDuration` jeweils die Quantile $q_{0,1}$, $q_{0,5}$ und $q_{0,9}$. Trainiert wird mit der über beide Zielgrößen und Quantile gemittelten Pinball-Loss-Funktion [6]. Zwei bewusst kleine Konfigurationen werden auf einem chronologisch nachgelagerten Tuningabschnitt verglichen. Early Stopping begrenzt die Epochenzahl. Anschließend wird die gewählte Konfiguration für die ermittelte Epochenzahl erneut auf Training und Tuning trainiert; Kalibrierungs- und Testdaten bleiben dabei unberührt. Das kleine Suchraster begrenzt angesichts des kurzen Tuningabschnitts das Risiko einer Selektionsüberanpassung [2].

4.6.3 Nichtkonformitätsscore und Intervallkalibrierung

Für Merkmal f wird die Abweichung einer Beobachtung $y_{t,f}$ vom vorhergesagten Quantilintervall relativ zu dessen Breite bewertet:

$$e_{t,f} = \frac{\max\{q_{0,1,t,f} - y_{t,f},\, y_{t,f} - q_{0,9,t,f}\}}{\max\{q_{0,9,t,f} - q_{0,1,t,f}, w_{\min,f}\}}, \qquad s_t = \max_f e_{t,f}. \tag{4.3}$$

Ein negativer Wert liegt innerhalb des ursprünglichen Quantilintervalls; ein positiver Wert misst die relative Überschreitung. Das Maximum s_t erzeugt eine gemeinsame Entscheidung für beide Zielgrößen. Aus 368 gemessenen Punkten des getrennten Kalibrierungsabschnitts wird bei nominal $\alpha = 0{,}01$ eine endliche empirische Quantilschwelle bestimmt. Das Verfahren ist an Conformalized Quantile Regression angelehnt [7], verwendet aber zusätzlich eine Breitenstandardisierung und ein Maximum über zwei Zielgrößen. Wegen der zeitlichen Abhängigkeit der Fenster wird keine verteilungsfreie 99-%-Garantie beansprucht [1]; die tatsächliche Testabdeckung wird berichtet.

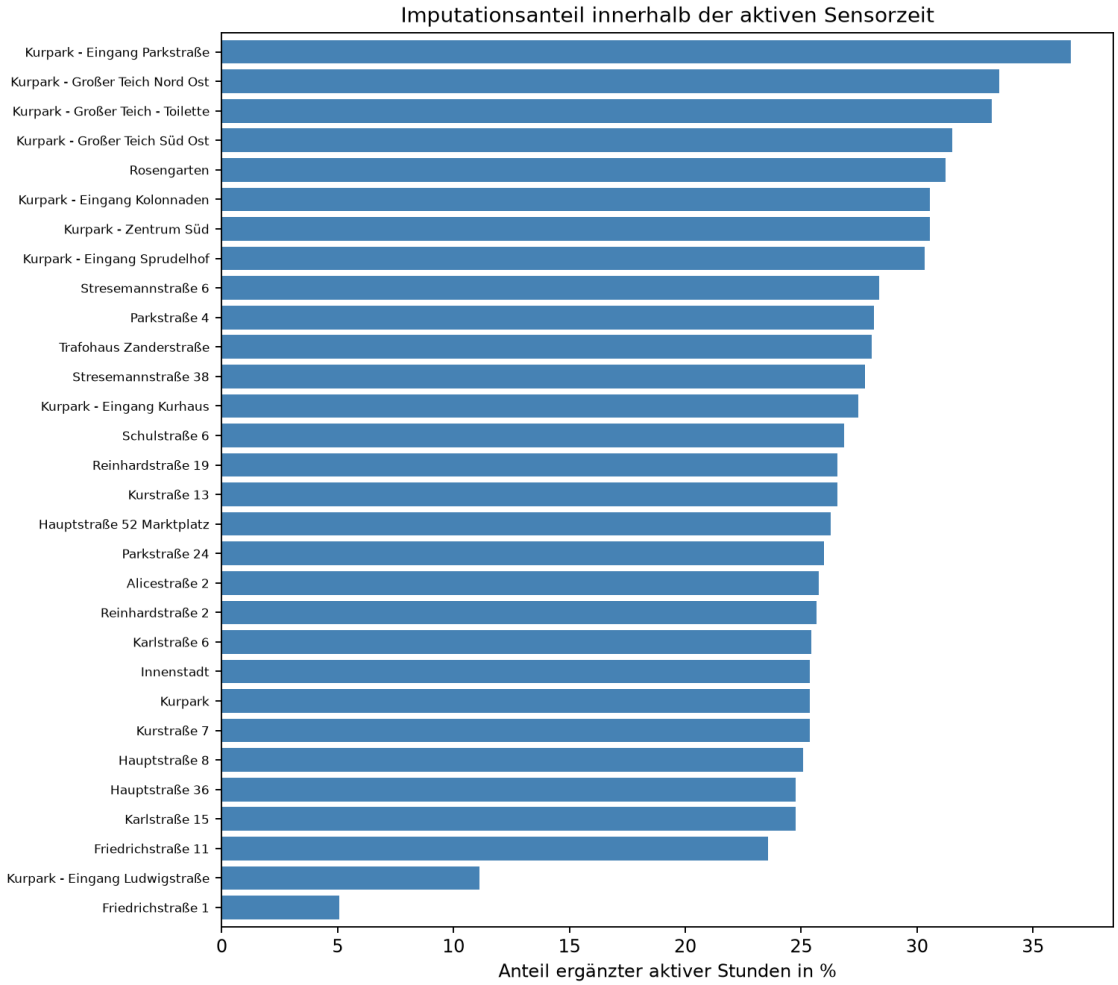


Abbildung 4.5: Anteil ergänzter Stunden innerhalb der aktiven Zeit jedes Sensors. Eigene Darstellung.

4.6.4 Kausale Hybridregel

Starke Einzelabweichungen werden unmittelbar erkannt. Für moderate, aber anhaltende Abweichungen wird zusätzlich eine kausale Persistenzregel verwendet:

$$A_t = \mathbf{1}(s_t > \tau_{\text{hoch}}) \ \vee \ \mathbf{1}\left(\sum_{j=0}^{m-1} \mathbf{1}(s_{t-j} > \tau_{\text{niedrig}}) \geq k\right). \tag{4.4}$$

Die Regel arbeitet je Sensor, betrachtet nur aktuelle und vergangene Scores und wird bei einer Zeitlücke oder einem imputierten Ziel zurückgesetzt. Aus 18 vorab festgelegten Kombinationen werden τ_{hoch}, τ_{niedrig}, m und k ausschließlich anhand synthetischer Anomalien im Kalibrierungsabschnitt gewählt. Zulässig sind nur Regeln mit höchstens 1 % Alarmen auf den unveränderten Kalibrierungswerten. Optimiert wird der über die Anomalietypen gleichgewichtete Ereignis-F1; die Injektionen des Testabschnitts beeinflussen diese Auswahl nicht.

4.6.5 Umgang mit imputierten Zielwerten

Imputierte Werte dürfen als markierter Kontext in ein Zeitfenster eingehen, werden aber nicht als Ziel für Training, Modellauswahl, Kalibrierung oder Forecast-Metriken verwendet. Eine fehlende Originalmessung wird unabhängig vom

Forecast als Datenqualitätsereignis ausgegeben. Dadurch wird ein aus einem Zeitprofil erzeugter Ersatzwert weder als reguläre Beobachtung noch als bestätigte Verhaltensanomalie fehlinterpretiert.

Kapitel 5

Evaluation der Methode

5.1 Zeitliche Datentrennung

Alle Teilmengen werden chronologisch und nicht zufällig gebildet. Dies verhindert, dass spätere Stunden als Lernbeispiele für frühere Prognosen verwendet werden. Tabelle 5.1 nennt die Grenzen und die Anzahl tatsächlich gemessener Zielpunkte nach dem 24-Stunden-Windowing.

Tabelle 5.1: Chronologische Teilmengen des Forecasters. Alle Grenzen sind in UTC angegeben. Eigene Darstellung.

Teilmenge	Beginn	Ende (exklusiv)	Zielpunkte
Training	erster möglicher Zielwert	08.07.2025	4.111
Tuning	08.07.2025	09.07.2025	318
Kalibrierung	09.07.2025	10.07.2025	368
Test	10.07.2025	Reihenende	1.346

Auf dem Tuningabschnitt werden zwei kleine LSTM-Konfigurationen verglichen. Das Auswahlkriterium ist der über beide Zielgrößen gemittelte relative MAE gegenüber der saisonalen $t - 24$-Naive-Prognose. Nach dem Refit bestimmt der Kalibrierungsabschnitt zunächst die Nichtkonformitätsschwelle und anschließend die Persistenzregel. Der Testabschnitt wird für keine dieser Entscheidungen verwendet.

5.2 Bewertung der Prognosegüte

Die Medianprognose $q_{0,5}$ wird mit MAE und RMSE bewertet. Zusätzlich wird die saisonal skalierte mittlere absolute Abweichung (MASE) nach Hyndman und Koehler berichtet [4]:

$$\mathrm{MASE} = \frac{H^{-1} \sum_{h=1}^{H} |y_{T+h} - \hat{y}_{T+h}|}{(T-24)^{-1} \sum_{t=25}^{T} |y_t - y_{t-24}|}. \tag{5.1}$$

Der Nenner wird ausschließlich aus gemessenen Trainingszielen berechnet. Damit ist MASE von dem ergänzend angegebenen Verhältnis $\mathrm{MAE}_{\mathrm{Modell,Test}} / \mathrm{MAE}_{t-24,\mathrm{Test}}$ zu unterscheiden. Werte unter eins bedeuten jeweils eine Verbesserung gegenüber der zugehörigen Skalierung beziehungsweise Testbaseline.

Für die empirisch kalibrierten Intervalle werden die marginale Abdeckung je Zielgröße, die gemeinsame Abdeckung beider Zielgrößen und die mittlere Intervallbreite ausgewiesen. Eine hohe Abdeckung allein ist nicht hinreichend, da sie durch sehr breite und damit wenig trennscharfe Intervalle erreichbar wäre.

5.3 Synthetische Anomalieinjektion

Reale Anomalieklassen liegen nicht vor. Deshalb wird die technische Erkennungsfähigkeit ergänzend mit kontrollierten Injektionen geprüft. Dieses Vorgehen liefert eindeutige Labels für genau definierte Fehlertypen, ersetzt aber keine Evaluation realer Ereignisse [9]. Die Anomalien werden ausschließlich in ursprünglich gemessene Werte injiziert, bevor Zeitfenster erzeugt und Prognosen berechnet werden. Damit beeinflussen mehrstündige Ereignisse den nachfolgenden Modellkontext wie reale Messwerte.

Untersucht werden ein einstündiger positiver Spike, ein einstündiger Dip, ein vierstündiger Level-Shift, ein über vier Stunden ansteigender Drift und ein sechsstündiger Stuck-at-Fehler. Mit Ausnahme von Stuck-at werden beide Zielgrößen und bei den mehrstündigen Typen beide Richtungen abgedeckt. Die Stärken 0,5, 1,0 und 2,0 beziehen sich auf sensor- und merkmalsabhängige robuste $\log(1+x)$-IQR-Einheiten. Stuck-at friert ein Merkmal auf die letzte vorherige Messung ein; Ereignisse mit weniger als 0,5 realisierter IQR-Abweichung werden verworfen, weil sie keine belastbare künstliche Veränderung darstellen.

Die Auswahl der Alarmregel verwendet drei feste Seeds im Kalibrierungsabschnitt und nur die Stärken 1,0 und 2,0. Der endgültige Benchmark verwendet drei andere feste Seeds im Testabschnitt und schließt 0,5 als Sensitivitätsanalyse ein. Pro Lauf wird höchstens ein Ereignis je Sensor erzeugt. Jede injizierte Reihe wird mit einem identischen unveränderten Gegenlauf gepaart. Ein Treffer zählt nur, wenn die Injektion einen zusätzlichen Alarm hervorruft; ein bereits am gleichen Zeitpunkt bestehender Alarm wird nicht nachträglich als Erfolg der Injektion gewertet.

5.4 Punkt- und Ereignismetriken

Auf Punktebene werden Konfusionsmatrix, Precision, Recall, F1, ROC-AUC, PR-AUC und zeitliche Intersection over Union berechnet. Precision und Recall sind durch

$$\text{Precision} = \frac{TP}{TP+FP}, \qquad \text{Recall} = \frac{TP}{TP+FN} \tag{5.2}$$

definiert. Die PR-AUC ist wegen des starken Ungleichgewichts zwischen Normal- und Anomaliepunkten besonders informativ; ROC-AUC wird ergänzend ausgegeben.

Zusammenhängende stündliche Alarme desselben Sensors werden zusätzlich als Ereignisse gruppiert. Berichtet werden Ereignis-Precision, Ereignis-Recall, Ereignis-F1, mittlere zeitliche IoU und die Verzögerung bis zum ersten überlappenden Alarm. Diese Existenz- und Überlappungsdefinition ist eine bewusst einfache ereignisorientierte Auswertung und nicht das vollständige Metriksystem von Tatbul et al. [12]. Die ursprünglichen Punktvorhersagen werden nicht verändert. Insbesondere wird kein Point Adjustment verwendet, da es die gemessene Leistung stark überschätzen kann [5].

5.5 Reproduzierbarkeit

Die Pipeline wird aus dem Projektverzeichnis mit folgenden Befehlen ausgeführt:

```
py -3.12 -m src.preprocessing
py -3.12 -m src.forecaster.train
py -3.12 -m src.forecaster.evaluate
```

Bei unveränderten Rohdaten genügt für ein neues Modell die Ausführung der beiden letzten Befehle. Für die erneute Auswertung des bereits gespeicherten Modells reicht `py -3.12 -m src.forecaster.evaluate`. Modellparameter, Splits, Skalierung, Kalibrierung und Detektorregel werden in `model_bundle.json` gespeichert. Die Auswertung erzeugt unter anderem `evaluation_metrics.json`, `anomalies.csv`, `anomaly_events.csv`, `injection_benchmark.csv` und die Abbildung `anomalies_example.png`.

Kapitel 6

Ergebnisse

6.1 Modellauswahl und Detektorkalibrierung

Tabelle 6.1 zeigt die auf dem Tuningabschnitt ermittelten Werte der beiden LSTM-Konfigurationen. Der Mittelwert der beiden relativen MAE-Werte dient ausschließlich der Modellauswahl.

Tabelle 6.1: Ergebnis der LSTM-Auswahl auf dem Tuningabschnitt. Eigene Darstellung.

Modell	beste Epoche	MAE Visitors	MAE Duration	mittl. rel. MAE
Small	32	16,400	3,486	0,883
Regularized	21	15,176	3,598	0,851

Gewählt wird die regularisierte Konfiguration mit 64 LSTM-Einheiten, einer dichten Schicht mit 48 Einheiten, einem sechsdimensionalen Sensor-Embedding, Dropout 0,25 und einer Lernrate von 0,0005. Der Trainingsverlauf ist in Abbildung 6.1 dargestellt.

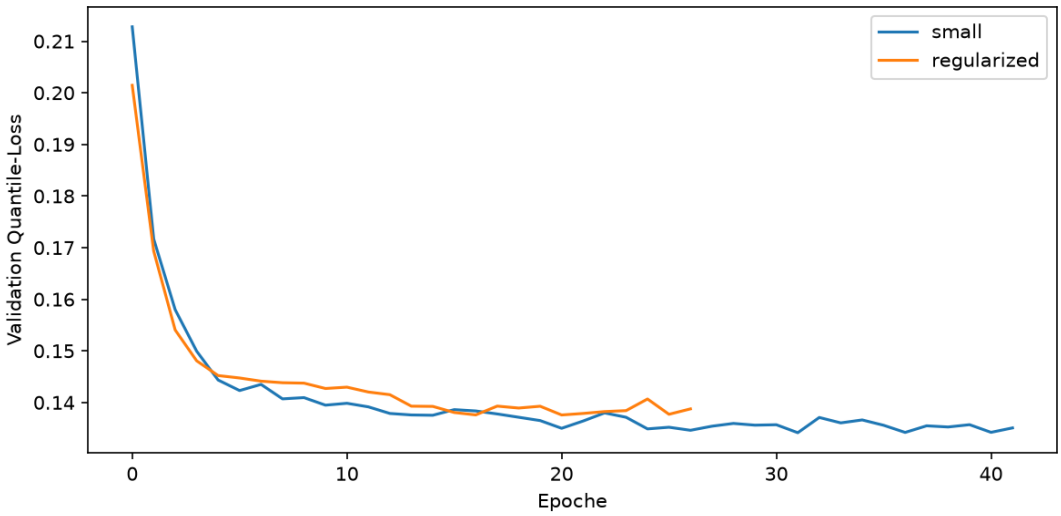


Abbildung 6.1: Validierungs-Pinball-Loss der beiden Modellkandidaten. Eigene Darstellung.

Die gemeinsame empirische 1-%-Schwelle beträgt 0,7486. Unter den 15 zulässigen Alarmregeln wählt die Kalibrierung zusätzlich die Bedingung, dass mindestens drei der letzten vier lückenlosen Messscores den niedrigeren Wert 0,3082

überschreiten. Auf den unveränderten 368 Kalibrierungspunkten erzeugt diese Regel zwei Alarme beziehungsweise 0,54 % und hält damit das vorab festgelegte 1-%-Budget ein. Der Macro-Ereignis-F1 der Kalibrierungsinjektionen beträgt 0,746. Dieser Wert ist ein Auswahlkriterium und kein Testergebnis.

6.2 Prognosegüte im Testabschnitt

Tabelle 6.2: Prognosegüte auf 1.346 gemessenen Testzielen. Die Abdeckung und Breite beziehen sich auf die empirisch kalibrierten Intervalle. Eigene Darstellung.

Ziel	MAE	RMSE	MASE	rel. MAE	Abdeckung	Breite
Visitors	12,114	22,962	0,622	0,745	99,63 %	224,99
AvgDuration	4,124	7,540	0,855	0,821	99,55 %	98,54

Beide MASE-Werte und beide relativen Test-MAE-Werte liegen unter eins. Die Medianprognose ist damit im Mittel genauer als die jeweils verwendete saisonale Skalierung beziehungsweise $t-24$-Testbaseline. Die gemeinsame empirische Abdeckung beider Zielgrößen beträgt 99,26 %. Gleichzeitig sind die Intervalle insbesondere für die Passantenzahl breit. Die hohe Abdeckung ist deshalb zusammen mit der Breite zu interpretieren und belegt allein keine hohe Trennschärfe des Anomaliedetektors.

6.3 Kandidaten im unveränderten Datensatz

Die eingefrorene Hybridregel markiert 15 der 1.346 gemessenen Testpunkte. Sie bilden elf zusammenhängende Forecast-Ereignisse. Die ursprüngliche reine 1-%-Punktschwelle hätte zehn Punkte markiert; die Persistenzregel ergänzt somit fünf moderate Punkte. Abbildung 6.2 zeigt den Sensor mit den meisten Forecast-Kandidaten. Die rote Markierung bedeutet eine statistische Abweichung und keine fachlich bestätigte Anomalie.

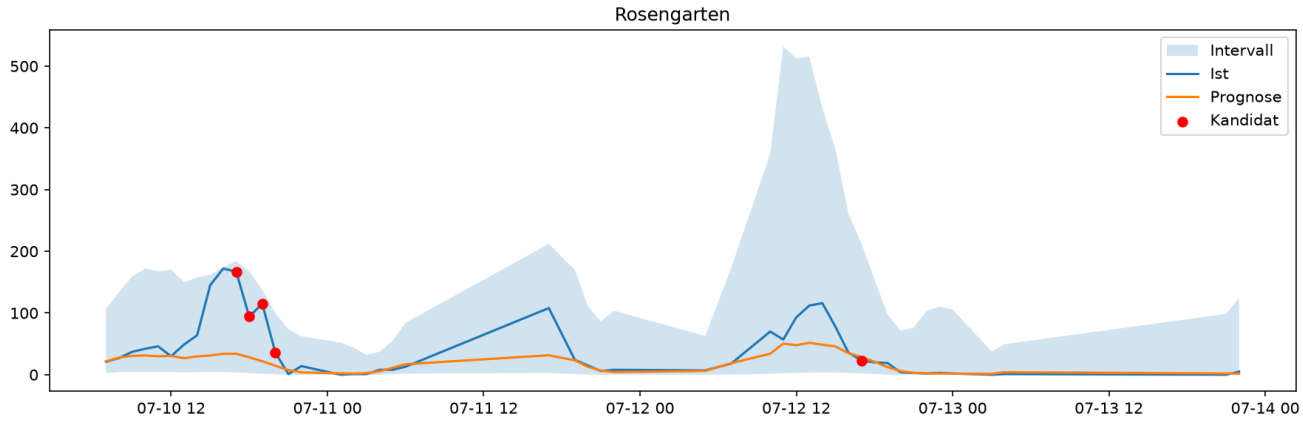


Abbildung 6.2: Messung, Medianprognose, empirisch kalibriertes Intervall und Forecast-Kandidaten eines Beispielsensors. Eigene Darstellung.

Zusätzlich besitzen 1.333 Testziele keine Originalmessung. Diese werden zu 275 zusammenhängenden Datenlücken-Ereignissen gruppiert und separat ausgewiesen. Sie sind Hinweise auf fehlende Sensordaten, aber nicht automatisch Anomalien des Passantenverhaltens. Werden Forecast- und Datenqualitätsalarme gemeinsam gruppiert, entstehen 282 Ereignisse; diese Zahl darf daher nicht als Anzahl erkannter Verhaltensanomalien interpretiert werden.

6.4 Ergebnisse der Anomalieinjektion

Tabelle 6.3 fasst die starken Injektionen der Stärke 2,0 und den gefilterten sechs Stunden langen Stuck-at-Test über drei Testseeds zusammen. Die Referenzspalten zeigen die unveränderte reine 1-%-Punktschwelle. Sämtliche Treffer sind inkrementell gegenüber dem jeweils gepaarten unveränderten Lauf.

Tabelle 6.3: Punkt- und Ereignisergebnisse der Testinjektionen. R = Recall, Ref. = Referenzdetektor. Eigene Darstellung.

Typ	Punkt-R	Punkt-F1	Ereignis-R	Ereignis-F1	Ref.-R	Ref.-F1
Spike, 2,0	0,633	0,732	0,633	0,767	0,633	0,775
Dip, 2,0	0,533	0,651	0,533	0,658	0,533	0,672
Level-Shift, 2,0	0,708	0,742	0,861	0,878	0,833	0,883
Drift, 2,0	0,458	0,543	0,750	0,810	0,694	0,780
Stuck-at, 6 h	0,237	0,345	0,371	0,499	0,315	0,404

Die Persistenzregel erhöht den Ereignis-Recall erwartungsgemäß bei mehrstündigen Veränderungen: bei starkem Level-Shift von 0,833 auf 0,861, bei starkem Drift von 0,694 auf 0,750 und bei Stuck-at von 0,315 auf 0,371. Für einstündige Spikes und Dips entsteht kein Recall-Gewinn. Bei Level-Shift und den punktuellen Typen sinkt der Ereignis-F1 geringfügig, weil zusätzliche Alarme die Precision belasten. Die Regel verbessert somit nicht jede einzelne Kennzahl, erhöht aber gezielt die Sensitivität für anhaltende Abweichungen, ohne die empirische Kalibrierungs-Alarmrate zu erhöhen.

Schwache Injektionen bleiben schwierig. Bei Stärke 0,5 beträgt der Ereignis-Recall 0,067 für Spike, 0,017 für Dip, 0,167 für Level-Shift und 0,028 für Drift. Der Detektor erkennt folglich nicht jede definierte Anomalie. Die vollständigen Werte aller Stärken einschließlich Precision, PR-AUC, IoU und Verzögerung stehen in `injection_benchmark.csv` und `injection_benchmark.json`.

6.5 Diskussion und Limitationen

Die Ergebnisse beantworten die Forschungsfrage differenziert. Der globale Quantil-Forecaster übertrifft die saisonale Baseline im mittleren Prognosefehler. Starke punktuelle und mehrstündige Injektionen werden teilweise bis überwiegend erkannt; die zusätzliche Persistenz verbessert vor allem Level-Shift, Drift und Stuck-at. Für schwache Anomalien und einzelne Dips ist die Sensitivität gering.

Die synthetische Ground Truth gilt ausschließlich für die definierten Transformationen. Sie belegt weder den Recall unbekannter realer Anomalien noch die fachliche Richtigkeit der elf Kandidaten im Originaldatensatz. Der nur zwei Wochen umfassende Datensatz begrenzt außerdem die beobachtbaren Wochenmuster und die Größe von Tuning und Kalibrierung. Zeitliche Abhängigkeit verhindert eine klassische verteilungsfreie Conformal-Garantie. Schließlich wurde der Testzeitraum im Verlauf der retrospektiven Entwicklung bereits betrachtet; die Testinjektionen sind durch neue Seeds und eine eingefrorene Regel getrennt, stellen aber keine vollständig unangetastete konfirmatorische Studie dar.

Kapitel 7

Zusammenfassung und Ausblick

Anhang A

Programmcode

Literatur

[1] Rina Foygel Barber u. a. "Conformal Prediction Beyond Exchangeability". In: *The Annals of Statistics* 51.2 (2023), S. 816–845. DOI: 10.1214/23-AOS2276.

[2] Gavin C. Cawley und Nicola L. C. Talbot. "On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation". In: *Journal of Machine Learning Research* 11 (2010), S. 2079–2107. URL: https://www.jmlr.org/papers/v11/cawley10a.html.

[3] Sepp Hochreiter und Jürgen Schmidhuber. "Long Short-Term Memory". In: *Neural Computation* 9.8 (1997), S. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.

[4] Rob J. Hyndman und Anne B. Koehler. "Another Look at Measures of Forecast Accuracy". In: *International Journal of Forecasting* 22.4 (2006), S. 679–688. DOI: 10.1016/j.ijforecast.2006.03.001.

[5] Siwon Kim u. a. "Towards a Rigorous Evaluation of Time-Series Anomaly Detection". In: *Proceedings of the AAAI Conference on Artificial Intelligence* 36.7 (2022), S. 7194–7201. DOI: 10.1609/aaai.v36i7.20680.

[6] Roger Koenker und Jr. Bassett Gilbert. "Regression Quantiles". In: *Econometrica* 46.1 (1978), S. 33–50. DOI: 10.2307/1913643.

[7] Yaniv Romano, Evan Patterson und Emmanuel J. Candès. "Conformalized Quantile Regression". In: *Advances in Neural Information Processing Systems*. Bd. 32. 2019, S. 3543–3553. URL: https://proceedings.neurips.cc/paper_files/paper/2019/hash/5103c3584b063c431bd1268e9b5e76fb-Abstract.html.

[8] David Salinas u. a. "DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks". In: *International Journal of Forecasting* 36.3 (2020), S. 1181–1191. DOI: 10.1016/j.ijforecast.2019.07.001.

[9] Sebastian Schmidl, Phillip Wenig und Thorsten Papenbrock. "Anomaly Detection in Time Series: A Comprehensive Evaluation". In: *Proceedings of the VLDB Endowment* 15.9 (2022), S. 1779–1797. DOI: 10.14778/3538598.3538602.

[10] Muhammad Awais Shafique. "Imputing Missing Data in Hourly Traffic Counts". In: *Sensors* 22.24 (2022), S. 9876. DOI: 10.3390/s22249876.

[11] Tuo Sun u. a. "Traffic Missing Data Imputation: A Selective Overview of Temporal Theories and Algorithms". In: *Mathematics* 10.14 (2022), S. 2544. DOI: 10.3390/math10142544.

[12] Nesime Tatbul u. a. "Precision and Recall for Time Series". In: *Advances in Neural Information Processing Systems*. Bd. 31. 2018, S. 1920–1930. URL: https://proceedings.neurips.cc/paper_files/paper/2018/hash/8f468c873a32bb0619eaeb2050ba45d1-Abstract.html.

[13] Yimei Zhang u. a. "A Comprehensive Survey on Traffic Missing Data Imputation". In: *IEEE Transactions on Intelligent Transportation Systems* 25.12 (2024), S. 19252–19275. DOI: 10.1109/TITS.2024.3478816.